

НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ЯДЕРНЫЙ УНИВЕРСИТЕТ «МИФИ»

Институт интеллектуальных кибернетических систем
Кафедра № 42 «Криптология и кибербезопасность»
Направление 01.04.02 «Прикладная математика и информатика»

Выпускная квалификационная работа магистра

Метод выявления манипулированных видео на основе пространственно-временного анализа: детектирование подмены лиц и синтетических видеопоследовательностей

Студент группы М24-525: Тараканов Александр Алексеевич

Научный руководитель: к.э.н., доцент Смирнов Дмитрий Сергеевич

Консультант: ведущий разработчик Копылов Иван Станиславович

Актуальность и проблема

Deepfake - реалистичные синтетические видео (face swap, reenactment, lip-sync)

Угрозы: дезинформация, мошенничество, шантаж, подрыв доверия к видеоконтенту

Покадровые детекторы (XceptionNet, EfficientNet):

AUC 99%+ in-domain, но падение на 15-25% при cross-dataset оценке

Пространственные артефакты нестабильны при смене метода генерации

Ключевой пробел:

Параллельное извлечение пространственных и временных признаков с явным временным входом в литературе встречается реже, чем последовательные и 3D-свёрточные подходы

Большинство методов рассматривают кадры независимо или используют последовательный pipeline (CNN+LSTM)

Цель и задачи исследования

Цель:

Разработка метода детектирования манипулированных видео на основе параллельного пространственно-временного анализа и его экспериментальная оценка

Задачи:

1. Анализ существующих методов детектирования deepfake
2. Исследование пространственных и временных признаков манипуляций
3. Разработка dual-path архитектуры с параллельными ветвями
4. Программная реализация и обучение модели
5. Экспериментальная оценка: ablation study, $T=16$ vs $T=32$, multi-dataset, cross-dataset

Обзор существующих подходов

Покадровые методы

XceptionNet, EfficientNet-B4

Высокая in-domain AUC (~99%)

Плохая обобщающая способность

Последовательные (CNN→LSTM)

Temporal зависит от spatial encoder

Ошибки spatial каскадируются

3D CNN (AltFreezing, I3D)


Неразделимость вкладов spatial/temporal

5 ключевых ограничений

1. Зависимость от dataset-specific артефактов
2. Последовательная обработка (spatial→temporal)
3. Неявное кодирование временных признаков
4. Неразделимость вклада компонентов
5. Отсутствие интерпретируемого слияния

→ Мотивация: dual-path architecture

Предлагаемый метод: архитектура



Ключевое свойство: параллельность ветвей, explicit temporal input (frame differences), интерпретируемое слияние

Ключевые архитектурные решения

Temporal Input

Frame differences vs optical flow vs raw RGB

Компромисс: явное кодирование
темпоральных изменений +
сохранение цветовой информации

Размер основной сети

EfficientNet-B4 (spatial) vs B0 (temporal)

Разная сложность входных данных:
RGB кадры vs разностные карты
Более лёгкая сеть для временной ветви

Sequence Model

Transformer vs LSTM для temporal

Глобальные зависимости при $T-1=15$
Self-attention эффективнее
для коротких последовательностей

Fusion Strategy

Adaptive weighted fusion

Интерпретируемость:
 $\alpha_{\text{spatial}} + \alpha_{\text{temporal}} = 1$
Обучаемые веса ветвей

Протокол обучения

Данные

3 датасета (DFDC02+DFD01+CelebDF): ~10000 видео

Разделение по video-ID - одно видео не попадает и в train, и в val

Clip-consistent augmentation - одна и та же аугментация на всех кадрах клипа

Оптимизация

AdamW - стандартный оптимизатор для дообучения предобученных сетей

Разные скорости обучения: основная сеть $1e-4$ (бережём ImageNet-веса), классификатор $3e-4$

CosineAnnealing LR scheduler - плавное снижение скорости обучения

Стратегия обучения

Warmup (прогрев): первые 5 эпох основная сеть заморожена, учим только классификатор

Разморозка: дообучаем 2 последних блока основной сети

Early stopping - автоостановка (patience=7: 7 эпох без прироста → стоп)

AUC - главная метрика, по ней выбирается лучшая версия модели

Инфраструктура

Kaggle P100 GPU - бесплатный облачный GPU для обучения

30 эпох максимум - верхний предел, реально остановились на эп. 28+7

Mixed precision (AMP) - умножения в fp16, градиенты в fp32. Без этого batch=8 не влезал бы в 16 GB памяти GPU

[этап 1] Результаты: In-domain evaluation (DFDC02, T=16)

Метод	AUC	Accuracy	F1
Spatial-only (A2)	0.9835	0.9273	0.9250
Sequential CNN+BiLSTM (A4)	0.9715	0.9172	0.9130
Temporal-only (A3)	0.9655	0.9152	0.9075
Предлагаемый dual-path (A1)	0.9777	0.9253	0.9201

Ключевой вывод:

Spatial-only лидирует in-domain (AUC 0.9835) за счёт пространственных артефактов конкретного датасета

Dual-path (0.9777) объединяет оба типа сигналов; на cross-dataset переносе DFDC02 -> DFD01 dual-path 0.553 показал на 5 п.п. AUC лучше spatial 0.504

[ГЛАВНЫЙ РЕЗУЛЬТАТ] Ablation Study на 3DS, T=32

Модель (3 датасета, T=32)	AUC	Accuracy	EER
A1: Full dual-path	0.9943	96.7%	0.041
A2: Spatial-only	0.9904	95.8%	0.047
A3: Temporal-only	0.9883	95.4%	0.046
A4: Sequential (BiLSTM)	0.9844	94.9%	0.057

Ключевые выводы:


Full dual-path (A1): AUC = 0.994, Accuracy = 96.7 %, F1 = 0.978, EER = 0.041 - наилучшая конфигурация

Масштабирование: 1DS→2DS→3DS + T=32 повысило AUC с 0.978 до 0.994


EER снизился на 66 % (0.121 → 0.041) при переходе T=16 → T=32

Кривые обучения и Val AUC на 1/2/3 конфигурациях


Кривые обучения (Train Loss). Обучение на 1 датасете (DFDC02), T=16




Кривые обучения (Train Loss). Обучение на 2 датасетах (DFDC02 + DF001), T=16




Кривые обучения (Train Loss). Обучение на 3 датасетах (DFDC02 + DF001 + Celeb-DF v2), T=16




Validation AUC по эпохам. Обучение на 1 датасете (DFDC02), T=16






Validation AUC по эпохам. Обучение на 2 датасетах (DFDC02 + DF001), T=16



Validation AUC по эпохам. Обучение на 3 датасетах (DFDC02 + DF001 + Celeb-DF v2), T=16




Ablation: сводка тест-метрик на 1/2/3 конфигурациях




Confusion Matrix и ROC (A1 Full, 3DS T=32)

fusion Matrix — celebdf+dfdc02+dfd01_full_seed42_bs8_T32_adaptive



ROC Curve — celebdf+dfdc02+dfd01_full_seed42_bs8_T32_adaptive



Анализ результатов: per-domain и cross-dataset

Per-domain AUC на тестовой выборке 3DS T=16:

DFDC02: AUC = 0.984

Celeb-DF v2: AUC = 0.997

DFD01: AUC = 0.574 ($n_{\text{real}}=54$)

Малое число real в DFD01 - оценка нестабильна

Cross-dataset DFDC02 -> DFD01:

A1 Full (dual-path): AUC = 0.553

A2 Spatial-only: AUC = 0.504

$\Delta = +0.049$ в пользу dual-path

Согласуется с DeepfakeBench [25]: 15-25 %
падение

Fusion веса (12 demo видео):

α_{spatial} для fakes: 0.928

α_{spatial} для real: 0.646

α_{temporal} для real: 0.354

Научная новизна и практическая значимость

1. Параллельная dual-path архитектура с явным временным входом (frame differences) - конкретная конфигурация EffNet-B4 + EffNet-B0 + Transformer + adaptive fusion
2. Систематическая ablation: 4 архитектуры x 2 значения T x 1/2/3 датасета в идентичных условиях
3. Воспроизводимый pipeline на PyTorch + Flask MVP, открытый код

Практическая значимость

Воспроизводимый pipeline (PyTorch, open-source код)

Flask MVP для анализа видео через веб-интерфейс

Кроссплатформенность: CUDA, MPS (Apple Silicon), CPU

Модульная архитектура: лёгкая замена компонентов

Полная документация экспериментов

Ограничения и направления развития

**Per-domain разница: DFD01 AUC = 0.574
(n_real=54, оценка нестабильна)**

Cross-dataset перенос: 43 % падение AUC
(0.978 → 0.553)

Бинарная классификация (без типа
манипуляции)

Только 3 датасета, 3 метода генерации

Адаптивный выбор T не реализован

A5 (concat) / A6 (gate) — реализованы в коде, не
прогнаны (~3 GPU-ч/конфиг.) — future work

Cross-dataset matrix (полный 6-парный перенос) —
ожидаемое падение AUC 15-25% (DeepfakeBench)

Направления развития

Расширение на FaceForensics++
(дополнительные датасеты и методы генерации)

Face alignment для нормализации геометрии

Мультимодальный анализ
(аудио + визуальные признаки)

Адаптация к диффузионным моделям
(Stable Diffusion Video, Sora)

Адаптивный T (dynamic frame count)

Заключение

Основные результаты:

1. Реализована dual-path архитектура: EffNet-B4 + EffNet-B0 + Transformer + adaptive fusion
2. На 3 датасетах при T=32 достигнуты AUC = 0.994, Acc = 96.7 %, F1 = 0.978, EER = 0.041
3. Полный воспроизводимый pipeline на PyTorch + Flask MVP

Ablation подтвердил вклад каждого компонента архитектуры

Cross-dataset проверка показала ожидаемую деградацию AUC ~ 43 %

Спасибо за внимание!

Готов ответить на ваши вопросы