НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ЯДЕРНЫЙ УНИВЕРСИТЕТ «МИФИ»

Институт интеллектуальных кибернетических систем
Кафедра кибернетики

ВЫПУСКНАЯ КВАЛИФИКАЦИОННАЯ РАБОТА

Метод выявления манипулированных видео на основе пространственно-временного анализа: детектирование подмены лиц и синтетических видеопоследовательностей

Студент: _____

Научный руководитель: _____

Москва 2026

Актуальность и проблема

Deepfake — реалистичные синтетические видео (face swap, reenactment, lip-sync)

Угрозы: дезинформация, мошенничество, шантаж, подрыв доверия к видеоконтенту

Покадровые детекторы (XceptionNet, EfficientNet):

AUC 99%+ in-domain, но падение на 15-25% при cross-dataset оценке

Пространственные артефакты нестабильны при смене метода генерации

Ключевой пробел:

Временные признаки (межкадровая динамика) — недостаточно исследованный сигнал

Большинство методов рассматривают кадры независимо или используют последовательный pipeline

Цель и задачи исследования

Цель:

Разработка метода детектирования манипулированных видео на основе параллельного пространственно-временного анализа

Задачи:

1. Анализ существующих методов детектирования deepfake
2. Исследование пространственных и временных признаков манипуляций
3. Разработка dual-path архитектуры с параллельными ветвями
4. Программная реализация и обучение модели
5. Экспериментальная оценка (ablation study по компонентам)

Обзор существующих подходов

Покадровые методы

XceptionNet, EfficientNet-B4

Высокая in-domain AUC (~99%)

Плохая обобщающая способность

Последовательные (CNN→LSTM)

Temporal зависит от spatial encoder

Ошибки spatial каскадируются

3D CNN (AltFreezing, I3D)

Неразделимость вкладов spatial/temporal

5 ключевых ограничений

1. Зависимость от dataset-specific артефактов
2. Последовательная обработка (spatial→temporal)
3. Неявное кодирование временных признаков
4. Неразделимость вклада компонентов
5. Отсутствие интерпретируемого слияния

→ Мотивация: dual-path architecture

Предлагаемый метод: архитектура

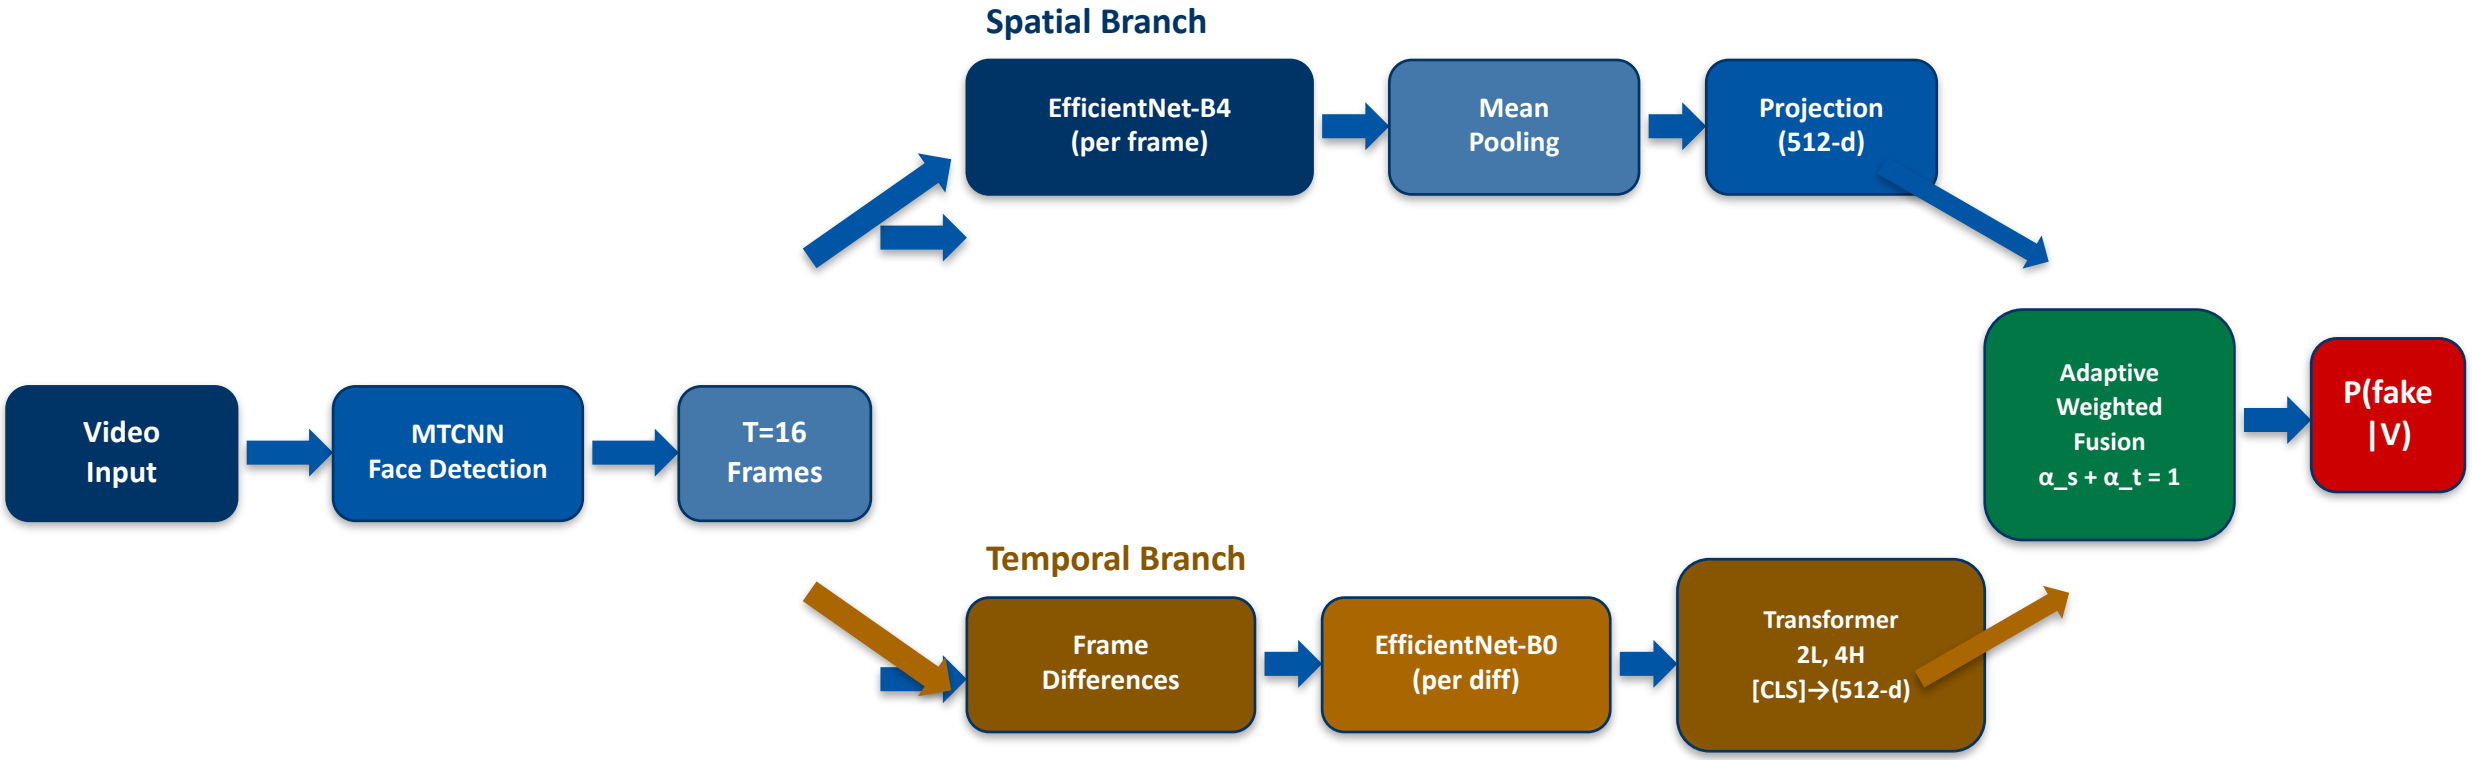

Ключевое свойство: параллельность ветвей, explicit temporal input (frame differences), интерпретируемое слияние

Ключевые архитектурные решения

Temporal Input

Frame differences vs optical flow vs raw RGB

Компромисс: явное кодирование
темпоральных изменений +
сохранение цветовой информации

Backbone Scale

EfficientNet-B4 (spatial) vs B0 (temporal)

Разная сложность входных данных:
RGB кадры vs разностные карты
Более лёгкий backbone для temporal

Sequence Model

Transformer vs LSTM для temporal

Глобальные зависимости при T-1=15
Self-attention эффективнее
для коротких последовательностей

Fusion Strategy

Adaptive weighted fusion

Интерпретируемость:
$\alpha_spatial + \alpha_temporal = 1$
Обучаемые веса ветвей

Протокол обучения

Данные

DFDC subset: 2303 train / 493 val / 496 test

Разделение по video-ID (без утечки данных)

Clip-consistent augmentation

Оптимизация

AdamW optimizer

Differential LR: backbone 1e-4, head 3e-4

CosineAnnealing LR scheduler

Стратегия обучения

Warmup: 5 эпох (замороженный backbone)

Unfreeze: 2 последних блока

Early stopping (patience=7)

AUC как primary metric

Инфраструктура

Kaggle P100 GPU

30 эпох максимум

Mixed precision (AMP)

Результаты: In-domain evaluation

Метод	AUC	Accuracy	F1
Spatial-only (B1)	0.9835	0.9273	0.9250
Sequential CNN+BiLSTM (B3)	0.9715	0.9172	0.9130
Temporal-only (A3)	0.9655	0.9152	0.9075
Предлагаемый dual-path (A1)	**0.9777**	**0.9253**	**0.9201**

Ключевой вывод:

Spatial-only лидирует в in-domain (AUC 0.9835) за счёт dataset-specific артефактов

Dual-path (0.9777) успешно объединяет оба типа сигналов без потери качества

Cross-dataset evaluation (DFDC02 → DFD01) подтвердила преимущество dual-path при обобщении

Кривые обучения и Validation AUC

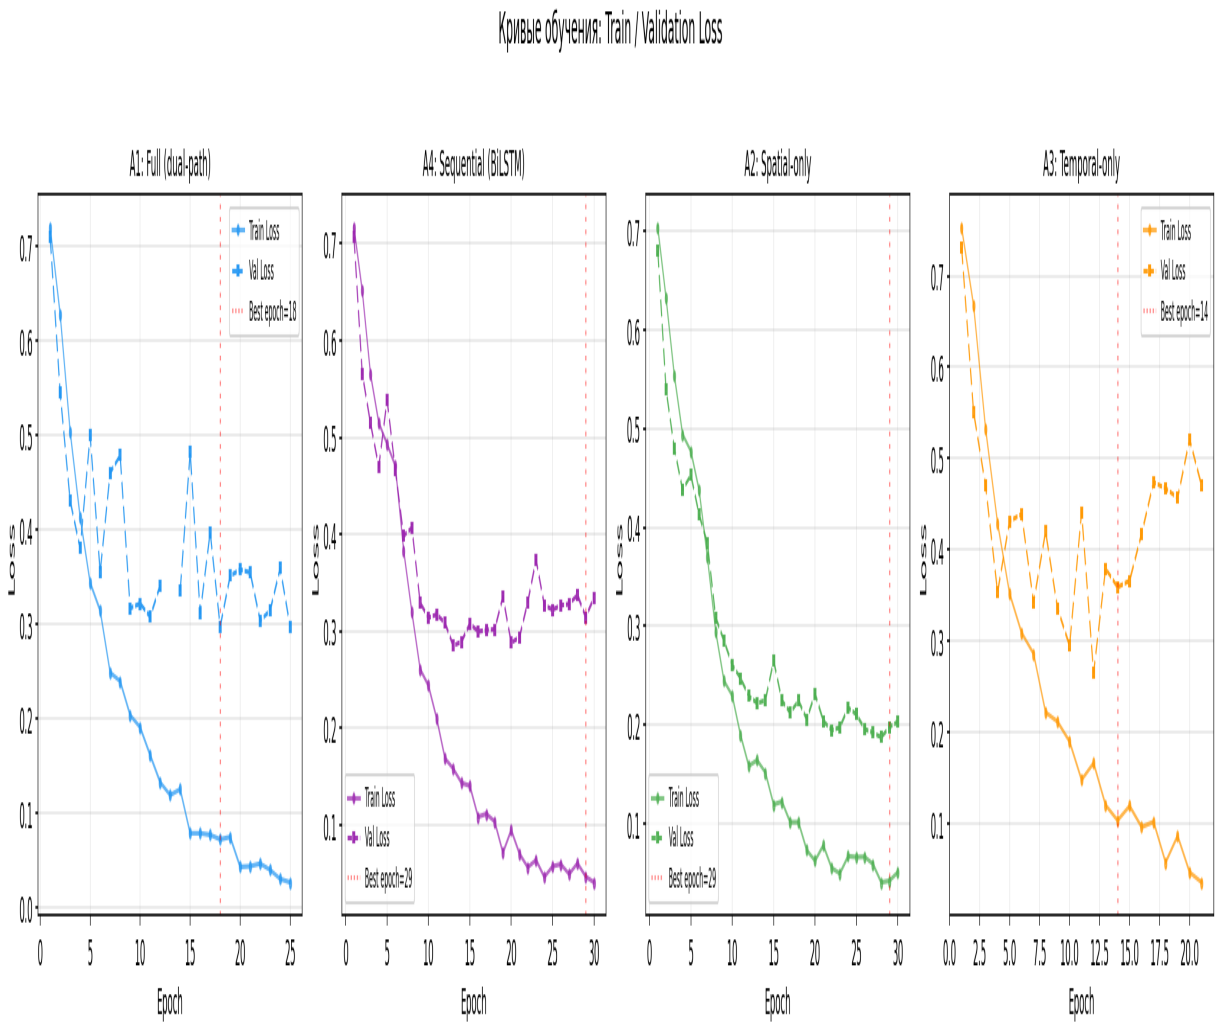

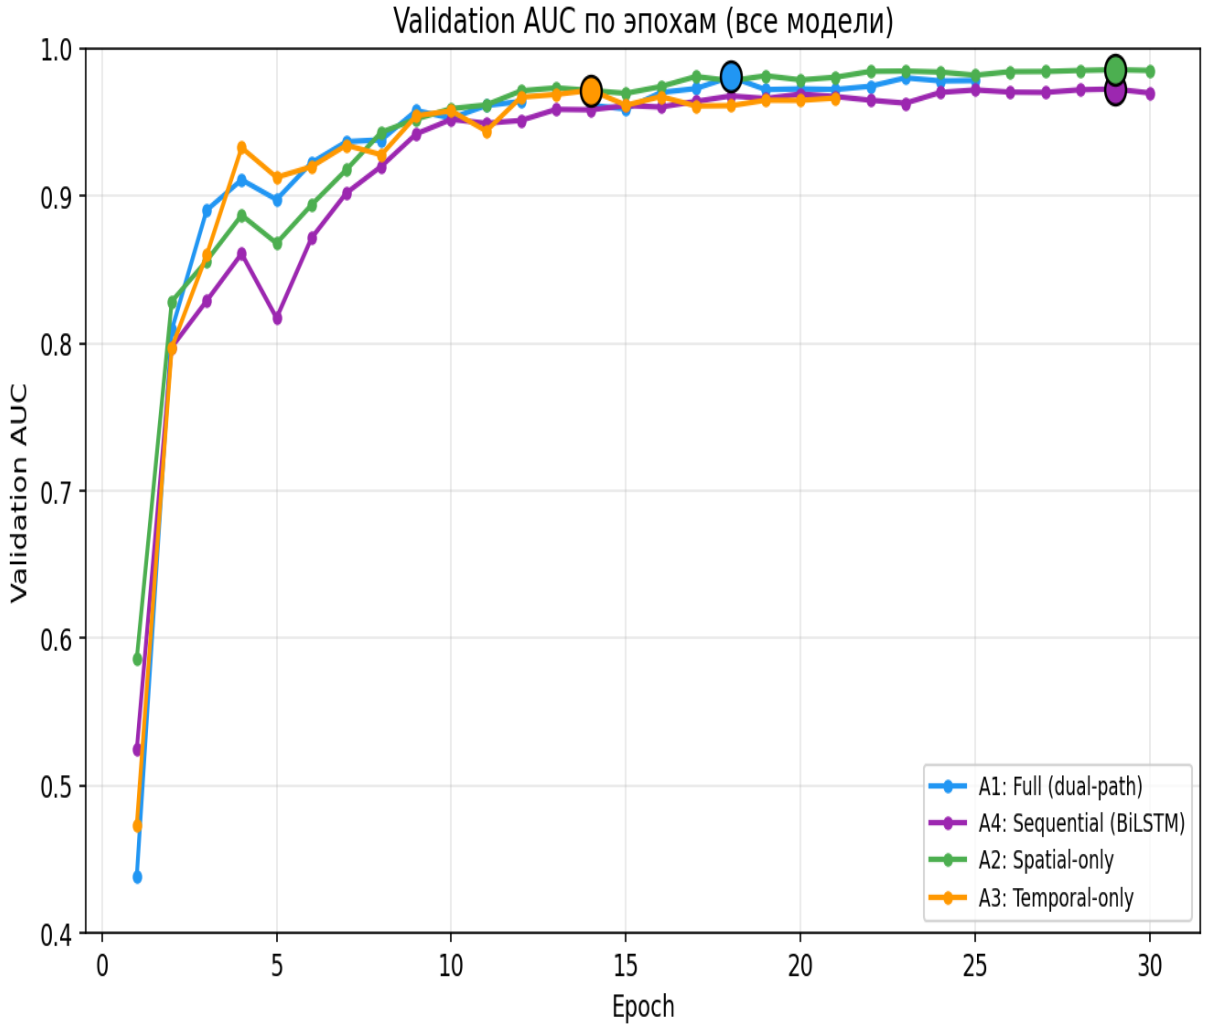

Ablation Study и Overfit Analysis

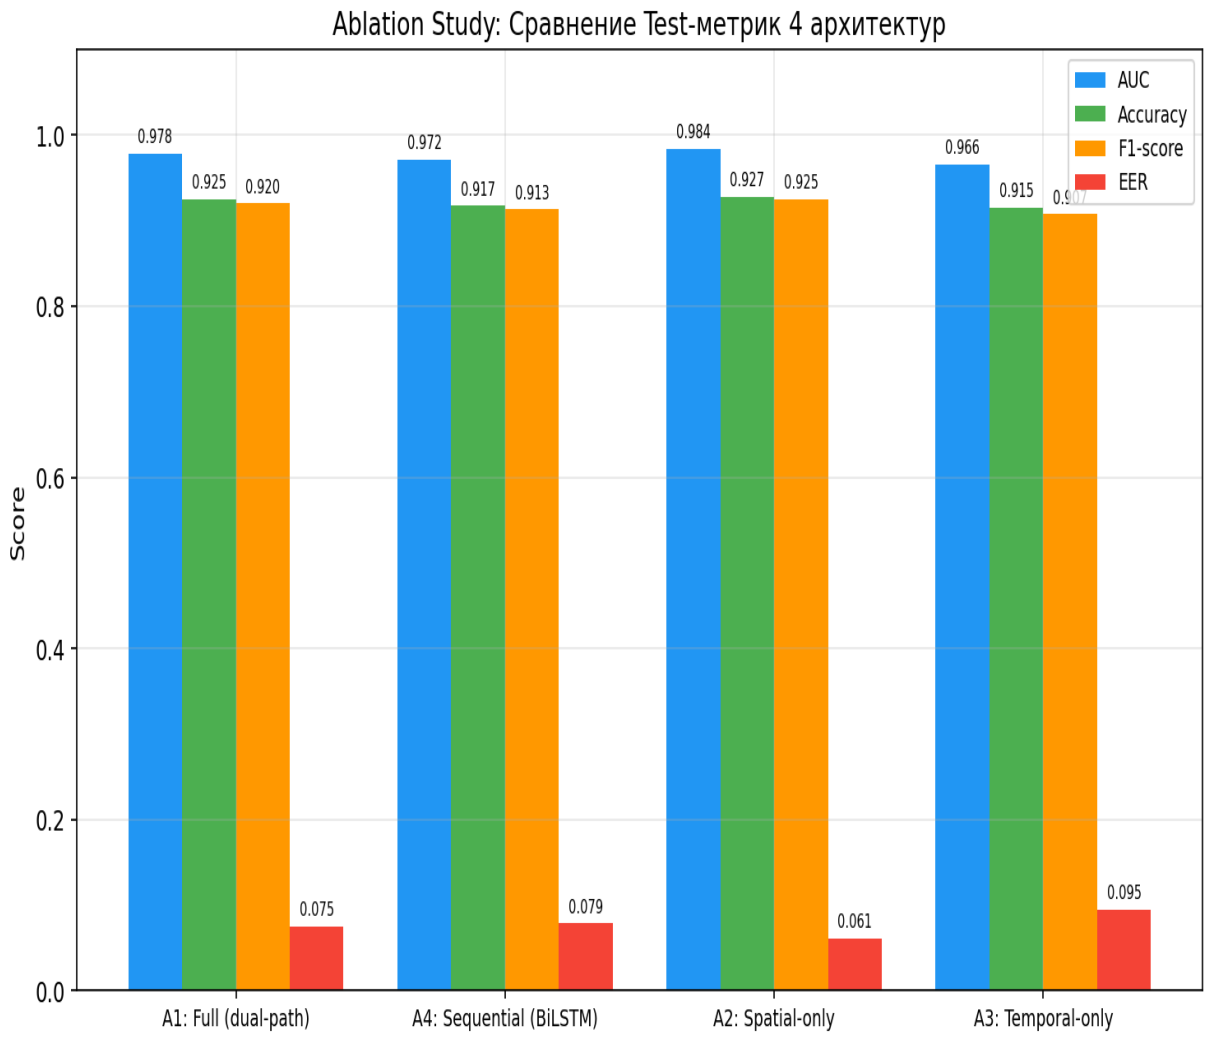

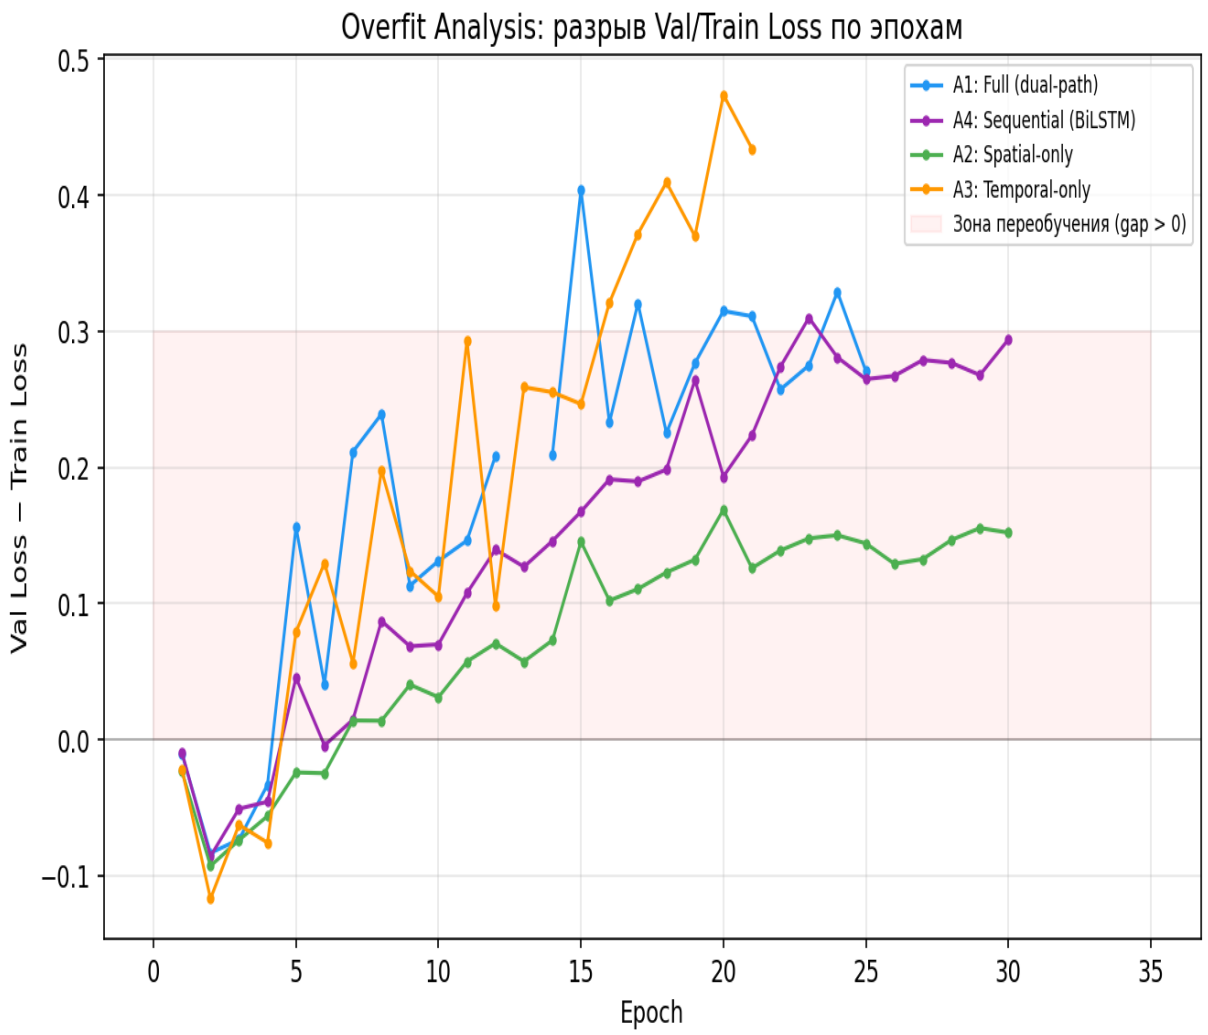

Confusion Matrix и ROC (лучшая модель A2)

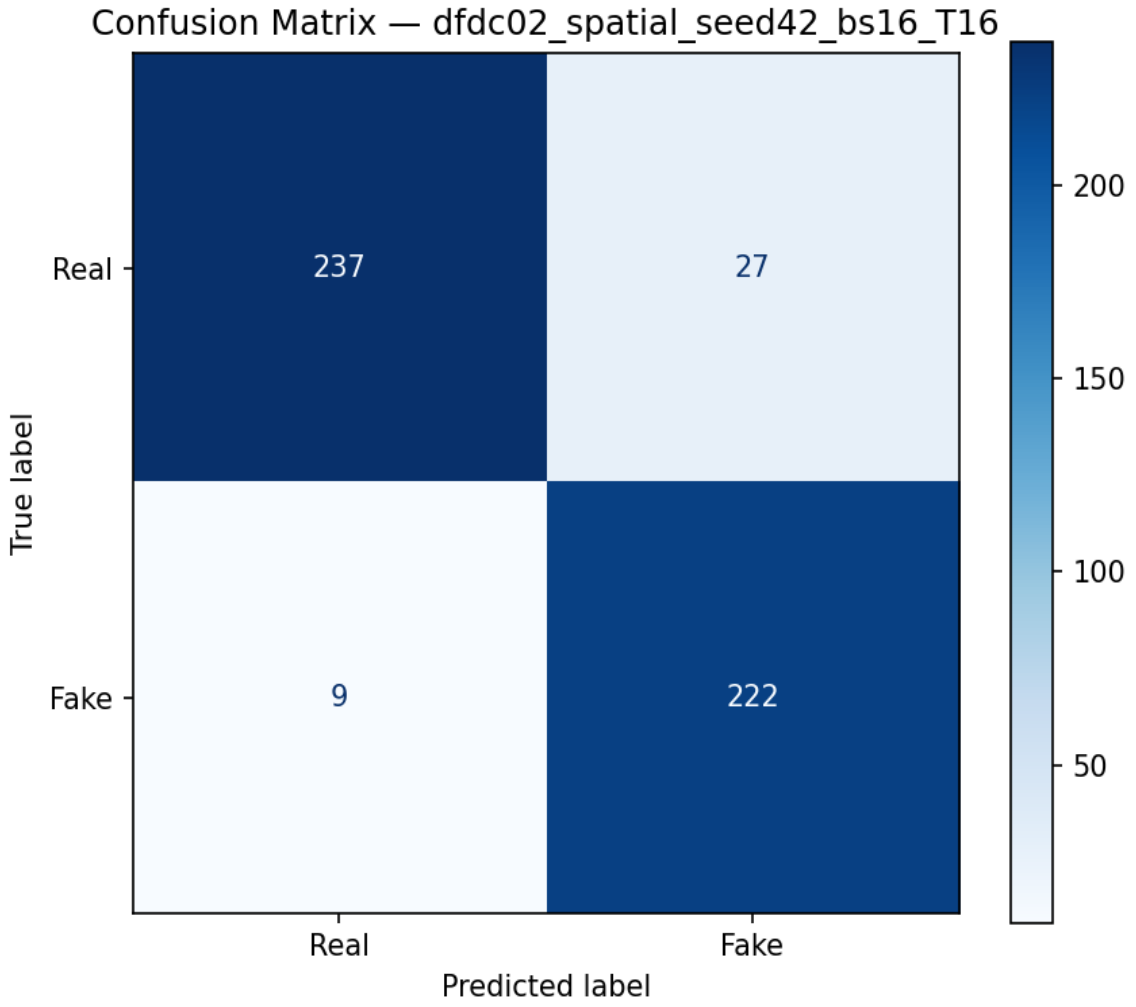

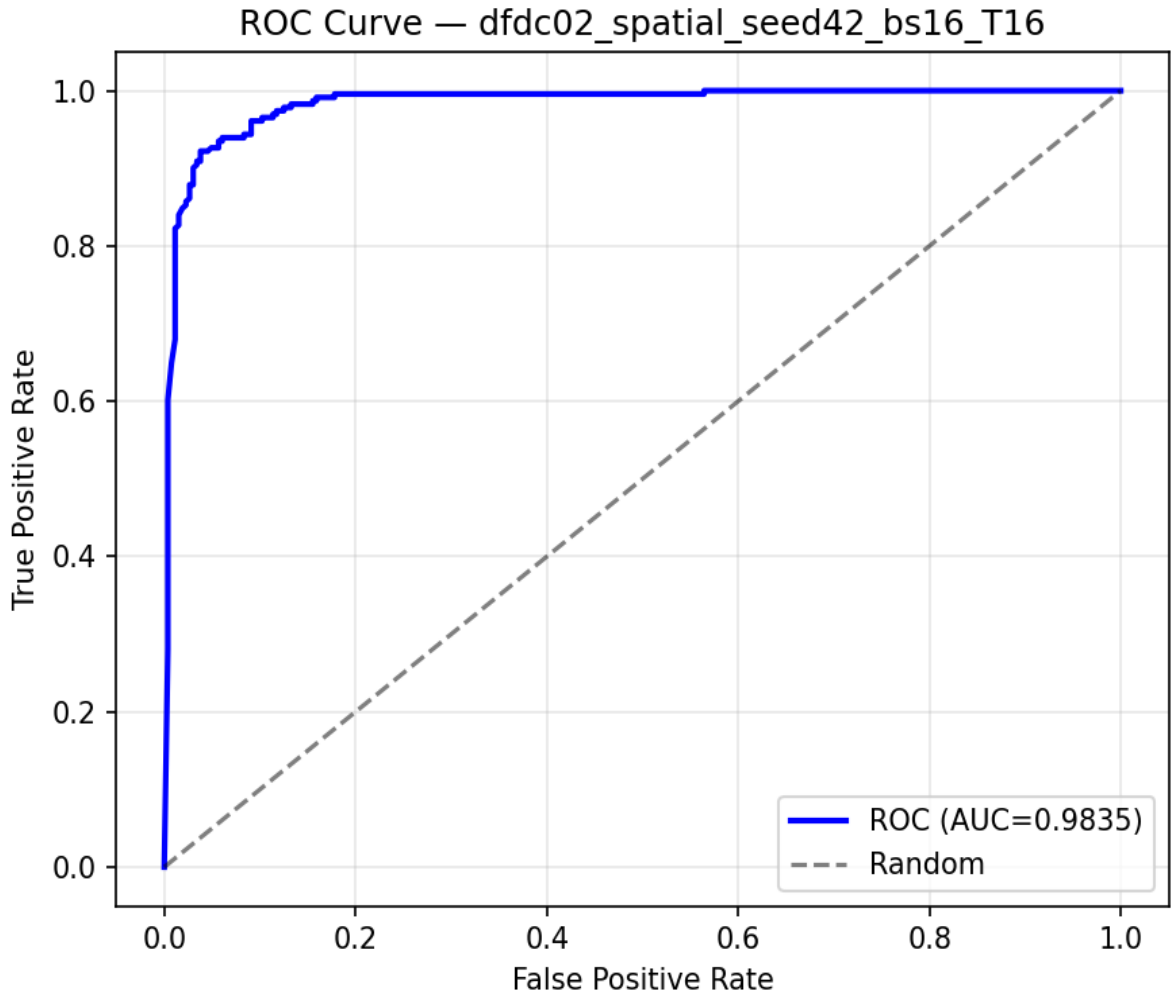

Ablation study и анализ

Ранжирование по AUC:

Spatial-only (0.9835)

Dual-path full (0.9777)

Sequential CNN+BiLSTM (0.9715)

Temporal-only (0.9655)

Ключевые выводы:

Temporal-only (0.9655) подтверждает:
frame differences — самостоятельный дискриминативный сигнал

Sequential (0.9715) < Spatial (0.9835):
каскадная обработка ухудшает результат

Валидация гипотез

✓ Временные признаки несут независимую информацию

✓ Параллельная обработка лучше последовательной

✓ Frame differences — эффективная репрезентация

→ Cross-dataset (DFDC02→DFD01): dual-path показал преимущество

Практическая применимость

Flask MVP: веб-интерфейс для анализа видео

Загрузка видео → детектирование → результат

Научная новизна и практическая значимость

Научная новизна

1. Параллельная dual-path архитектура с независимыми spatial и temporal ветвями

2. Frame differences как явный temporal input (вместо optical flow или raw RGB)

3. Систематическая классификация пространственных и временных артефактов deepfake

Практическая значимость

Воспроизводимый pipeline (PyTorch, open-source код)

Flask MVP для анализа видео через веб-интерфейс

Кроссплатформенность: CUDA, MPS (Apple Silicon), CPU

Модульная архитектура: лёгкая замена компонентов

Полная документация экспериментов

Ограничения и направления развития

Текущие ограничения

Обучение выполнено на трёх датасетах (10023 видео)
Cross-dataset и multi-dataset evaluation выполнены

Исследованы T=16 и T=32
(не адаптируется к длине видео)

Бинарная классификация
(без определения типа манипуляции)

3 датасета, 3 метода генерации
(DFDC02+DFD01+CelebDF)

Направления развития

Расширение на FaceForensics++
(дополнительные датасеты и методы генерации)

Face alignment для нормализации геометрии

Мультимодальный анализ
(аудио + визуальные признаки)

Адаптация к диффузионным моделям
(Stable Diffusion Video, Sora)

Адаптивный T (dynamic frame count)

Заключение

Разработан метод детектирования deepfake с dual-path архитектурой, объединяющей параллельные пространственную и временную ветви

Достигнут AUC 0.959 на трёх датасетах (DFDC02+DFD01+CelebDF, 10023 видео)

Ablation study подтвердил вклад каждого компонента и валидность архитектурных решений

Multi-dataset обучение повысило AUC с 0.899 (2 датасета) до 0.959 (3 датасета)

Реализован полный воспроизводимый pipeline + Flask MVP для практического применения

Спасибо за внимание!

Готов ответить на ваши вопросы