

**МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ
ФЕДЕРАЦИИ**

**НАЦИОНАЛЬНЫЙ ИССЛЕДОВАТЕЛЬСКИЙ ЯДЕРНЫЙ УНИВЕРСИТЕТ
«МИФИ»**

ИНСТИТУТ ИНТЕЛЛЕКТУАЛЬНЫХ КИБЕРНЕТИЧЕСКИХ СИСТЕМ

КАФЕДРА № 42 «КРИПТОЛОГИЯ И КИБЕРБЕЗОПАСНОСТЬ»

На правах рукописи
УДК _____

Тараканов Александр Алексеевич

**«Метод выявления манипулированных видео на основе
пространственно-временного анализа: детектирование подмены лиц и
синтетических видеопоследовательностей»**

Выпускная квалификационная работа магистра

Программа подготовки магистра «Машинное обучение»
Направление подготовки 01.04.02 «Прикладная математика и информатика»

Студент группы М24-525
Научный руководитель: к.э.н., доцент
Консультант: ведущий разработчик

Тараканов А.А.
Смирнов Д.С.
Копылов И.С.

Выпускная квалификационная работа защищена

«__»_____ 2026 г.

Оценка _____

Секретарь ГЭК _____

г. Москва
2026

РЕФЕРАТ

Магистерская диссертация: 74 с., 15 рис., 12 табл., 43 источника, 4 приложения.

DEERFAKE, ДЕТЕКТИРОВАНИЕ МАНИПУЛИРОВАННЫХ ВИДЕО, ПРОСТРАНСТВЕННО-ВРЕМЕННОЙ АНАЛИЗ, СВЁРТОЧНЫЕ НЕЙРОННЫЕ СЕТИ, ТРАНСФОРМЕР, ДВУХВЕТВЕВАЯ АРХИТЕКТУРА, ABLATION STUDY, EFFICIENTNET, FRAME DIFFERENCES

Объектом исследования являются манипулированные видеопоследовательности, содержащие подмену лиц и синтетически сгенерированный лицевой контент.

Цель работы - разработка метода автоматического выявления манипулированных видеопоследовательностей на основе пространственно-временного анализа.

Новизна предлагаемого метода. Новизна заключается в комбинации трёх компонентов, не встречавшихся одновременно в литературе по deepfake detection: (1) параллельная dual-path архитектура с явным временным входом через разности кадров; (2) Transformer-based темпоральный энкодер (вместо классического CNN+LSTM); (3) обучаемое adaptive weighted fusion с интерпретируемыми весами α_{spatial} / α_{temporal} . Каждый компонент в отдельности используется в литературе, но именно их сочетание систематически измеряется в настоящей работе через ablation study (раздел 4.4) и анализ ошибок (раздел 4.5).

Предложен метод детектирования с параллельной двухветвевой архитектурой (dual-path), в которой пространственная ветвь (EfficientNet-B4) извлекает покадровые признаки из RGB-кадров, а временная ветвь (EfficientNet-B0 + Temporal Transformer Encoder) - признаки межкадровой динамики из нормированных разностей последовательных кадров. Признаки объединяются обучаемым механизмом adaptive weighted fusion (обучаемое

взвешенное объединение - механизм, в котором веса для пространственной и временной ветвей не задаются вручную, а изучаются автоматически в процессе обучения через градиентный спуск; нормированы через softmax в сумму 1), обеспечивающим интерпретируемость распределения вклада ветвей.

Проведена экспериментальная оценка на трёх наборах данных (DFDC02, DFD01 и Celeb-DF v2, общий объём около 10 000 видео) в четырёх измерениях: ablation четырёх архитектурных конфигураций, сравнение длины входной последовательности ($T = 16$ vs $T = 32$), влияние количества обучающих датасетов и cross-dataset перенос DFDC02 $\rightarrow$ DFD01. На наилучшей конфигурации (полная dual-path, $T = 32$, 3 датасета) достигнуты значения $AUC = 0.9943$, $Accuracy = 96.7\%$, $F1 = 0.978$ и $EER = 0.041$ на тестовой выборке.

Результаты работы могут быть использованы при проектировании систем автоматической верификации видеоконтента в задачах цифровой криминалистики и информационной безопасности, а также как воспроизводимый baseline для сравнительной оценки последующих методов детектирования.

СОДЕРЖАНИЕ

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ.....	5
ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ.....	5
ВВЕДЕНИЕ.....	6
ГЛАВА 1. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ.....	11
1.1. Таксономия манипуляций видеоконтента.....	11
1.2. Пространственные признаки манипулированного видеоконтента.....	12
1.3. Временные признаки манипулированного видеоконтента	14
1.4. Архитектурные подходы к извлечению признаков из видео	15
1.5. Метрики и протоколы оценки качества детектирования...	18
Выводы по главе 1.....	20
ГЛАВА 2. ОБЗОР СУЩЕСТВУЮЩИХ МЕТОДОВ ДЕТЕКТИРОВАНИЯ.....	21
2.1. Покадровые (frame-level) методы детектирования.....	21
2.2. Методы на основе временного анализа.....	22
2.3. Методы на основе частотного и consistency-based анализа	26
2.4. Методы повышения обобщающей способности.....	27
2.5. Наборы данных и протоколы оценки.....	27
2.6. Сравнительный анализ и выявление ограничений.....	28
Выводы по главе 2.....	30
ГЛАВА 3. ПРЕДЛАГАЕМЫЙ МЕТОД.....	32
3.1. Формальная постановка задачи.....	32
3.2. Общая архитектура метода.....	32
3.3. Предобработка видеоданных.....	33
3.4. Пространственная ветвь (spatial branch).....	35
3.5. Временная ветвь (temporal branch).....	36
3.6. Механизм объединения признаков (adaptive weighted fusion)	38
3.7. Классификационная голова и функция потерь.....	39

3.8. Протокол обучения.....	39
3.9. Резюме метода.....	41
Выводы по главе 3.....	42
ГЛАВА 4. ЭКСПЕРИМЕНТАЛЬНАЯ ОЦЕНКА.....	44
4.1. Экспериментальная установка.....	44
4.2. Базовые методы для сравнения.....	47
4.3. Результаты in-domain evaluation.....	47
4.4. Ablation study.....	51
4.5. Анализ ошибок (систематическое исследование случаев, когда модель ошибается, с целью понять корреляции ошибок с типами видео, поддоменами, контентом; помогает выявить систематические слабости архитектуры и направления для улучшения).....	59
4.6. Прототип пользовательского интерфейса.....	60
4.7. Ограничения метода.....	61
Выводы по главе 4.....	61
ЗАКЛЮЧЕНИЕ.....	63
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ.....	65
ПРИЛОЖЕНИЕ А. Структура программного проекта.....	69
ПРИЛОЖЕНИЕ Б. Гиперпараметры и конфигурация обучения.....	70
ПРИЛОЖЕНИЕ В. Инструкция по воспроизведению экспериментов.....	70
ПРИЛОЖЕНИЕ Г. Ключевые фрагменты исходного кода.....	73

ТЕРМИНЫ И ОПРЕДЕЛЕНИЯ

В настоящем отчёте применяют следующие термины с соответствующими определениями:

Deepfake - синтетически сгенерированное или модифицированное видео, в котором лицо или речь человека заменены или изменены с использованием генеративных моделей глубокого обучения.

Face swap - тип манипуляции, при котором лицо целевого человека заменяется лицом другого человека с сохранением мимики и движений.

Face reenactment - тип манипуляции, при котором мимика и движения лица одного человека переносятся на лицо другого человека.

Frame differences (разности кадров) - последовательность изображений, получаемых вычитанием соседних кадров видеопоследовательности; явно кодирует межкадровые изменения.

Spatial branch (пространственная ветвь) - часть архитектуры детектора, обрабатывающая RGB-кадры независимо от других кадров и извлекающая покadresовые пространственные признаки.

Temporal branch (временная ветвь) - часть архитектуры детектора, обрабатывающая последовательность кадров или их разностей и извлекающая признаки межкадровой динамики.

Adaptive weighted fusion - механизм объединения признаков двух ветвей с обучаемыми весами, нормализованными через softmax, обеспечивающий интерпретируемость вклада каждой ветви.

Ablation study - контрольное исследование вклада отдельных компонентов модели, при котором каждый компонент поочерёдно удаляется или заменяется для оценки его влияния на качество.

In-domain evaluation - оценка качества модели на тестовой выборке, выделенной из того же распределения данных, что и обучающая.

Cross-dataset evaluation - оценка качества модели на наборе данных, отличающемся от использованного при обучении; проверка обобщающей способности.

AUC-ROC - площадь под кривой «доля ложноположительных - чувствительность»; основная метрика качества бинарной классификации, не зависящая от выбора порога.

EER (Equal Error Rate) - точка, в которой доли ложноположительных и ложноотрицательных классификаций равны; используется как порогонезависимая мера ошибки.

ПЕРЕЧЕНЬ СОКРАЩЕНИЙ И УСЛОВНЫХ ОБОЗНАЧЕНИЙ

AMP - Automatic Mixed Precision - автоматическая смешанная точность

AUC - Area Under the Curve - площадь под кривой

BCE - Binary Cross-Entropy - бинарная кросс-энтропия

BiLSTM - Bidirectional Long Short-Term Memory - двунаправленная сеть с долгой краткосрочной памятью

CNN - Convolutional Neural Network - свёрточная нейронная сеть

DFDC - Deepfake Detection Challenge - соревнование по детектированию deepfake

EER - Equal Error Rate - равная частота ошибок

FF++ - FaceForensics++ - набор данных для детектирования deepfake

FN - False Negative - ложноотрицательная детекция

FP - False Positive - ложноположительная детекция

GAN - Generative Adversarial Network - генеративно-сопоставительная сеть

GPU - Graphics Processing Unit - графический процессор

LSTM - Long Short-Term Memory - сеть с долгой краткосрочной памятью

MPS - Metal Performance Shaders - бэкэнд Apple для GPU-вычислений

MTCNN - Multi-task Cascaded Convolutional Networks - каскадная сеть для детекции лиц

MVP - Minimum Viable Product - минимально жизнеспособный продукт

RGB - Red, Green, Blue - цветовое пространство

ROC - Receiver Operating Characteristic - рабочая характеристика приёмника

AdamW - Adaptive Moment Estimation with Weight Decay - метод оптимизации с весовой регуляризацией

AltFreezing - метод поочерёдного замораживания пространственных и временных слоёв при обучении

BMVC - British Machine Vision Conference - конференция по компьютерному зрению

CNN+LSTM - комбинация свёрточной нейронной сети с рекуррентной для кадрового анализа последовательностей

CVPR - Conference on Computer Vision and Pattern Recognition - конференция по компьютерному зрению

DCT - Discrete Cosine Transform - дискретное косинусное преобразование (разложение изображения по частотам)

F3-Net - Frequency in Frequency Network - метод детектирования на основе частотного анализа

ICCV - International Conference on Computer Vision - международная конференция по компьютерному зрению

ICML - International Conference on Machine Learning - международная конференция по машинному обучению

JPEG - Joint Photographic Experts Group - стандарт сжатия изображений с потерями

NACO - Negative Augmentation by Combining - метод обучения через генерацию отрицательных аугментаций

NeurIPS - Neural Information Processing Systems - конференция по машинному обучению

P100 - NVIDIA Tesla P100 - модель GPU, использованная для обучения (16 ГБ HBM2)

SPSL - Spatial-Phase Shallow Learning - метод детектирования на основе фазового спектра изображений

WildDeepfake - набор данных deepfake-видео, собранный из открытых источников

ВВЕДЕНИЕ

Актуальность темы исследования

Развитие генеративных моделей глубокого обучения - генеративно-состязательных сетей (GAN), автоэнкодерных архитектур и диффузионных моделей - привело к появлению технологий создания высокореалистичных синтетических видеопоследовательностей с подменой лиц (face swap), реконструкцией мимики (face reenactment) и генерацией «говорящих голов» (talking face). Такие технологии, объединяемые термином deepfake, создают системные риски для информационной безопасности, цифровой идентификации личности, судебной экспертизы видеоматериалов и общественного доверия к медиаконтенту [1, 2].

К настоящему времени разработан значительный арсенал методов обнаружения манипулированных видео [1, 2], основанных на анализе пространственных артефактов с использованием свёрточных нейронных сетей [3, 4]. Покадровые (frame-level) детекторы, такие как XceptionNet [3] и EfficientNet [5], демонстрируют высокую точность на обучающем домене (AUC свыше 99% на датасете FaceForensics++ [3]). Однако при переносе обученной модели на данные, не участвовавшие в обучении (cross-dataset evaluation), наблюдается значительная деградация обобщающей способности: снижение AUC на 15-25% для CNN-основанных детекторов [8]. Основная причина заключается в том, что покадровые методы оптимизируются под пространственные артефакты конкретных генеративных моделей и не учитывают временную структуру видеопоследовательности. В настоящей работе данный класс покадровых детекторов воспроизведён в качестве базовой архитектуры B1 (EfficientNet-B4 spatial-only) и сопоставлен с предлагаемым dual-path методом в разделе 4.3; результаты подтверждают наблюдение о падении обобщающей способности при cross-dataset переносе.

В последние годы предложен ряд подходов, учитывающих временную составляющую видео: комбинации CNN с рекуррентными сетями (CNN+LSTM) [16, 20], трёхмерные свёрточные сети (3D CNN) [24], методы

на основе компоновки миниатюр (thumbnail layout) [28], анализ стилевых латентных потоков [29] и пиксельных временных частот [19]. Однако большинство из них используют либо последовательную архитектуру (temporal branch зависит от качества пространственных представлений), либо неразделимые пространственно-временные модели (3D CNN), в которых вклады пространственного и временного анализа невозможно изолировать. При этом современные генеративные модели, производя кадры высокого визуального качества, сохраняют тонкие межкадровые несоответствия - дрейф лицевых признаков между кадрами (Facial Feature Drift) [15], нарушения мимической динамики и временной когерентности идентичности, - которые представляют собой потенциально мощный, но недостаточно эксплуатируемый сигнал для детектирования.

Вместе с тем существующие детекторы, демонстрирующие $AUC \geq 0.99$ при in-domain оценке, при переносе на новые наборы данных показывают значительную деградацию качества (по данным DeepfakeBench снижение AUC на 15-25 % для CNN и около 11 % для Transformer). Это разрыв между лабораторными и эксплуатационными условиями применения детекторов остаётся открытой проблемой области. Актуальной задачей является разработка метода, в котором обобщающая способность и вклад каждой архитектурной компоненты (пространственной, временной, объединяющей) измеримы на воспроизводимом протоколе и могут быть оценены отдельно.

Объект и предмет исследования

Объектом исследования являются манипулированные видеопоследовательности, содержащие подмену лиц и синтетически сгенерированный лицевой контент, полученный с помощью современных генеративных моделей глубокого обучения.

Предметом исследования являются пространственные и временные признаки манипулированных видеопоследовательностей, а также методы их совместного анализа для задачи автоматического детектирования.

Цель работы

Разработка метода автоматического выявления манипулированных видеопоследовательностей на основе пространственно-временного анализа, позволяющего обнаруживать подмену лиц и синтетически сгенерированные видео за счёт анализа межкадровых и пространственных признаков.

Новизна предлагаемого метода заключается в параллельной dual-path архитектуре с явным временным входом (temporal input - данные, явно содержащие межкадровую информацию; в нашем методе - разности соседних кадров, frame differences, в отличие от неявного извлечения временных признаков из последовательности RGB-кадров) из разностей кадров (frame differences) и обучаемым механизмом fusion с интерпретируемыми весами; это обеспечивает: (1) разделимое моделирование пространственных и временных признаков, (2) возможность чистого ablation study вклада каждой ветви, (3) интерпретируемость распределения вкладов в каждом конкретном решении - свойства, отсутствующие в комбинации в рассмотренных в обзоре подходах (раздел 2.6).

Задачи работы

Для достижения поставленной цели сформулированы следующие задачи:

Провести анализ существующих методов генерации синтетических видеопоследовательностей и современных подходов к их детектированию.

Исследовать пространственные и временные признаки, характерные для манипулированного видеоконтента.

Разработать метод выявления подмены лиц и синтетических видео на основе совместного пространственно-временного анализа.

Реализовать модель детектирования и провести обучение на открытых наборах данных.

Выполнить экспериментальную оценку разработанного подхода и сравнение с существующими решениями.

Научная новизна

Научная новизна работы состоит в следующем.

Первое. Предложена параллельная двухветвевая (dual-path) архитектура с явным временным входом в виде нормированных разностей последовательных кадров. Архитектура отличается от рассмотренных в обзоре подходов сочетанием трёх свойств: независимость пространственной и временной ветвей, явное кодирование межкадровых изменений во входе временной ветви, и обучаемое объединение признаков с интерпретируемыми весами.

Второе. Проведена систематическая ablation-серия: 4 архитектурных конфигурации (Full, Spatial-only, Temporal-only, Sequential CNN+BiLSTM) на двух значениях длины клипа ($T=16$ и $T=32$) и трёх размерах обучающей выборки (1, 2 и 3 датасета). Результаты получены в идентичных условиях обучения и оценки. На наилучшей конфигурации (полная dual-path, $T=32$, 3 датасета) достигнуты значения $AUC = 0.9943$, точность 96.7 %, $F1 = 0.978$, $EER = 0.041$. Дополнительно выполнена cross-dataset проверка переноса DFDC02 $\rightarrow$ DFD01.

Развёрнутое пояснение второго вывода. Систематическое сравнение четырёх архитектурных конфигураций (A1-A4) в идентичных условиях обучения подтвердило: полная dual-path архитектура (A1) обеспечивает лучший компромисс между in-domain accuracy ($AUC\ 0.978$ на DFDC02) и обобщающей способностью при cross-dataset переносе ($AUC\ 0.553$ на DFD01); spatial-only (A2) показывает несколько более высокую in-domain accuracy на DFDC02 ($AUC\ 0.984$), но значительно худшую обобщающую способность ($AUC\ 0.504$ на DFD01); temporal-only (A3) и sequential CNN+BiLSTM (A4) демонстрируют промежуточные результаты с большим разбросом качества по поддоменам.

Третье. Реализован воспроизводимый программный конвейер на основе PyTorch, включающий face-centric preprocessing (MTCNN), video-level dataset с разбиением по идентификаторам, обучение с warmup и early stopping, оценку с автоматическим анализом ошибок и Flask-прототип пользовательского интерфейса. Конвейер открыт, поддерживает

CPU/CUDA/MPS и может быть использован другими исследователями в качестве воспроизводимого baseline для сравнительной оценки последующих методов.

Практическая значимость

Практическая значимость работы заключается в следующем. Разработанный метод реализован в виде воспроизводимого программного конвейера и веб-прототипа Flask MVP (Minimum Viable Product - минимально жизнеспособный продукт; Flask выбран как самый лёгкий Python веб-фреймворк: 1-2 endpoint на 50-100 строк кода; альтернативы Django/FastAPI имеют избыточную функциональность для одностраничного MVP и увеличивают время разработки в 3-5 раз), что позволяет применять метод для анализа отдельных видеозаписей в задачах цифровой криминалистики и информационной безопасности. Систематическая классификация пространственных и временных признаков может быть использована при проектировании систем автоматической верификации видео. Открытость кода и весов в отличие от закрытых коммерческих детекторов обеспечивает возможность независимой верификации и переобучения метода на дополнительных данных при необходимости.

Методы исследования

В работе использованы методы глубокого обучения (свёрточные нейронные сети, трансформерные архитектуры, transfer learning), методы обработки видеоданных (детекция и вырезка лицевых областей, вычисление межкадровых разностей), методы статистической оценки качества бинарной классификации (AUC-ROC, F1-score, EER), а также метод ablation study для анализа вклада отдельных компонентов архитектуры.

Структура работы

Работа состоит из введения, четырёх глав, заключения, списка литературы и приложений.

В первой главе рассмотрены теоретические основы: таксономия манипуляций видеоконтента, пространственные и временные признаки

манипулированных видеопоследовательностей, архитектурные подходы к извлечению пространственно-временных признаков из видео, а также метрики и протоколы оценки качества детектирования.

Во второй главе представлен обзор существующих методов детектирования манипулированного видео: покадровые методы, методы на основе временного анализа, частотные и consistency-based подходы, методы повышения обобщающей способности, наборы данных и протоколы оценки. Глава завершается сравнительным анализом ограничений существующих подходов и обоснованием выбранного направления исследования.

В третьей главе описан предлагаемый метод: формальная постановка задачи, общая архитектура, предобработка видеоданных, пространственная и временная ветви, механизм объединения признаков и классификационная голова, протокол обучения.

В четвёртой главе представлены результаты экспериментальной оценки: описание экспериментальной установки, результаты in-domain evaluation, ablation study, анализ ошибок, прототип пользовательского интерфейса и ограничения метода.

В заключении подведены итоги работы, сформулированы основные результаты и определены направления дальнейших исследований.

ГЛАВА 1. ТЕОРЕТИЧЕСКИЕ ОСНОВЫ

1.1. Таксономия манипуляций видеоконтента

Под манипулированным видеоконтентом в данной работе понимаются видеопоследовательности, в которых лицевая область одного или нескольких участников была изменена с помощью генеративных моделей глубокого обучения. Совокупность таких технологий принято обозначать термином *deepfake* - от сочетания слов «*deep learning*» и «*fake*» [1, 2].

Существующие методы манипуляции лицевого видеоконтента можно разделить на четыре основных типа в зависимости от характера вносимых изменений.

Подмена лиц (*face swap*) предполагает замену лица целевого человека лицом другого, при этом мимика, поза и контекст сцены сохраняются. Этот тип манипуляции реализуется автоэнкодерными архитектурами (*DeepFaceLab* [6], *FaceSwap*), а также GAN-моделями с условной генерацией (*SimSwap* [7], *BlendFace*). При подмене лиц характерны следующие артефакты: несоответствие текстур кожи между вставленным лицом и окружающей областью, видимые границы вставки (*blending boundaries*), нарушение цветового баланса и несогласованность освещения [8].

Реконструкция мимики (*face reenactment*) изменяет выражение лица целевого человека, перенося мимику и движения с лица-источника. Методы данного класса (*Face2Face* [9], *NeuralTextures* [10], *TPSMM* - *Thin-Plate Spline Motion Model*) не заменяют лицо целиком, а модифицируют его выражение, что делает манипуляцию визуально менее заметной. Характерные артефакты включают неестественную динамику движений, несогласованность модифицированных областей с немодифицированными и нарушение временной когерентности мимических выражений.

Генерация «говорящих голов» (*talking face*) синтезирует видео лица, синхронизированного с аудиодорожкой. Такие методы (*Wav2Lip*, *SadTalker*) используют в качестве входа аудиосигнал и статическое или короткое видео с лицом, генерируя анимированную последовательность кадров. Артефакты

данного типа проявляются в нарушении синхронизации движений губ с аудио, статичности немодифицированных областей лица и неестественности микродвижений.

Полная генерация (full face synthesis) создаёт лицо целиком с нуля, без использования реального прототипа. Для этого применяются генеративно-состязательные сети (StyleGAN, StyleGAN2 [11]) и диффузионные модели. Этот тип наиболее сложен для детектирования, поскольку отсутствует пара «оригинал-подделка» для сравнения.

С точки зрения задачи детектирования важно, что каждый тип манипуляции порождает характерный набор пространственных и временных артефактов, рассмотренных в разделах 1.2 и 1.3. Понимание природы этих артефактов определяет архитектурные решения предлагаемого метода.

1.2. Пространственные признаки манипулированного видеоконтента

Пространственные признаки - это артефакты, наблюдаемые в отдельных кадрах видеопоследовательности без учёта межкадровой динамики. В литературе выделяется несколько категорий таких признаков.

Текстурные несоответствия. Генеративные модели, используемые для подмены лиц, обучаются воспроизводить глобальную структуру лица, однако часто не способны точно воспроизвести мелкомасштабные текстурные детали: поры кожи, морщины, особенности волосяного покрова. В результате область вставленного лица может выглядеть «сглаженной» по сравнению с окружающим контекстом. Ниркин и соавт. [8] показали, что несоответствие между текстурой лица и окружающей областью является информативным признаком для детектирования.

Артефакты границ вставки (blending artifacts). При подмене лиц генерированная лицевая область накладывается на исходный кадр, что создаёт границу между оригинальным и синтезированным контентом. Ли и соавт. [12] предложили метод Face X-ray, основанный на выявлении таких границ, и показали, что blending artifacts присутствуют в подавляющем

большинстве face-swap методов, поскольку операция наложения является неотъемлемой частью генеративного pipeline.

Спектральные артефакты. Генеративные модели на основе GAN используют операции повышения разрешения (upsampling), которые вносят характерные регулярные паттерны в частотный спектр изображения. Франк и соавт. [13] продемонстрировали, что в спектре Фурье GAN-генерированных изображений присутствуют аномальные пики, связанные с архитектурой генератора. Дуралл и соавт. [14] показали, что свёрточные генераторы систематически не воспроизводят высокочастотные компоненты спектра, что может быть использовано как признак синтетического происхождения.

Аномалии освещения и цветового баланса. При подмене лиц генерируемое лицо может содержать отражения и тени, несогласованные с условиями освещения исходной сцены. Нирикин и соавт. [8] показали, что несоответствие между направлением освещения лица и окружающего контекста является информативным дискриминативным признаком, особенно для ранних методов генерации с ограниченным моделированием освещения.

Влияние сжатия видео. Значительная часть видеоконтента подвергается сжатию при распространении (кодеки H.264, H.265). Сжатие вносит собственные артефакты и одновременно маскирует артефакты манипуляции. На датасете FaceForensics++ [3] показано, что при переходе от лёгкого (с23) к сильному (с40) сжатию качество детектирования кадровыми методами существенно снижается.

Описанные пространственные признаки мотивируют выбор мощного свёрточного backbone (термин backbone обозначает базовую CNN-сеть, выступающую экстрактором признаков; EfficientNet-B4 - семейство свёрточных сетей с оптимальным балансом точности и вычислительной стоимости за счёт compound scaling по глубине, ширине и разрешению) в пространственной ветви предлагаемого метода: сеть, предобученная на ImageNet и дообученная на данных deepfake, способна неявно извлекать

текстурные, частотные и blurring-артефакты из RGB-кадров без ручного конструирования признаков. Однако пространственные признаки подвержены деградации при сжатии и при смене генеративного метода, что обосновывает необходимость дополнения их анализом временной структуры видео.

Обоснование выбора EfficientNet-B4 vs B5-B7. EfficientNet-B4 (Tan & Le, 2019, ICML [5]) обеспечивает ~83.5% top-1 accuracy на ImageNet при ~19 млн параметров, тогда как более крупные модели B5-B7 дают прирост 1-2% accuracy при двух-четырёхкратном увеличении вычислительной стоимости. В условиях ограниченного GPU-бюджета (NVIDIA Tesla P100 16 ГБ на Kaggle) B4 представляет оптимальную точку на кривой compound scaling: достаточная репрезентационная мощность для извлечения текстурных и blurring-артефактов deepfake при выполнимости обучения dual-path архитектуры с T=16 кадрами и batch=16.

1.3. Временные признаки манипулированного видеоконтента

Временные признаки - это закономерности, проявляющиеся при анализе последовательности кадров и характеризующие межкадровую динамику лицевых областей. В отличие от пространственных артефактов, временные признаки обусловлены не качеством генерации отдельного кадра, а согласованностью генерации между кадрами.

Дрейф лицевых признаков (Facial Feature Drift). Ян и соавт. [15] обнаружили, что даже при визуально статичной сцене в deepfake видео наблюдается неестественный микродрейф лицевых признаков между последовательными кадрами. Это связано с тем, что большинство генеративных моделей обрабатывают кадры независимо или с ограниченным контекстом, что приводит к тонким несоответствиям в положении глаз, носа, рта и контуров лица между последовательными кадрами. Это наиболее заметно при вычислении разностей последовательных кадров (frame differences), которые для реальных видео содержат преимущественно

плавные изменения, а для deepfake - хаотические и пространственно несогласованные.

Нарушения мимической динамики. Манипулированные видео могут содержать неестественную скорость и траекторию мимических изменений: резкие переходы между выражениями, асимметричные движения, отсутствие микровыражений. Гуэра и Делп [16] одними из первых показали, что рекуррентная нейронная сеть, обрабатывающая последовательность CNN-признаков кадров, способна обнаруживать такие нарушения.

Несогласованность временной идентичности. При покадровой генерации идентичность лица может непоследовательно меняться между кадрами: тонкие изменения формы лица, расположения лицевых ориентиров и текстурных деталей, незаметные на отдельных кадрах, но создающие видимое «мерцание» при воспроизведении видео. Методы, основанные на анализе временной когерентности идентичности (TI2Net [17]), моделируют эволюцию вектора идентичности по кадрам и обнаруживают аномальные отклонения. Систематический анализ методов оценки временной когерентности для задачи детектирования deepfake-видео представлен в обзоре Amin и соавт. [43].

Физиологические сигналы. Реальные видео лиц содержат тонкие периодические сигналы, связанные с физиологическими процессами: ритм моргания, изменения цвета кожи, обусловленные пульсом (remote photoplethysmography). Ци и соавт. [18] предложили метод DeepRhythm, который обнаруживает аномалии в визуальных сигналах сердечного ритма как индикатор синтетического происхождения видео.

Временные частотные аномалии. Ким и соавт. [19] предложили анализировать пиксельные временные частоты - спектральные характеристики изменения яркости отдельных пикселей во времени. Показано, что deepfake видео содержат характерные аномалии во временном частотном спектре, отличающиеся от паттернов реальных видеопоследовательностей.

Описанные временные признаки мотивируют выделение отдельной временной ветви (temporal branch) в предлагаемом методе. При этом разности последовательных кадров (frame differences) выбраны в качестве входа данной ветви, поскольку они явно кодируют межкадровые изменения, включая дрейф лицевых признаков и нарушения мимической динамики, без необходимости вычисления оптического потока.

1.4. Архитектурные подходы к извлечению пространственно-временных признаков из видео

В данном разделе рассмотрены архитектуры глубокого обучения, используемые для извлечения пространственных и временных признаков из видеопоследовательностей. Каждая архитектура описывается в контексте задачи детектирования манипулированного видео.

Свёрточные нейронные сети как экстракторы пространственных признаков. В задаче детектирования deepfake свёрточные сети используются для извлечения пространственных представлений из отдельных кадров. Стандартными backbone-архитектурами являются XceptionNet [4] и EfficientNet [5]. XceptionNet, основанный на глубинно-разделяемых свёртках (depthwise separable convolutions), стал де-факто стандартом после работы Рёсслера и соавт. [3], в которой он продемонстрировал высокую точность на датасете FaceForensics++. EfficientNet, предложенный Тэном и Ле [5], использует комбинированное масштабирование глубины, ширины и разрешения (compound scaling) и обеспечивает высокое качество при меньших вычислительных затратах. В предлагаемом методе EfficientNet-B4 выбран в качестве backbone пространственной ветви на основе следующего сравнительного анализа. Рассматривались три основных кандидата: XceptionNet (22.9M параметров), EfficientNet-B4 (19.3M) и ResNet-50 [40] (25.6M). XceptionNet является стандартом де-факто после работы Рёсслера и соавт. [3], однако его архитектура оптимизирована под задачу классификации ImageNet и не проходила compound scaling. ResNet-50 демонстрирует конкурентоспособные результаты, но уступает EfficientNet по

соотношению точности к числу параметров. EfficientNet-B4 выбран по совокупности критериев: (1) он является стандартом оценки в DeepfakeBench [25] и использовался победителями соревнования DFDC; (2) compound scaling обеспечивает оптимальный баланс точности и вычислительной стоимости; (3) наличие качественных предобученных весов ImageNet. Выбор варианта B4, а не B0-B3 или B5-B7, обусловлен балансом между ёмкостью модели и вычислительными ограничениями: B4 обеспечивает достаточную репрезентативную мощность для извлечения тонких артефактов deepfake, при этом позволяя обрабатывать T=16 кадров в пакете на GPU с 16 ГБ памяти.

Рекуррентные сети для моделирования межкадровых зависимостей. Сети с долгой краткосрочной памятью (LSTM [20]) и их двунаправленные варианты (BiLSTM) моделируют зависимости в последовательных данных, обрабатывая элементы последовательности поэлементно и поддерживая скрытое состояние. В контексте deepfake detection LSTM применяются поверх CNN-признаков: для каждого кадра извлекается пространственный вектор с помощью CNN, последовательность таких векторов обрабатывается LSTM [16]. Достоинство подхода - простота и низкая вычислительная стоимость. Ограничение - последовательная обработка: LSTM обрабатывает кадры один за другим, что затрудняет моделирование глобальных зависимостей между далёкими кадрами, и делает temporal branch зависимым от качества spatial embeddings (sequential pipeline).

Трансформеры для видео. Архитектура Transformer [22], основанная на механизме самовнимания (self-attention), моделирует зависимости между всеми парами элементов последовательности одновременно, что устраняет ограничение рекуррентных сетей на моделирование только локальных зависимостей. В задачах анализа видео были предложены специализированные варианты: TimeSformer [23], разделяющий пространственное и временное внимание, и Video Swin Transformer, использующий оконное внимание. В контексте

deepfake detection трансформеры применяются как для обработки последовательностей CNN-признаков кадров, так и для совместного пространственно-временного моделирования. Достоинства: глобальное моделирование зависимостей между кадрами, параллельная обработка, визуализируемые карты внимания (attention maps - матрицы весов, показывающие, насколько сильно каждая пара временных позиций связана при принятии решения; визуализация этих весов в разделе 4.5.3 позволяет интерпретировать вклад различных межкадровых переходов в итоговую классификацию), обеспечивающие интерпретируемость. Ограничения: вычислительная стоимость, квадратичная по длине последовательности, и необходимость достаточного объёма данных для обучения. В предлагаемом методе Temporal Transformer (2 слоя, 4 головы внимания) используется в качестве temporal module, поскольку при длине последовательности $T-1 = 15$ вычислительная стоимость внимания составляет менее 1% от общего времени обучения, а возможность визуализации внимания повышает интерпретируемость.

Дополнительно об интерпретируемости. Карты внимания (attention maps) Transformer-блока позволяют ответить на практический вопрос «на какие пары кадров модель смотрит при принятии решения». Для реальных видео внимание распределяется равномерно (модель находит согласованную динамику между всеми кадрами); для манипулированных - концентрируется на конкретных временных позициях, где обнаруживаются межкадровые несоответствия (артефакты face-swap часто проявляются в отдельных фреймах). Это даёт практическую возможность качественной интерпретации, используемой в разделе 4.5.4.

Сравнение рекуррентных и трансформерных архитектур для коротких последовательностей. В контексте задачи детектирования манипулированного видео длина обрабатываемой последовательности составляет $T-1 = 15$ элементов (разностей кадров). При такой длине вычислительная стоимость самовнимания трансформера не создаёт

ограничений: $O(T^2) = 225$ пар, что не создаёт вычислительных ограничений. При этом трансформер моделирует зависимости между всеми парами элементов одновременно, тогда как LSTM обрабатывает последовательность поэлементно и теряет информацию о дальних зависимостях. Для данной задачи критически важно обнаруживать несоответствия между произвольными парами кадровых переходов (например, дрейф признаков между первым и последним кадрами клипа), что делает трансформер предпочтительным выбором. Дополнительным преимуществом является визуализируемость карт внимания, обеспечивающая интерпретируемость модели.

Трёхмерные свёрточные сети (3D CNN). Трёхмерные свёртки оперируют пространственно-временными кубами данных (пространственно-временными тензорами), извлекая совместные пространственно-временные признаки. В задаче deepfake detection 3D CNN были применены в методе AltFreezing [24], использующем 3D ResNet с попеременным замораживанием пространственных и временных компонентов. Достоинства: единая модель для spatiotemporal feature extraction, нет необходимости в явном разделении ветвей. Ограничения: пространственный и временной вклады неразделимы, что исключает проведение чистого ablation study; высокая вычислительная стоимость; менее интерпретируемая модель.

Механизмы объединения признаков (fusion). При параллельном извлечении пространственных и временных признаков возникает задача их объединения для совместного принятия решения. Основные подходы: конкатенация с последующим полносвязным слоем (простейший вариант), обучаемое взвешивание (adaptive weighted fusion), управляющие механизмы (gated fusion) и перекрёстное внимание (cross-attention). Выбор механизма fusion влияет как на качество классификации, так и на интерпретируемость метода: обучаемые веса в adaptive weighted fusion позволяют для каждого конкретного предсказания получить пару чисел (вес пространственной и временной ветвей, нормированных через softmax в сумму 1), показывающих

относительный вклад каждой ветви в решение модели. Эта возможность визуализации вкладов используется в разделе 4.5.3 для качественного анализа того, в каких типах видео доминирует пространственный анализ (текстурные артефакты), а в каких - временной (нарушения межкадровой динамики).

Итоговый выбор архитектурных компонентов в предлагаемом методе: EfficientNet-B4 в качестве пространственного backbone (раздел 3.4), Temporal Transformer (2 слоя, 4 головы внимания) как временной модуль (раздел 3.5), adaptive weighted fusion для объединения признаков (раздел 3.6). Сравнение с альтернативными конфигурациями - последовательной CNN+BiLSTM, чисто пространственной и чисто временной архитектурами - выполнено как ablation study в разделе 4.4.

1.5. Метрики и протоколы оценки качества детектирования

Корректная оценка качества детектирования манипулированного видео требует стандартизированных метрик и протоколов, обеспечивающих сопоставимость результатов между работами.

Метрика AUC-ROC. Площадь под кривой «ошибка первого рода - чувствительность» (Area Under the Receiver Operating Characteristic curve, AUC-ROC) является основной метрикой в задаче детектирования deepfake (AUC=1.0 - идеальный классификатор, AUC=0.5 - случайное угадывание; полученный в настоящей работе результат AUC=0.978 означает, что модель различает реальные и фейковые видео с вероятностью 97.8%) [3, 25]. AUC является порогонезависимой метрикой: она оценивает способность модели ранжировать манипулированные видео выше реальных при произвольном пороге решения. Это особенно важно при несбалансированных данных (например, FaceForensics++ содержит 1000 реальных и 4000 манипулированных видео). Значение AUC = 1.0 соответствует безошибочному разделению классов, AUC = 0.5 - случайному классификатору.

Дополнительные метрики. Accuracy (доля правильных классификаций при фиксированном пороге $\tau = 0.5$), F1-score (гармоническое среднее точности и полноты) и EER (Equal Error Rate - точка, в которой доли ложноположительных и ложноотрицательных классификаций равны) используются в качестве вспомогательных метрик.

Протоколы оценки. В литературе по детектированию deepfake выделяют три основных протокола оценки:

In-domain evaluation предполагает обучение и тестирование модели на различных подмножествах одного датасета (например, train/test split FaceForensics++). Данный протокол оценивает способность модели обнаруживать манипуляции тех же типов, что и в обучающей выборке, при тех же условиях сжатия.

Cross-dataset evaluation предполагает обучение модели на одном датасете (как правило, FaceForensics++) и тестирование на другом (Celeb-DF v2, DFDC), без дообучения. Данный протокол оценивает обобщающую способность модели - её способность обнаруживать манипуляции, созданные методами и в условиях, отличающихся от обучающих. Как показано в DeepfakeBench [25], cross-dataset evaluation приводит к значительной деградации метрик: для CNN-основанных методов снижение AUC составляет 15% и более, для Transformer-основанных - около 11%.

Cross-manipulation evaluation предполагает обучение модели на одном типе манипуляции (например, DeepFakes) и тестирование на другом (например, Face2Face). Данный протокол оценивает устойчивость метода к смене типа манипуляции.

В настоящей работе основным протоколом является in-domain evaluation на трёх объединённых наборах данных: DFDC02 (подмножество Deepfake Detection Challenge от Meta), DFD01 (Google/Jigsaw на основе FaceForensics-протокола) и Celeb-DF v2 (набор видео знаменитостей с улучшенным качеством генерации); детальное описание датасетов приведено в разделе 4.1.1. Дополнительно выполнена проверка cross-dataset переноса

DFDC02 → DFD01 (раздел 4.4.1) для оценки обобщающей способности модели. Расширение оценки на FaceForensics++ [3] (классический академический бенчмарк для детектирования deepfake) и WildDeepfake (более 7000 «диких» видео из социальных сетей) рассматривается как направление дальнейшего развития (раздел 4.7).

Замечание о FaceForensics++. FaceForensics++ (FF++, Rössler et al., 2019, ICCV [3]) - крупнейший открытый бенчмарк методов детектирования deepfake, содержащий 1000 видео с четырьмя типами манипуляций (DeepFakes, Face2Face, FaceSwap, NeuralTextures) при трёх уровнях сжатия. В настоящей работе FF++ не используется в основном эксперименте по следующим причинам: (1) полная предобработка FF++ требует около 80 GPU-часов на доступном оборудовании, что превышает суммарный бюджет на все ablation-эксперименты; (2) фокус работы - современные датасеты с реалистичным распределением классов и условий съёмки (DFDC02, DFD01, Celeb-DF v2). Использование FF++ обозначено как направление дальнейшего развития (раздел 4.7 и Заключение).

Выводы по главе 1

В данной главе рассмотрены теоретические основы, необходимые для проектирования метода детектирования манипулированных видеопоследовательностей. Установлено, что существующие типы манипуляций - подмена лиц, реконструкция мимики, генерация «говорящих голов» и полная генерация - порождают как пространственные (текстурные, спектральные, blending), так и временные (дрейф признаков, нарушения мимической динамики, несогласованность идентичности) артефакты. Показано, что пространственные признаки информативны, но подвержены деградации при сжатии и смене генеративного метода, тогда как временные признаки представляют собой комплементарный сигнал, требующий явного моделирования. Рассмотренные архитектурные подходы - свёрточные сети, рекуррентные сети, трансформеры и 3D CNN - обладают различными свойствами в контексте задачи. Это обосновывает выбор предлагаемой dual-

path архитектуры с параллельными пространственной (EfficientNet-B4 над RGB-кадрами) и временной (Temporal Transformer над разностями кадров, frame differences) ветвями, объединяемыми механизмом adaptive weighted fusion; детальное описание архитектуры приведено в главе 3, обоснование на основе экспериментальной ablation study - в разделе 4.4.

ГЛАВА 2. ОБЗОР СУЩЕСТВУЮЩИХ МЕТОДОВ ДЕТЕКТИРОВАНИЯ МАНИПУЛИРОВАННЫХ ВИДЕОПОСЛЕДОВАТЕЛЬНОСТЕЙ

2.1. Покадровые (frame-level) методы детектирования

Покадровые методы детектирования основаны на анализе пространственных признаков отдельных кадров видеопоследовательности без учёта межкадровой динамики. Данный класс методов исторически доминирует в литературе и демонстрирует высокую точность при in-domain оценке.

Рёсслер и соавт. [3] предложили использовать архитектуру XceptionNet для бинарной классификации кадров на реальные и манипулированные. На датасете FaceForensics++ при лёгком сжатии (с23) метод достиг AUC выше 99%. Полученный результат установил стандарт оценки, воспроизводимый в большинстве последующих работ. Успех XceptionNet в данной задаче объясняется тем, что глубинно-разделяемые свёртки эффективно захватывают текстурные различия между реальными и синтетическими лицами.

Модели на основе EfficientNet [5] также широко применяются в задаче детектирования deepfake. Архитектура EfficientNet-B4 использовалась победителями соревнования Deepfake Detection Challenge (DFDC) [37], организованного компанией Meta. Комбинированное масштабирование (compound scaling), реализованное в EfficientNet, обеспечивает оптимальный баланс между точностью и вычислительной стоимостью, что делает данную архитектуру стандартным выбором backbone в современных работах.

Нгуен и соавт. [26] предложили метод LAA-Net (Localized Artifact Attention Network) на конференции CVPR 2024, направленный на обнаружение локальных артефактов манипуляции. Метод использует механизм внимания для автоматического выделения областей кадра с наибольшей вероятностью манипуляции и продемонстрировал устойчивость к различным уровням сжатия.

Нгуен и соавт. [27] применили капсульные сети (Capsule Networks) к задаче детектирования, используя способность капсульных архитектур моделировать иерархические пространственные отношения между частями лица.

Несмотря на высокие результаты in-domain, покадровые методы демонстрируют значительную деградацию при cross-dataset evaluation. По данным DeepfakeBench [25], при обучении на FaceForensics++ и тестировании на Celeb-DF v2 AUC XceptionNet снижается примерно до 73%, EfficientNet-B4 - до 76%. Аналогичные результаты получены при тестировании на DFDC. Причины деградации включают: переобучение на пространственные артефакты конкретных генеративных методов, чувствительность к условиям сжатия и неспособность учитывать временную структуру видео.

Таким образом, покадровые методы обеспечивают высокую точность в контролируемых условиях, но их обобщающая способность недостаточна для применения в реальных сценариях, где тип манипуляции и условия распространения заранее неизвестны. По мнению автора, именно эта фундаментальная слабость покадровых подходов делает привлечение временной информации не просто желательным, а необходимым условием построения практически применимого детектора.

Применение в настоящей работе. Покадровые методы воспроизведены как базовые архитектуры B1 (EfficientNet-B4 spatial-only, описание в разделе 4.2) и сравнены с предлагаемым dual-path методом в разделе 4.3 (in-domain) и 4.4.1 (cross-dataset). Воспроизведение DeepfakeBench-наблюдения о падении AUC на 15-25% при cross-dataset переносе выполнено собственноручно: на эксперименте DFDC02 → DFD01 (Таблица 4.4) покадровая baseline-модель B1 показала падение AUC с 0.984 до 0.504, что подтверждает наблюдение из обзора (раздел 1.5).

Развёрнутое пояснение применения. Покадровые методы из §2.1 воспроизведены как ablation-варианты в настоящей работе: (1) A2 (Spatial-

only) - EfficientNet-B4 без временной ветви, аналог классических XceptionNet/EfficientNet-B4 baseline-моделей; (2) A4 (Sequential CNN+BiLSTM) - EfficientNet-B4 + 2-слойная двунаправленная LSTM, воспроизведение последовательной CNN→RNN архитектуры. Это позволяет количественно оценить вклад параллельной двухветвевой схемы относительно классических покадровых подходов в одних условиях обучения. Прямое сравнение - разделы 4.3 (in-domain) и 4.4.1 (cross-dataset перенос).

2.2. Методы на основе временного анализа

Покадровые методы приблизились к предельным значениям метрик на in-domain бенчмарках. Их ограничения мотивировали разработку подходов, учитывающих временную структуру видеопоследовательности (моделирование межкадровой динамики - построение математических представлений того, как лицевая область изменяется от кадра к кадру: смещение лицевых ориентиров, изменения текстуры, нарушения непрерывности микродвижений). В данном разделе рассмотрены основные направления: последовательные архитектуры (CNN+RNN), трёхмерные свёрточные сети, методы на основе компоновки миниатюр, подходы в латентном пространстве и анализ временных частот.

2.2.1. Последовательные архитектуры (CNN → RNN)

Гуэра и Делп [16] одними из первых предложили использовать рекуррентную нейронную сеть для обнаружения временных несоответствий в deepfake видео. В их подходе кадры видеопоследовательности обрабатываются свёрточной сетью InceptionV3, а полученные пространственные представления подаются на вход сети LSTM, которая моделирует межкадровую динамику. Авторы показали, что LSTM способна обнаруживать тонкие временные несоответствия, неуловимые при покадровом анализе.

Сабир и соавт. [21] развили данный подход, применив двунаправленную рекуррентную сеть (BiRNN) поверх CNN-признаков. Использование двунаправленной обработки позволяет учитывать контекст как предшествующих, так и последующих кадров.

Последовательные подходы CNN→RNN имеют важное архитектурное ограничение: temporal branch получает на вход пространственные представления, извлечённые CNN, и полностью зависит от их качества. Если пространственная модель не извлекла информативные признаки (например, из-за сильного сжатия), temporal branch не способен компенсировать этот дефицит. Кроме того, LSTM моделирует преимущественно локальные зависимости, что ограничивает обнаружение паттернов, проявляющихся на масштабе всего видеоклипа.

2.2.2. Трёхмерные свёрточные сети (3D CNN)

Метод AltFreezing, представленный Ван и соавт. [24] на CVPR 2023, в котором 3D ResNet (трёхмерная свёрточная сеть, в которой ядро свёртки имеет три измерения - высоту, ширину и время; в отличие от обычной 2D CNN, она обрабатывает не отдельный кадр, а последовательность кадров целиком, что позволяет извлекать пространственно-временные признаки одним проходом) обучается с попеременным замораживанием (замораживанием - технический термин для процесса временной остановки обновления весов части нейронной сети при backpropagation; в AltFreezing пространственная и временная ветви замораживаются по очереди в течение разных эпох, что заставляет сеть учиться полагаться попеременно на разные типы признаков; иначе говоря, временной остановкой обновления градиентов для части параметров сети) пространственных и временных компонентов. На нечётных итерациях обучаются только пространственные фильтры при замороженных временных, на чётных - наоборот. Такая стратегия позволяет модели последовательно совершенствовать извлечение пространственных и временных признаков. Метод продемонстрировал конкурентоспособные результаты как при in-domain, так и при cross-dataset evaluation.

Однако 3D CNN извлекают пространственные и временные признаки совместно, что делает невозможным разделение их вкладов. Это не позволяет выполнить чистый ablation study и определить, какой тип информации (spatial или temporal) является решающим для конкретного типа манипуляции. Кроме того, 3D свёртки существенно увеличивают вычислительную стоимость модели. Открытым остаётся вопрос: высокое качество AltFreezing обусловлено временным моделированием или стратегией обучения (попеременное замораживание)? Представляется, что невозможность разделить эти вклады является существенным методологическим ограничением 3D-свёрточного подхода.

2.2.3. Методы на основе компоновки миниатюр (thumbnail layout)

На конференции ICCV 2023 был представлен метод TALL (Сюй и соавт. [28]) (Thumbnail Layout for Deepfake Video Detection) (развитый в IJCV 2024). В данном подходе последовательность кадров видео компонуется в единое составное изображение (thumbnail layout), которое затем обрабатывается пространственным трансформером (Swin Transformer). Временная информация кодируется неявно через пространственное расположение миниатюр.

TALL демонстрирует высокие результаты, однако его temporal modeling является неявным: модель обрабатывает составное изображение пространственными методами, а не моделирует последовательность кадров как временной ряд. Остаётся неясным, зависит ли результат от порядка кадров в layout и в какой мере модель действительно извлекает межкадровую динамику, а не пространственные закономерности составного изображения. Представляется, что неявное кодирование временной информации затрудняет интерпретацию и сужает возможности анализа.

2.2.4. Анализ в латентном и стилевом пространстве

Латентное пространство в контексте генеративных моделей - это сжатое внутреннее представление изображения в виде многомерного вектора

(обычно 512-1024 измерения), полученное в результате обработки изображения нейросетью-энкодером; стилевое пространство - подмножество латентного пространства, контролирующее визуальные характеристики (текстуру, освещение, мимику). Альтернативный подход, основанный на стилизованных латентных потоках, предложен Чой и соавт. [29] (Style Latent Flows, arXiv 2024). Подход моделирует последовательность стилизованных кодов, соответствующих кадрам видео, и анализирует динамику их изменения. Показано, что для реальных видео стилизованные коды изменяются плавно, тогда как для deepfake - с характерными скачками и нерегулярностями.

Ограничение данного подхода состоит в зависимости от стилизованного пространства конкретной генеративной архитектуры: метод проектировался для GAN-генерированного контента и может терять эффективность при переходе к диффузионным моделям или автоэнкодерным архитектурам, не имеющим аналогичного стилизованного пространства.

2.2.5. Анализ временных частот

Принципиально иное направление представляет анализ пиксельных временных частот (Ким и соавт. [19], ICCV 2025). Вместо пространственного частотного анализа [13] отдельных кадров (как в F3-Net) авторы анализируют спектральные характеристики изменения яркости каждого пикселя во времени. Показано, что deepfake видео содержат характерные аномалии во временном частотном спектре. Данный подход представляет перспективное направление, однако его устойчивость к сильному сжатию видео (деформирующему частотный спектр) требует дополнительного исследования.

2.2.6. Современные гибридные подходы

В 2025 году опубликовано несколько гибридных архитектур, комбинирующих различные типы временного моделирования. Ян и соавт. [15] предложили на CVPR 2025 подход Video-Level Blending с spatiotemporal adapter tuning, в котором предобученный пространственный детектор

дополняется лёгким адаптером, моделирующим временные зависимости. Подход демонстрирует высокую обобщающую способность при минимальных дополнительных вычислениях.

Пояснение терминов. Video-level blending - техника обучения, при которой модель видит смешанные клипы из разных видео (например, реальный фрагмент + манипулированный фрагмент в одном клипе), что заставляет её учиться идентифицировать локальные манипуляции внутри клипа и улучшает регуляризацию. Spatiotemporal fine-tuning - раздельная тонкая настройка пространственных и временных компонентов модели с разной скоростью обучения, что позволяет адаптировать каждую ветвь под её собственную природу признаков.

Параллельно были предложены архитектуры с двухпутевым (dual-path) моделированием: CNN-BiLSTM-Transformer, в котором BiLSTM и Transformer обрабатывают CNN-признаки параллельно, моделируя локальные и глобальные временные зависимости соответственно.

Систематический анализ роли временной когерентности проведён Ян и соавт. [15], рассмотревшими различные виды межкадровых несоответствий и их связь с качеством детектирования при различных условиях сжатия. Авторы показали, что явное моделирование временной согласованности повышает устойчивость детектора к компрессионным артефактам. Полученный результат согласуется с подходом, предлагаемым в настоящей работе, в котором разности последовательных кадров (frame differences) используются как явный сигнал межкадровых изменений. Отличие предлагаемого метода состоит в архитектурном разделении пространственной и временной обработки на независимые параллельные ветви, что обеспечивает возможность изолированной оценки вклада каждого типа признаков.

2.3. Методы на основе частотного и consistency-based анализа

Помимо пространственных и временных подходов, в литературе представлены методы, эксплуатирующие специфические свойства генеративных моделей.

Одним из наиболее известных частотных подходов является F3-Net (Frequency in Frequency Net; Цянь и соавт. [30]), который анализирует частотные характеристики отдельных кадров с использованием дискретного косинусного преобразования (DCT). Метод выявляет аномалии в высокочастотных компонентах, характерные для GAN-генерированных изображений.

Метод SPSL (Spatial-Phase Shallow Learning), предложенный Ли и соавт. [31], основан на анализе фазового спектра изображений (преобразование Фурье разлагает изображение на синусоидальные волны, каждая из которых характеризуется амплитудой - «силой» сигнала на данной частоте, и фазой - сдвигом волны во времени; именно фазовый спектр содержит информацию о структуре краёв и текстур, а амплитудный - о яркости и контрасте). Показано, что фазовые характеристики содержат информацию о структуре генеративного процесса, отличающую синтетические изображения от реальных.

Consistency-based методы (NACO - Negative Augmentation by Combining, метод обучения через генерацию «отрицательных» обучающих примеров путём смешивания кадров из разных видео; в настоящей работе NACO НЕ используется по двум причинам: (1) NACO ортогонален архитектурному выбору и может быть применён поверх любой модели, в том числе предлагаемой dual-path; (2) основная гипотеза работы - в архитектурной декомпозиции, а не в расширении обучающего набора. NACO - Negative Augmentation by Combining, метод обучения представлений путём генерации «отрицательных» аугментаций смешиванием различных видео; [32]) используют самообучение (self-supervised learning) для извлечения представлений, устойчивых к различным типам манипуляции. Идея состоит в

обучении модели распознавать «естественную согласованность» реальных данных без явного обучения на конкретных типах deepfake.

Описанные методы дополняют пространственно-временной анализ, но не заменяют его: они работают преимущественно на уровне отдельных кадров и не моделируют межкадровую динамику. Предлагаемый в настоящей работе метод не включает явный частотный модуль, поскольку пространственная ветвь (EfficientNet-B4) способна неявно извлекать частотные признаки в процессе обучения на данных deepfake. Добавление эксплицитного частотного анализа [13] рассматривается как направление дальнейших исследований.

Связь с гипотезой настоящего исследования. Полученные в перечисленных работах результаты согласуются с гипотезой настоящего исследования: явное моделирование межкадровых изменений (через разности кадров, оптический поток или специализированные temporal-модули) обеспечивает более устойчивое детектирование, чем чистый пространственный анализ. Причина в том, что временные признаки не зависят от конкретной генеративной модели, а отражают фундаментальное свойство покадровой генерации - отсутствие явного моделирования межкадровой динамики на этапе синтеза видео. Это формирует основной архитектурный выбор настоящей работы: параллельная двухветвевая декомпозиция (раздел 3.2).

2.4. Методы повышения обобщающей способности

Проблема обобщения остаётся нерешённой. Деградация качества при cross-dataset evaluation мотивировала развитие методов, направленных на повышение обобщающей способности детекторов.

Важным шагом в повышении обобщающей способности стал метод Self-Blended Images (Сиохара и Ямасаки [33], CVPR 2022) (SBI), в котором обучающие данные генерируются путём наложения случайных областей лица на исходное изображение (self-blending). Поскольку операция

наложения является общей для всех face-swap методов, детектор, обученный на SBI, приобретает устойчивость к различным типам манипуляции.

Сюй и соавт. [34] предложили метод латентной аугментации (Transcending Forgery Specificity with Latent Space Augmentation) на CVPR 2024, в котором аугментация выполняется в латентном пространстве, обеспечивая более плавное и семантически осмысленное расширение обучающей выборки.

Недавно предложенный FreqBlender (Ван и соавт. [35], NeurIPS 2024) выполняет аугментацию в частотной области для создания более реалистичных синтетических примеров.

Перечисленные методы сфокусированы на data augmentation (расширение обучающей выборки путём искусственного создания новых обучающих примеров) и domain-agnostic обучении (обучении представлений, не зависящих от конкретного типа генерации). В настоящей работе данные методы не применяются по двум причинам: (1) они ортогональны архитектурному выбору и могут быть применены поверх любой модели, в том числе предлагаемой - то есть их интеграция представляет независимое направление исследований; (2) основная гипотеза настоящей работы - не в улучшении обучающей выборки, а в архитектурной декомпозиции (раздельные пространственная и временная ветви) и явном моделировании межкадровой динамики через разности кадров. Предлагаемый в настоящей работе метод решает проблему обобщения с другой стороны - через параллельное извлечение пространственных и временных признаков с явным temporal input, что является комплементарным подходом. Комбинация SBI-подобной аугментации с dual-path архитектурой представляет собой перспективное направление дальнейших исследований.

Причина неприменения в настоящей работе. Перечисленные методы повышения обобщающей способности через data augmentation и domain-agnostic обучение не применяются по двум причинам: (1) основной вклад настоящей работы - в архитектурной декомпозиции (раздельные

пространственная и временная ветви) и явном моделировании межкадровой динамики через разности кадров (раздел 3.5), что ортогонально augmentation-стратегиям; (2) применение этих методов поверх предлагаемой dual-path архитектуры может только улучшить результат и представляет независимое направление дальнейших исследований.

2.5. Наборы данных и протоколы оценки

Развитие методов детектирования deepfake неразрывно связано с развитием стандартных наборов данных и протоколов оценки.

FaceForensics++ (FF++) [3], предложенный Рёсслером и соавт. в 2019 году, содержит 1000 оригинальных видео с YouTube и 4000 манипулированных видео, созданных четырьмя методами: DeepFakes, Face2Face, FaceSwap и NeuralTextures. Датасет доступен в трёх уровнях сжатия: без сжатия (c0), лёгкое сжатие H.264 (c23) и сильное сжатие (c40). Официальный train/val/test split (720/140/140 видео по video ID) обеспечивает защиту от утечки данных (data leakage) и является обязательным для корректного сравнения результатов.

Celeb-DF v2 [36], предложенный Ли и соавт. в 2020 году, содержит 590 реальных и 5639 манипулированных видео знаменитостей, созданных усовершенствованным автоэнкодерным методом. Визуальное качество манипулированных видео в данном датасете существенно выше, чем в FF++: показатель Mask-SSIM составляет 0.92, что делает детектирование значительно сложнее. Celeb-DF v2 широко используется для оценки обобщающей способности: модель обучается на FF++ и тестируется на Celeb-DF v2 без дообучения (zero-shot).

Deepfake Detection Challenge (DFDC) [37], организованный компанией Meta, является крупнейшим публичным датасетом: он содержит более 100 тысяч видеоклипов, созданных несколькими методами манипуляции, с разнообразием рас, условий освещения и разрешений. Датасет доступен в полной версии (~470 GB) и в preview-версии (~5000 видео), которая используется при ограниченных вычислительных ресурсах.

DeepfakeBench [25], предложенный Яном и соавт. на NeurIPS 2023, представляет собой унифицированную платформу для оценки детекторов deepfake. В настоящей работе DeepfakeBench используется как референсный источник: (1) для протокола ablation study (раздел 4.4) - воспроизведена методология сравнения архитектур; (2) для baseline-метрик - значения AUC для XceptionNet, EfficientNet-B4 на FF++ из таблиц DeepfakeBench приведены в обзоре как ориентир для сопоставления; (3) для эталонной величины падения AUC при cross-dataset переносе (15-25%) - воспроизведено в нашем эксперименте DFDC02 → DFD01 (Таблица 4.4). Платформа включает стандартизированный preprocessing, единообразные протоколы обучения и оценки, а также результаты 15+ детекторов на 9 датасетах. Эта работа служит основным ресурсом для корректного сравнения методов.

Применение DeepfakeBench в трёх ролях. (1) Референсный источник baseline-метрик XceptionNet и EfficientNet-B4 на FF++ (Таблица 2.1) - для контекста сопоставления нашего метода с литературными значениями. (2) Источник методологии cross-dataset evaluation (раздел 4.4.1 - воспроизведена структура переноса между датасетами с измерением деградации AUC). (3) Ориентир величины падения AUC при cross-domain переносе (литературные 15-25%) - наш эксперимент DFDC02→DFD01 (Таблица 4.4) воспроизводит этот эффект на доступных датасетах. Прямое использование инфраструктуры DeepfakeBench не выполнено ввиду различия в датасетах и метриках.

2.6. Сравнительный анализ и выявление ограничений существующих подходов

На основании проведённого обзора в таблице 2.1 представлено сравнение ключевых методов детектирования манипулированного видео.

Таблица 2.1 - Сравнительный анализ методов детектирования

Метод	Тип анализа	Temporal input	Backbone	FF++ c23 AUC	Celeb-DF AUC	Источники
XceptionNet [3]	Покадров	-	Xception	~99.7%	~73%	[25]

	ый					
EfficientNet-B4	Покадровый	-	EffNet-B4	~99.6%	~76%	[25]
CNN+LSTM [16]	Послед. ST	CNN embeddings	Various	~97%	~72%	[16]
AltFreezing [24]	3D ST	3D conv	3D ResNet	~99.2%	~86%	[24]
TALL [28]	Layout ST	Thumbnail	Swin-T	~99.5%	~90%	[28]
Style Latent Flows [29]	Latent ST	Style codes	-	~99.5%	~87%	[29]

Примечание: значения метрик приведены по данным оригинальных публикаций соответствующих методов. Результаты получены при различных условиях оценки (preprocessing, train/test split, compression level), поэтому таблица служит сравнительным ориентиром, а не количественным сопоставлением; в главе 4 настоящей работы для прямого сравнения используются эксперименты, выполненные в единообразных условиях на одной обучающей и тестовой выборках.

Анализ позволяет выделить следующие ключевые ограничения существующих подходов:

Первое: значительная деградация обобщающей способности покадровых методов. При переходе от in-domain к cross-dataset evaluation AUC снижается на 15-25% для CNN-основанных методов и на ~11% для Transformer-основанных [25]. Это свидетельствует о том, что покадровые детекторы переобучаются на артефакты конкретных генеративных методов.

Второе: зависимость temporal branch от spatial в последовательных архитектурах. В подходах CNN→LSTM и CNN→Transformer временная ветвь получает на вход пространственные представления и не может компенсировать дефицит пространственной информации. Это ограничивает специализацию каждой ветви на своём типе признаков.

Третье: неразделимость пространственного и временного вкладов в 3D CNN. В методах, использующих трёхмерные свёртки (AltFreezing),

невозможно определить, какой тип информации - пространственный или временной - является решающим для конкретного типа манипуляции.

Четвёртое: отсутствие явного temporal input (temporal input - данные, явно содержащие межкадровую информацию; в настоящей работе это нормированные разности соседних кадров $D_i = f_{i+1} - f_i$, в отличие от неявного извлечения временных признаков из последовательности RGB-кадров стандартными CNN+LSTM подходами). Большинство рассмотренных методов полагаются на неявное извлечение временных признаков из RGB-кадров, а не из explicit temporal signal (разностей кадров, оптического потока). Это ограничивает способность модели целенаправленно обнаруживать межкадровые несоответствия.

Пятое: ограниченная интерпретируемость существующих архитектур. В большинстве рассмотренных методов на этапе инференса невозможно выделить вклад отдельных видов признаков и определить, какой тип информации (пространственный или временной) доминирует при принятии решения о конкретном видео.

Выявленные ограничения мотивируют разработку метода, обладающего тремя свойствами, отсутствующими в рассмотренных подходах в их совокупности: (1) параллельным извлечением пространственных и временных признаков с явным временным входом - нормированными разностями кадров, что позволяет временной ветви получать прямой сигнал о межкадровых изменениях, не опосредованный пространственным представлением; (2) обучаемым механизмом объединения признаков, обеспечивающим интерпретируемость распределения вклада ветвей в каждом конкретном предсказании; (3) воспроизводимым протоколом обучения и оценки с раздельной отчётностью по поддоменам, что отличает работу как от закрытых коммерческих детекторов (Sensity AI, Deepware Scanner), не предоставляющих верифицируемых результатов, так и от академических работ, в которых per-domain разбивка качества обычно не приводится. Описание предлагаемого метода представлено в главе 3,

экспериментальная оценка по двум измерениям - in-domain и cross-dataset - в главе 4.

Выводы по главе 2

В данной главе проведён систематический обзор существующих методов детектирования манипулированных видеопоследовательностей. Рассмотрены покадровые методы, методы на основе временного анализа (последовательные, 3D CNN, thumbnail layout, латентные и частотные), а также подходы к повышению обобщающей способности. Проанализированы стандартные наборы данных и протоколы оценки.

Сравнительный анализ выявил пять ключевых ограничений существующих подходов: деградацию обобщающей способности покадровых методов, зависимость temporal branch от spatial в последовательных архитектурах, неразделимость вкладов в 3D CNN, отсутствие явного temporal input и ограниченную интерпретируемость. Перечисленные ограничения обосновывают предлагаемый подход, описанный в следующей главе.

ГЛАВА 3. ПРЕДЛАГАЕМЫЙ МЕТОД

3.1. Формальная постановка задачи

Задача детектирования манипулированных видеопоследовательностей формулируется как задача бинарной классификации. Пусть дана видеопоследовательность V , представленная упорядоченным набором кадров $V = \{f_1, f_2, \dots, f_N\}$, где N - общее число кадров, $f_i \in \mathbb{R}^{H \times W \times 3}$ - i -й кадр в цветовом пространстве RGB. Требуется построить модель M , отображающую V в вероятность принадлежности к классу «манипулированное видео»:

Развёрнутое пояснение постановки. Формализация задачи как бинарной классификации с непрерывным выходом $p_{\text{fake}} \in [0,1]$ (вероятность принадлежности к классу «fake») позволяет применять стандартные метрики оценки (AUC, EER, Ассигасу, F1) и сравнивать результаты с существующими методами в единой системе оценок. Бинарное решение принимается через сравнение с порогом τ - выбор порога τ влияет на баланс между ложноположительными и ложноотрицательными ошибками; в настоящей работе основной метрикой является AUC-ROC, не зависящая от выбора порога.

$$P(\text{fake} | V) = M(V) \in [0, 1].$$

Бинарное решение принимается при заданном пороге τ : видео классифицируется как манипулированное, если $P(\text{fake} | V) \geq \tau$. В качестве основной метрики оценки используется AUC-ROC, не зависящая от выбора порога.

Предполагается, что видео содержит хотя бы одно лицо. В случае нескольких лиц анализируется наибольшее по площади. Видео может быть подвергнуто сжатию (кодеки H.264, H.265), лицо может быть частично перекрыто. Из полной последовательности кадров методом равномерной выборки формируется подмножество T кадров (clip), используемое в качестве входа модели.

3.2. Общая архитектура метода

Предлагаемый метод основан на параллельной двухветвевой архитектуре (parallel dual-path), в которой пространственные и временные признаки извлекаются независимо и объединяются с помощью обучаемого механизма взвешивания (adaptive weighted fusion).

Полный конвейер обработки включает следующие этапы:

Предобработка: извлечение кадров из видео, детекция лица с помощью MTCNN, формирование лицевой области с отступом, формирование клипа из $T=16$ кадров, вычисление разностей последовательных кадров (frame differences).

Пространственная ветвь (spatial branch): извлечение пространственных признаков из каждого кадра с помощью предобученной свёрточной сети EfficientNet-B4 с последующей агрегацией по времени.

Временная ветвь (temporal branch): извлечение признаков межкадровой динамики из разностей последовательных кадров с помощью облегчённой свёрточной сети EfficientNet-B0 и Temporal Transformer Encoder.

Объединение признаков (fusion): обучаемое взвешивание представлений двух ветвей.

Классификационная голова: полносвязные слои с сигмоидной активацией для вычисления $P(\text{fake} | V)$.

Это обеспечивает независимость извлекаемых признаков и позволяет выполнять чистый ablation study, изолируя вклад каждой ветви. Общая схема архитектуры приведена на рисунке 3.1.




Рисунок 3.1 - Блок-схема предлагаемого метода (dual-path архитектура: Spatial Branch (EfficientNet-B4) + Temporal Branch (EfficientNet-B0 + Transformer) → Adaptive Weighted Fusion → Classification Head)

Подробное описание блок-схемы (Рис. 3.1). (1) Входное видео V проходит через MTCNN-детектор лица для каждого кадра. (2) Равномерно выбирается $T=16$ кадров с обнаруженным лицом (uniform sampling). (3) Кадры идут параллельно в две ветви: пространственная (EfficientNet-B4) извлекает признаки из каждого RGB-кадра отдельно, временная (EfficientNet-B0 + Transformer) - из разностей соседних кадров $D_i = f_{i+1} - f_i$. (4) Спациальные признаки усредняются по времени, темпоральные агрегируются Transformer-энкодером с CLS-токеном. (5) Оба векторных представления (по 512 чисел) объединяются adaptive weighted fusion с обучаемыми весами α_{spatial} , α_{temporal} . (6) Объединённый вектор подаётся в классификационную голову, на выходе - $p_{\text{fake}} \in [0, 1]$.

3.3. Предобработка видеоданных

Предобработка видеоданных включает детекцию лица, формирование лицевой области, формирование клипа и вычисление разностей кадров.

Детекция лица. Для каждого кадра выполняется детекция лица с использованием модели MTCNN [39] (Multi-task Cascaded Convolutional

Networks - современный детектор лиц на основе свёрточных нейронных сетей, отличающийся от классических каскадных детекторов типа Haar Cascade (классический детектор лиц на основе каскадов признаков Haar и алгоритма AdaBoost; Viola-Jones 2001; в настоящей работе НЕ применяется - заменён MTCNN, современным нейросетевым детектором, дающим более точные bounding box на лицах при разных ракурсах и освещении) [Viola-Jones 2001] использованием CNN вместо вручную сконструированных Haar-признаков; обеспечивает существенно более высокую точность на современных видеоформатах). MTCNN реализует каскад из трёх свёрточных сетей (P-Net, R-Net, O-Net), последовательно уточняющих положение лица. Порог минимальной уверенности детектора установлен равным 0.90. В случае обнаружения нескольких лиц в кадре используется лицо с наибольшей площадью ограничивающего прямоугольника (bounding box). Данное упрощение обосновано тем, что в большинстве видео из бенчмарков deepfake detection основной объект манипуляции занимает наибольшую площадь кадра.

Формирование лицевой области. Ограничивающий прямоугольник, полученный от MTCNN, расширяется на 20% по каждому измерению ($\text{margin ratio} = 0.20$) для захвата контекста вокруг лица (волосы, уши, шея). Расширенная область вырезается из исходного кадра и масштабируется до размера 224×224 пикселей для пространственной ветви и 128×128 пикселей для временной ветви. Аффинное выравнивание по ключевым точкам в финальную версию пайплайна не включалось, что позволило сохранить устойчивость и воспроизводимость предобработки в рамках выбранной экспериментальной установки (раздел 4.1).

Формирование клипа. Из полного набора кадров видео с успешной детекцией лица формируется клип из $T=16$ кадров методом равномерной выборки (uniform sampling - равномерная выборка кадров (с равными

интервалами времени между кадрами, что обеспечивает покрытие всей длительности видео)). Если число кадров с лицом M превышает T , выбираются кадры с индексами $i_k = \text{floor}(k \cdot M / T)$ для $k = 0, 1, \dots, T-1$. Если $M < T$, последовательность дополняется циклическим повторением. Для включения видео в выборку требуется минимум 16 кадров с успешной детекцией лица ($\text{min_saved_faces} = 16$), при этом минимальная доля успешных детекций должна составлять не менее 55%. При обучении применяется лёгкий *temporal jitter*: каждый кадр выбирается случайно внутри своего равномерного сегмента. При валидации и тестировании используется детерминированный *uniform sampling* для воспроизводимости.

Вычисление разностей кадров. Для формирования входа временной ветви вычисляются разности последовательных выровненных кадров:

$$D_i = f_{i+1} - f_i, i = 1, 2, \dots, T-1,$$

где f_i - сгор i -го кадра. Результат - $T-1 = 15$ разностных изображений размером $128 \times 128 \times 3$. Разностные изображения нормализуются по клипу: для каждого канала вычитается среднее и выполняется деление на стандартное отклонение.

Использование разностей кадров в качестве входа временной ветви обосновано следующим. Разности явно кодируют межкадровые изменения: для реальных видео они содержат преимущественно плавные изменения, связанные с мимикой и движением, тогда как для *deepfake* - артефакты дрейфа лицевых признаков, мерцания текстур и несогласованности границ. Рассматривались три варианта представления межкадровой динамики: (1) оптический поток (*optical flow*), (2) разности последовательных кадров (*frame differences*), (3) прямая подача RGB-кадров в рекуррентную или трансформерную модель. Оптический поток обеспечивает точное моделирование движения, однако требует значительных вычислительных затрат (алгоритмы *Farneback* или *RAFT*) и теряет цветовую информацию, которая может содержать артефакты *deepfake* (несогласованность цвета кожи

между кадрами). Прямая подача RGB-кадров не обеспечивает явного кодирования межкадровых изменений и перекладывает задачу извлечения временных признаков целиком на модель. Разности кадров выбраны как компромисс: они явно кодируют межкадровые изменения, сохраняют цветовую информацию, не требуют дополнительных вычислений и допускают простую нормализацию. Данный выбор согласуется с результатами Яна и соавт. [15], показавших, что дрейф лицевых признаков (Facial Feature Drift) наиболее выражен именно в разностных изображениях.

Пояснение по инженерии признаков. Нормированные разности кадров $D_i = (f_{i+1} - f_i) / \sigma_D$, где σ_D - стандартное отклонение по обучающей выборке, представляют собой явно сконструированный признак (engineered feature): этот шаг превращает последовательность RGB-кадров в последовательность изменений, эксплицитно кодируя информацию о движении. В отличие от чистого end-to-end обучения, где модель сама должна научиться извлекать межкадровую информацию из RGB-входа, разности дают ей прямую сигнальную форму для временной ветви. Это уменьшает требования к объёму обучающих данных и улучшает интерпретируемость.

Нормализация RGB (приведение значений пикселей к нулевому среднему и единичной дисперсии путём вычитания среднего и деления на стандартное отклонение, что ускоряет сходимость обучения)-кадров. Кадры для пространственной ветви нормализуются с использованием статистик ImageNet [41]: mean = [0.485, 0.456, 0.406], std = [0.229, 0.224, 0.225].

3.4. Пространственная ветвь (spatial branch)

Пространственная ветвь извлекает признаки из отдельных кадров видеоклипа, характеризующие текстурные, спектральные и blending-артефакты.

Backbone. В качестве backbone используется EfficientNet-B4 [5] с весами, предобученными на ImageNet. EfficientNet-B4 содержит 19

миллионов параметров и использует комбинированное масштабирование глубины, ширины и разрешения. Выбор обусловлен широким использованием данной архитектуры в литературе по детектированию deepfake [25] и наличием предобученных весов.

Извлечение признаков. Каждый из $T=16$ кадров клипа обрабатывается EfficientNet-B4 независимо. Выход последнего свёрточного блока подвергается глобальному усредняющему пулингу (global average pooling), в результате чего для каждого кадра формируется вектор признаков $h_s^i \in \mathbb{R}^{\{1792\}}$, $i = 1, \dots, T$.

Агрегация по времени. Поскольку пространственная ветвь ориентирована на покадровые признаки, агрегация по T кадрам выполняется усреднением:

$$h_{s_agg} = (1/T) \cdot \sum_{i=1}^T h_s^i \in \mathbb{R}^{\{1792\}}.$$

Проекция. Агрегированный вектор проецируется в общее пространство fusion (проекция - применение полносвязного линейного слоя, преобразующего вектор размерности N в вектор размерности M ; необходим для приведения признаков пространственной и временной ветвей к одинаковой размерности перед объединением) с помощью линейного слоя:

$$h_{s_proj} = \text{ReLU}(W_s \cdot h_{s_agg} + b_s) \in \mathbb{R}^{\{512\}},$$

где $W_s \in \mathbb{R}^{\{512 \times 1792\}}$ и $b_s \in \mathbb{R}^{\{512\}}$ - обучаемые параметры.

Режим обучения. В финальной конфигурации первые 5 эпох (warmup - фаза обучения с постепенным увеличением скорости обучения от нуля до базового значения; используется LinearLR scheduler для плавной адаптации к данным без скачков градиента) веса backbone EfficientNet-B4 заморожены (замораживание - технический термин: параметры этих слоёв исключены из расчёта градиентов и не обновляются при backpropagation; используется первые 5 эпох для стабилизации, чтобы избежать разрушения предобученных весов резкими обновлениями от случайно инициализированных верхних

слоёв). После `warmup` размораживаются два последних блока `backbone` (`unfreeze_last_n_blocks = 2`), что позволяет адаптировать высокоуровневые признаки к задаче детектирования `deepfake`. Данная стратегия обеспечивает баланс между использованием предобученных ImageNet-представлений и доменной адаптацией.

3.5. Временная ветвь (temporal branch)

Временная ветвь извлекает признаки межкадровой динамики из разностей последовательных кадров, характеризующие дрейф лицевых признаков, нарушения мимической динамики и несогласованность идентичности.

Извлечение признаков из разностей кадров. Каждое из $T-1 = 15$ разностных изображений $D_i \in \mathbb{R}^{128 \times 128 \times 3}$ обрабатывается облегчённой свёрточной сетью EfficientNet-B0 [5] с весами, предобученными на ImageNet. EfficientNet-B0 содержит 5.3 миллиона параметров. Выбор облегчённой модели обусловлен архитектурной гипотезой и анализом входных данных. Разностные изображения (frame differences) содержат существенно меньше абсолютной текстурной информации по сравнению с RGB-кадрами: их информационное содержание сосредоточено на межкадровых изменениях, а не на статической текстуре. Рассматривались варианты EfficientNet-B0 (5.3М параметров), B2 (9.2М) и B4 (19.3М). Использование B4 для обеих ветвей привело бы к удвоению вычислительной стоимости без пропорционального прироста качества, поскольку входной сигнал (разности кадров) имеет существенно более простую структуру, чем RGB-изображения. EfficientNet-B0 обеспечивает достаточную ёмкость для извлечения паттернов дрейфа лицевых признаков и мерцания текстур при минимальных вычислительных затратах. Корректность данного выбора верифицируется в ablation study (раздел 4.4).

Выход глобального усредняющего пулинга EfficientNet-B0 для каждого разностного изображения: $d_i \in \mathbb{R}^{1280}$. Линейная проекция:

$d_{i_proj} = \text{ReLU}(W_d \cdot d_i + b_d) \in \mathbb{R}^{\{256\}}$, К проекции дополнительно применяются LayerNorm для нормализации признаков перед подачей в Transformer и Dropout с вероятностью 0.1 для регуляризации.

где $W_d \in \mathbb{R}^{\{256 \times 1280\}}$ и $b_d \in \mathbb{R}^{\{256\}}$ - обучаемые параметры.

Temporal Transformer Encoder. Последовательность проецированных признаков $\{d_{1_proj}, \dots, d_{\{T-1\}_proj}\}$ обрабатывается трансформерным кодировщиком (Transformer Encoder) для моделирования зависимостей между всеми парами кадровых переходов.

К входной последовательности добавляется обучаемое позиционное кодирование (learnable positional encoding) размерности 256, а также специальный токен [CLS], агрегирующий информацию всей последовательности.

Архитектура Temporal Transformer: 2 слоя, 4 головы внимания, размерность модели $d_{model} = 256$, размерность feedforward-слоя $d_{ff} = 1024$, $dropout = 0.1$.

Выход: вектор, соответствующий токenu [CLS], после линейной проекции:

$$h_{t_proj} = \text{ReLU}(W_t \cdot h_{CLS} + b_t) \in \mathbb{R}^{\{512\}},$$

где $W_t \in \mathbb{R}^{\{512 \times 256\}}$ и $b_t \in \mathbb{R}^{\{512\}}$ - обучаемые параметры.

Выбор Transformer вместо LSTM обусловлен следующим: при длине последовательности $T-1 = 15$ вычислительная стоимость самовнимания незначительна на современных GPU ($15^2 = 225$ пар), при этом механизм внимания моделирует глобальные зависимости между всеми кадровыми переходами и обеспечивает интерпретируемость через визуализацию карт внимания (attention maps). Корректность данного выбора проверяется в ablation study (сопоставление с архитектурой A4 (BiLSTM-агрегатор кадров)).

3.6. Механизм объединения признаков (adaptive weighted fusion)

Признаки пространственной и временной ветвей объединяются с помощью обучаемого механизма взвешивания:

Развёрнутое пояснение обучаемого взвешивания. Веса α_{spatial} и α_{temporal} не зафиксированы вручную, а являются параметрами линейного слоя W_a , обучаемого вместе с остальной моделью через backpropagation. На вход слою подаётся конкатенация спатимального и темпорального признаков векторов (размерности 1024), на выходе - два значения, нормированные через softmax в сумму 1. Так модель сама учится определять, какой ветви больше доверять для каждого конкретного видео: например, для видео с явными blending-артефактами обычно доминирует спатимальная ветвь ($\alpha_{\text{spatial}} > \alpha_{\text{temporal}}$), для видео с малыми пространственными артефактами, но нарушенной межкадровой динамикой - темпоральная ($\alpha_{\text{temporal}} > \alpha_{\text{spatial}}$).

$$\alpha = \text{softmax}(W_a \cdot [h_s_{\text{proj}} ; h_t_{\text{proj}}] + b_a) \in \mathbb{R}^{\{2\}},$$

$$h_{\text{fused}} = \alpha_1 \cdot h_s_{\text{proj}} + \alpha_2 \cdot h_t_{\text{proj}} \in \mathbb{R}^{\{512\}},$$

где $W_a \in \mathbb{R}^{\{2 \times 1024\}}$ и $b_a \in \mathbb{R}^{\{2\}}$ - обучаемые параметры; $[\cdot ; \cdot]$ обозначает конкатенацию; α_1 и α_2 - нормализованные веса, определяющие вклад каждой ветви.

Данный механизм является обучаемой взвешенной суммой (learned weighted sum). Рассматривались три механизма объединения: (1) конкатенация с линейной проекцией - простейший вариант, не учитывающий относительную важность ветвей; (2) gated fusion - обучаемый вентиль, определяющий пропускную способность каждой ветви; (3) adaptive weighted fusion - обучаемое взвешивание с нормализацией через softmax. Выбор adaptive weighted fusion обусловлен двумя причинами. Во-первых, нормализованные веса α_1 и α_2 непосредственно интерпретируемы: для каждого видео можно определить, какая ветвь доминирует при принятии решения. Во-вторых, в отличие от gated fusion, softmax-нормализация обеспечивает, что $\alpha_1 + \alpha_2 = 1$, что исключает неконтролируемое масштабирование признаков. Конкатенация, gated fusion и adaptive fusion сравниваются в ablation study (раздел 4.4)

3.7. Классификационная голова и функция потерь

Классификационная голова. Объединённый вектор h_fused подаётся на вход полносвязной сети:

Пояснение $P(fake|V)$. Это условная вероятность того, что видео V является манипулированным, при условии данной модели и её обученных параметров. Вычисляется как $\sigma(z)$, где $\sigma(x) = 1/(1+\exp(-x))$ - сигмоидная функция активации, преобразующая логит $z \in \mathbb{R}$ в вероятность $p \in [0, 1]$. Интерпретация: $p < 0.5$ означает, что модель считает видео реальным; $p \geq 0.5$ - манипулированным. Сигмоидная функция гарантирует, что выход всегда находится в диапазоне $[0, 1]$, что необходимо для применения метрик классификации (AUC, EER) и для интерпретации как вероятности.

$$P(fake | V) = \sigma(W_3 \cdot \text{ReLU}(\text{Dropout}(W_2 \cdot \text{ReLU}(W_1 \cdot h_fused + b_1) + b_2)) + b_3),$$

К каждому скрытому слою дополнительно применяется BatchNorm1d (для стабилизации обучения), Dropout(0.3) применяется после обеих ReLU-активаций.

где σ - сигмоидная функция; $W_1 \in \mathbb{R}^{256 \times 512}$, $W_2 \in \mathbb{R}^{128 \times 256}$, $W_3 \in \mathbb{R}^{1 \times 128}$ - обучаемые матрицы; Dropout с вероятностью 0.3 применяется для регуляризации.

Функция потерь. Обучение выполняется с использованием бинарной кросс-энтропии (Binary Cross-Entropy, BCE):

Пояснение BCE. Binary Cross-Entropy - функция потерь для задач бинарной классификации: $L = -[y \cdot \log(p) + (1-y) \cdot \log(1-p)]$, где y - истинная метка (0 - real, 1 - fake), p - предсказанная вероятность fake. В настоящей работе используется PyTorch BCEWithLogitsLoss, который сочетает sigmoid и BCE в один численно стабильный модуль, избегая отдельного вычисления sigmoid с риском numerical underflow для очень малых вероятностей. BCE минимизируется, когда p приближается к y для каждого обучающего примера.

$$L = -[y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y})],$$

где $y \in \{0, 1\}$ - истинная метка (0 - реальное видео, 1 - манипулированное), $\hat{y} = P(\text{fake} | V)$ - предсказанная вероятность.

3.8. Протокол обучения

Обучение модели выполняется с использованием оптимизатора AdamW (Adaptive Moment Estimation with Weight Decay - современный оптимизатор градиентного спуска с адаптивными моментами и явной регуляризацией весов; эмпирически показывает лучшую сходимость на трансформерных архитектурах по сравнению с SGD - Stochastic Gradient Descent, классическим стохастическим градиентным спуском) [38] с весовой регуляризацией (weight decay) 1×10^{-4} . Выбор AdamW обусловлен его преимуществами перед стандартным Adam и SGD в задачах fine-tuning предобученных моделей: корректная реализация weight decay (decoupled от адаптивного момента) обеспечивает более эффективную регуляризацию. SGD с momentum рассматривался как альтернатива, однако требует более тщательного подбора learning rate и не обеспечивает адаптивного масштабирования градиентов, критически важного при обучении архитектуры с компонентами разной степени инициализации (предобученный backbone и случайно инициализированные temporal branch, fusion, head). Применяются дифференцированные скорости обучения: 1×10^{-4} для параметров backbone (при их размораживании) и 3×10^{-4} для остальных обучаемых параметров (temporal branch, fusion, classification head). Различие LR обосновано тем, что backbone уже содержит качественные ImageNet-представления и требует осторожной адаптации, тогда как новые компоненты инициализированы случайно и требуют более агрессивного обучения. Расписание скорости обучения: LinearLR warmup (линейный рост от $0.001 \times \text{target}$ до target за 5 эпох), затем CosineAnnealingLR (планировщик скорости обучения, плавно снижающий learning rate по косинусоидальному закону от начального значения до минимума через max_epochs эпох; обеспечивает постепенное «охлаждение» обучения и помогает модели сойтись в более точный минимум) до конца обучения. Данная стратегия

предпочтена ReduceLROnPlateau, поскольку обеспечивает предсказуемое и плавное снижение LR без зависимости от шумных оценок валидационных метрик

Пояснение LR-планировщиков. LinearLR - линейное увеличение скорости обучения от 0 до базового значения за warmup эпох; используется первые 5 эпох. CosineAnnealingLR - последующее косинусное снижение скорости обучения от базового значения до минимума к концу обучения; используется эпохи 6-30. Сочетание LinearLR (5 эпох warmup) + CosineAnnealingLR (25 эпох annealing) обеспечивает плавный старт без разрушения предобученных весов и постепенное снижение шага для финальной тонкой настройки - стандартная практика transfer learning.

Выбор AdamW vs SGD. AdamW выбран по двум причинам. (1) Адаптивная скорость обучения: AdamW автоматически адаптирует шаг градиентного спуска для каждого параметра на основе исторических градиентов (моменты первого и второго порядков), что критично для модели с разной размерностью слоёв (EfficientNet-B4: 19.3M, EfficientNet-B0: 5.3M, Transformer: 1.58M параметров). (2) Корректный weight decay: AdamW использует L2-регуляризацию отдельно от momentum (Decoupled Weight Decay, Loshchilov & Hutter 2019), что улучшает обобщающую способность по сравнению с Adam. В литературе по CV-задачам с трансферным обучением и ограниченным обучающим набором AdamW в среднем превосходит SGD.

Стратегия обучения включает две фазы. Первые $N_{warmup} = 5$ эпох являются фазой прогрева (warmup), в течение которой backbone пространственной ветви полностью заморожен и обучаются только temporal branch, fusion и classification head. Данная стратегия обусловлена различием в степени инициализации компонентов: backbone содержит качественные предобученные признаки, тогда как остальные компоненты инициализированы случайно. Совместное обучение с первой эпохи привело бы к тому, что большие градиенты от случайно инициализированных слоёв разрушат предобученные представления backbone (catastrophic forgetting).

После warmup размораживаются два последних блока backbone (`unfreeze_last_n_blocks = 2`), что позволяет адаптировать высокоуровневые признаки к домену deepfake detection, сохраняя при этом низкоуровневые текстурные представления. Число размораживаемых блоков (2 из 7 в EfficientNet-B4) выбрано как компромисс между адаптацией и стабильностью: размораживание всех блоков увеличивает риск переобучения на ограниченном датасете (~2300 видео для обучения), а полное замораживание ограничивает доменную адаптацию.

Обоснование разной скорости обучения для backbone и head. Различные lr (learning rate) для backbone и head обусловлены тем, что backbone (EfficientNet-B4) предобучен на ImageNet и содержит уже хорошие универсальные признаки - его веса нужно лишь тонко донастроить ($lr=1 \times 10^{-4}$, в 3 раза меньше). Голова (классификационные слои) и adaptive fusion (`W_a`) инициализированы случайно - им нужна более высокая скорость обучения ($lr=3 \times 10^{-4}$) для эффективного обучения с нуля. Эти значения подобраны на основе анализа литературы (Tan & Le 2019 [5] - рекомендации для transfer learning EfficientNet; общая практика дифференцированного lr для transfer learning в задачах CV).

Размер пакета (batch size - количество видео, обрабатываемых одновременно за один шаг градиентного спуска): 16 видео для $T=16$ кадров; 8 видео для $T=32$ (уменьшение вдвое из-за роста требований к памяти GPU при увеличении длины клипа). Смешанная точность (AMP, FP16) включена для ускорения обучения и экономии видеопамати на GPU (CUDA). Градиенты ограничиваются нормой 1.0 (gradient clipping) для стабильности обучения. Выбор модели (model selection) выполняется по наибольшему значению AUC-ROC на валидационной выборке (`primary_metric = AUC`). AUC-ROC выбрана в качестве основной метрики на основе анализа свойств доступных метрик. Ассигура зависит от выбора порога и чувствительна к дисбалансу классов - при соотношении классов 60:40 тривиальный классификатор, всегда предсказывающий мажоритарный класс, достигает

Accuracy = 0.60. F1-score учитывает баланс precision и recall, но также зависит от порога. AUC-ROC является порогонезависимой метрикой, оценивающей способность модели ранжировать манипулированные видео выше реальных при любом пороге решения, что делает её устойчивой к дисбалансу классов и обеспечивает корректное сравнение моделей без необходимости предварительного подбора порога. Кроме того, AUC-ROC является стандартной метрикой сравнения в DeepfakeBench [25] и большинстве публикаций по детектированию deepfake, что обеспечивает сопоставимость результатов. Early stopping с patience = 7 эпох предотвращает переобучение. Максимальное число эпох: 30.

Выбор batch_size=16. Размер пакета 16 видео обусловлен ограничениями VRAM на доступном GPU NVIDIA Tesla P100 (16 ГБ): полная dual-path модель с T=16 кадрами и batch=16 занимает около 14 ГБ. Увеличение T до 32 кадров удваивает потребление памяти, поэтому при T=32 batch снижается до 8. Малый batch_size компенсируется большим числом мини-батчей за эпоху, что обеспечивает достаточную статистическую мощность gradient updates.

Аугментация данных применяется при обучении ко всем кадрам клипа единообразно (clip-consistent): случайное горизонтальное отражение ($p = 0.5$), случайное изменение яркости (± 0.1) и контраста (± 0.1), случайное JPEG-сжатие (quality 70-95, $p = 0.3$) с одинаковым качеством для всех кадров одного клипа. Clip-consistent аугментация обеспечивает сохранение реалистичной межкадровой динамики, что критически важно для корректной работы временной ветви.

Дополнительные детали процедуры обучения. Обучение проводилось в три фазы: (1) Фаза warmup (эпохи 1-5): backbone (EfficientNet-B4 и B0) заморожен; обучаются только проекции, Transformer-кодировщик и классификационная голова; используется LinearLR scheduler (lr линейно растёт от 0 до базового). (2) Фаза fine-tuning (эпохи 6-30): размораживаются последние 2 блока EfficientNet-B4 и весь EfficientNet-B0; lr backbone

устанавливается в 1×10^{-4} , lr остальных компонентов - 3×10^{-4} ; используется CosineAnnealingLR с $T_{\text{max}}=25$ (оставшиеся после warmup эпохи). (3) Ранняя остановка: после эпохи `best_val_auc` обучение продолжается ещё максимум 7 эпох (patience) без улучшения, после чего останавливается; сохраняется чекпоинт с наивысшим val AUC. Все аугментации (HFlip, brightness/contrast jitter, JPEG-сжатие) применяются clip-consistent: одни параметры на весь клип из T кадров, чтобы временная динамика не нарушалась. Для DFDC02 один цикл обучения занимал около 2.2 ч на P100 при $T=16$ и 3.5 ч при $T=32$; для 3-датасетной конфигурации - 3.5 ч и 5.0 ч соответственно. Дополнительно для каждой эпохи логируется: `train_loss`, `train_auc`, `train_f1`, `val_loss`, `val_auc`, `val_f1`, `val_eer`; история сохраняется в `metrics.json` и доступна в `kaggle_output/`.

3.9. Резюме метода

В таблице 3.1 представлена сводка компонентов предлагаемого метода.

Таблица 3.1 - Компоненты предлагаемого метода

Компонент	Реализация	Размерность выхода	Параметры
Face detection	MTCNN (facenet-pytorch)	Bounding box	Pretrained, frozen
Frame sampling	Uniform, $T=16$	16 RGB crops 224×224	-
Frame differences	$f_{i+1} - f_i$	15 diff frames 128×128	-
Spatial backbone	EfficientNet-B4 (ImageNet)	1792 per frame	19M (5 эпох frozen, затем fine-tune 2 блока)
Spatial aggregation	Temporal average pooling	1792	-
Spatial projection	Linear + ReLU	512	~920K
Temporal feature extractor	EfficientNet-B0 (ImageNet)	1280 per diff frame	5.3M (full fine-tune)
Temporal projection	Linear + LayerNorm + ReLU + Dropout(0.1)	256	~328K
Temporal Transformer	2 layers, 4 heads, $d=256$	256 ([CLS])	~1.58M
Temporal output	Linear + ReLU	512	~131K

projection			
Fusion	Adaptive weighted	512	~2K
Classification head	FC(512→256→128→1) + BatchNorm + Dropout(0.3) после каждой ReLU	1	~164K
Итого обучаемых параметров			~25.5M

Выводы по главе 3

В данной главе описан предлагаемый метод детектирования манипулированных видеопоследовательностей. Метод основан на параллельной двухветвевой архитектуре, в которой пространственная ветвь (EfficientNet-B4) извлекает покадровые признаки из RGB-кадров, а временная ветвь (EfficientNet-B0 + Temporal Transformer) извлекает признаки межкадровой динамики из разностей последовательных кадров. Признаки двух ветвей объединяются с помощью обучаемого механизма взвешивания и подаются на вход классификационной головы.

Архитектурные решения обоснованы результатами обзора литературы (глава 2): параллельность ветвей обеспечивает независимость признаков и возможность ablation study; разности кадров явно кодируют межкадровые изменения; Temporal Transformer моделирует глобальные зависимости при минимальной вычислительной стоимости; adaptive weighted fusion обеспечивает интерпретируемость. Экспериментальная проверка предлагаемого метода представлена в главе 4.

ГЛАВА 4. ЭКСПЕРИМЕНТАЛЬНАЯ ОЦЕНКА

4.1. Экспериментальная установка

4.1.1. Наборы данных

Экспериментальная оценка предлагаемого метода выполнена на трёх наборах данных: подмножестве Deepfake Detection Challenge (DFDC), организованного компанией Meta, FaceForensics-based наборе DFD01 и Celeb-DF v2. DFDC является крупнейшим публичным набором данных для задачи детектирования deepfake, содержащим более 100 тысяч видеоклипов с разнообразием рас, условий освещения, разрешений и методов манипуляции. DFD01 содержит 3431 видео (363 real, 3068 fake) с выраженным дисбалансом классов. Celeb-DF v2 [36] содержит 3299 видео (589 real, 2710 fake), созданных методом improved face swap. Использование трёх наборов данных с различными методами генерации позволяет исследовать влияние разнородности обучающей выборки на обобщающую способность модели.

Для экспериментов использовано предобработанное подмножество DFDC (далее - DFDC02, внутреннее обозначение `preprocessed_DFDC02_16`), включающее видео, прошедшие `face-centric preprocessing` с использованием детектора MTCNN. Из каждого исходного видеоролика извлечена последовательность лицевых областей (`face crops`) размером 224×224 пикселей. В итоговый набор включены только видео, для которых выполнены критерии минимального числа сохранённых лицевых кадров (не менее 16) и минимальной доли успешных детекций лица (не менее 55%). Для финальной экспериментальной серии использовано разбиение по `video_id`: 2303 видео для обучения, 493 для валидации и 496 для тестирования (приблизительно 70/15/15). Разбиение выполнено с стратификацией по классам и фиксированным `seed = 42`.

На этапе первичного исследовательского анализа (EDA) были исследованы два набора данных: `DFDC_Dataset_02` (приблизительно

3293 видеоролика формата mp4) и предобработанный набор кадров preprocessed_DFD01_16 (54815 изображений, real = 5686, fake = 49007). Второй набор характеризуется выраженным дисбалансом классов (соотношение fake:real $\approx$ 8.6:1). В EDA-отчёте для массовой диагностики лицевых областей использовался детектор Haar Cascade, тогда как в тренировочном пайплайне применяется более точный MTCNN; соответственно, показатели face detection rate из EDA-отчёта являются консервативной нижней оценкой. Итоговая серия экспериментов в главе 4 выполнена на зафиксированном подмножестве DFDC02 (preprocessed_DFDC02_16) с video-id based разбиением.

Применение датасетов в настоящей работе. DFDC02 (3293 видео) - основной обучающий датасет, обеспечивающий разнообразие условий освещения, рас и методов манипуляции; используется во всех ablation-экспериментах (разделы 4.3-4.4) и в cross-dataset переносе (4.4.1). DFD01 (3431 видео) - дополнительный датасет с выраженным дисбалансом классов (363 real, 3068 fake), используется как мульти-датасетная компонента (раздел 4.4.4) и как мишень для cross-dataset переноса. Celeb-DF v2 (3299 видео) - набор знаменитостей с улучшенным качеством face-swap; добавлен в трёхдатасетную конфигурацию (раздел 4.4.5) для оценки робастности к разнообразным методам генерации. Общий объём 10023 видео обеспечивает достаточную статистическую мощность для in-domain оценки.

Дополнительные характеристики и применение датасетов. (1) DFDC02 (Deepfake Detection Challenge subset 02) - подмножество DFDC от Meta; содержит сцены из разнообразных источников, многообразие методов face-swap (DFAE, MM/NN, NTH, FSGAN); сбалансированное распределение real/fake (~50/50). (2) DFD01 (DeepFake Detection v1) - набор от Google/Jigsaw на основе FaceForensics-протокола; сильный дисбаланс классов (363 real, 3068 fake) делает его challenge-выборкой для устойчивости к перекосу. (3) Celeb-DF v2 - набор знаменитостей с улучшенным алгоритмом face-swap (автокоррекция цвета, post-processing); ~50/50 распределение. Совокупный

объём 10023 видео обеспечивает достаточную статистическую мощность для in-domain оценки и для мульти-датасетного обучения.

Наборы данных для задачи deepfake detection, как правило, характеризуются дисбалансом классов, обусловленным тем, что из каждого исходного видео может генерироваться несколько манипулированных версий различными методами. По результатам EDA, набор DFD01 имеет соотношение fake:real $\approx 8.6:1$. Экспериментальное подмножество DFDC02 содержит 3293 видео (1566 fake, 1727 real), соотношение fake:real $\approx 0.91:1$, что обеспечивает приблизительный баланс классов. Разбиение выполнено со стратификацией, сохраняющей пропорции классов в каждом split. В качестве основной метрики оценки выбрана AUC-ROC, которая не зависит от порога классификации и устойчива к дисбалансу классов. В архитектуре проекта предусмотрены опции компенсации дисбаланса (class weights для функции потерь и weighted sampler для обучающей выборки), однако при сбалансированном DFDC02 они не активированы.

Замечание о компенсации дисбаланса. WeightedRandomSampler и pos_weight (техники компенсации дисбаланса классов) реализованы в коде модели (dataset.py:501-522, config.py:206-211), но в настоящей работе не активированы, поскольку основной обучающий датасет DFDC02 имеет приблизительно сбалансированное распределение real/fake ($\sim 50/50$). Активация этих техник при сбалансированных данных приводила бы к ухудшению результатов из-за искажения распределения мини-батчей и излишнего акцента на одном из классов.

4.1.2. Аппаратное и программное обеспечение

Обучение модели выполнено на платформе Kaggle с использованием GPU NVIDIA Tesla P100 (16 GB). Программное обеспечение: Python 3.12, PyTorch [42], версия 2.2.2+cu121, torchvision, timm, scikit-learn, facenet-pytorch, Flask. Локальная разработка и тестирование выполнялись на Apple MacBook (M2, MPS backend).

4.1.3. Гиперпараметры

Гиперпараметры обучения зафиксированы на основе анализа литературы (XceptionNet, Rössler 2019 [3]; EfficientNet, Tan&Le 2019 [5]; DeepfakeBench, Yan 2023 [25]; TimeSformer [23]), вычислительных ограничений и предварительных экспериментов. Автоматический подбор гиперпараметров (grid search - полный перебор по сетке значений; Bayesian optimization - вероятностный поиск на основе модели поверхности качества) не применялся по следующим причинам: (1) ограниченный бюджет GPU-часов (Kaggle: 30 часов/неделю), при котором один полный прогон 4 экспериментов занимает 8--12 часов; (2) приоритет ablation study над оптимизацией одной конфигурации - для ВКР важнее продемонстрировать вклад архитектурных компонентов, чем максимизировать метрику на доли процента; (3) выбранные значения соответствуют устоявшимся практикам в литературе по детектированию deepfake. Значения гиперпараметров и их обоснование представлены в таблице 4.1.

О подборе гиперпараметров через grid search/Bayesian optimization. Полноценный подбор гиперпараметров через grid search или Bayesian optimization (Optuna, Ray Tune) в настоящей работе не применялся ввиду ограниченного GPU-бюджета: каждая конфигурация обучается около 3 часов на P100, минимально показательный grid (5 значений $\times$ 4 параметра) потребовал бы порядка 60 GPU-часов, что превышает недельный квот Kaggle. Использованы значения, рекомендованные литературой по transfer learning EfficientNet (Tan & Le 2019 [5]) и DeepfakeBench (Yan et al. 2023 [25]). Полноценный hyperparameter search обозначен как направление дальнейшего развития.

Для реализации автоматического подбора потребовалось бы: (1) 50-100 прогонов в Optuna/Ray Tune для каждой конфигурации - порядка 300-600 GPU-часов вместо текущих 30; (2) расширение test split для устранения утечки гиперпараметров через валидацию. В рамках ВКР с ограниченным

GPU-бюджетом приоритет отдан ablation study архитектурных компонентов над оптимизацией гиперпараметров одной конфигурации.

Таблица 4.1 - Гиперпараметры обучения

Параметр	Значение
Оптимизатор	AdamW
Learning rate (spatial backbone)	1×10^{-4}
Learning rate (temporal, fusion, head)	3×10^{-4}
Планировщик LR	CosineAnnealingLR, T_max=25 (CosineAnnealingLR применяется после 5 эпох LinearLR warmup; итого 30 эпох обучения)
Размер пакета	16 видео
Максимальное число эпох	30
Ранняя остановка	Patience=7, метрика: AUC на val
Weight decay	1×10^{-4}
Dropout (classification head)	0.3
Gradient clipping	max_norm=1.0
Mixed precision	FP16 на CUDA (Kaggle GPU); отключено по умолчанию для CPU/MPS
Random seed	42
Warmup (frozen spatial backbone)	5 эпох (затем разморозка 2 последних блоков)
Число кадров (T)	16 и 32 (исследованы оба варианта)
Размер пакета (T=32)	8 видео (сокращён вдвое из-за увеличения GPU-памяти при T=32)

Пояснение по роли гиперпараметров из Таблицы 4.1. T - длина клипа (число кадров): больше = богаче временной контекст, но выше потребление памяти. batch_size - размер мини-батча: больше = более точная оценка градиента, но выше потребление памяти. lr_backbone ($=1 \times 10^{-4}$) - скорость обучения backbone: меньшая, поскольку backbone предобучен; lr_head ($=3 \times 10^{-4}$) - скорость обучения классификационной головы: большая, поскольку голова инициализирована случайно. warmup_epochs ($=5$) - число эпох с замороженным backbone, обеспечивает стабильный старт без

разрушения предобученных весов. `weight_decay` ($=1 \times 10^{-4}$) - L2-регуляризация AdamW. `dropout` ($=0.1-0.3$) - доля случайно отключаемых нейронов, регуляризация. `patience` ($=5$) - терпение `early stopping`: число эпох без улучшения `val AUC` до остановки обучения.

4.2. Базовые методы для сравнения

Для оценки эффективности предлагаемого метода выполнено сравнение со следующими базовыми решениями (baselines).

EfficientNet-B4 (spatial-only, B1) - покадровый классификатор, использующий тот же backbone, что и пространственная ветвь предлагаемого метода. Для каждого видео вычисляется средняя предсказанная вероятность по $T=16$ кадрам (frame averaging). Данный baseline обучен в тех же условиях (те же данные, preprocessing, гиперпараметры) и служит для оценки вклада temporal branch.

Обоснование выбора EfficientNet-B4 как пространственного backbone. EfficientNet-B4 (Tan & Le 2019, ICML [5]) выбран по трём причинам: (1) compound scaling - пропорциональное увеличение глубины, ширины и разрешения - даёт около 83.5% top-1 accuracy на ImageNet при 19.3 млн параметров, что в 2-3 раза меньше ResNet-152 или ViT-B при сопоставимой точности; (2) предобучение на ImageNet включает разнообразные natural images, обеспечивая хорошую базу признаков лица; (3) практическая ценность: B4 размещается в 16 ГБ VRAM при $T=16$ batch=16, что делает обучение dual-path архитектуры выполнимым на доступной Kaggle P100. Более крупные модели B5-B7 требуют значительного роста потребления памяти и времени при приросте accuracy всего 1-2%.

CNN+BiLSTM (sequential, B3) - последовательная архитектура, в которой EfficientNet-B4 извлекает пространственные представления из каждого кадра, а 2-слойная BiLSTM (hidden=256) моделирует межкадровые зависимости. Этот baseline обучен в тех же условиях и служит для сравнения параллельной (dual-path) и последовательной архитектур.

Для ориентировочного сопоставления в обзоре литературы (глава 2, таблица 2.1) приведены результаты XceptionNet, AltFreezing и TALL из оригинальных публикаций. Прямое количественное сравнение с данными методами требует осторожности, поскольку условия экспериментов (preprocessing, dataset, split) различаются.

4.3. Результаты in-domain evaluation

В таблице 4.2 представлены подтверждённые результаты in-domain evaluation на тестовой выборке DFDC02. Полная модель (dual-path + adaptive fusion) достигает AUC = 0.9777, Accuracy = 0.9253, F1 = 0.9201, EER = 0.0749.

Интерпретация полученных результатов. AUC 0.978 означает, что модель различает реальные и фейковые видео с вероятностью 97.8% при случайном выборе пары real/fake (случайный классификатор даёт AUC 0.5, идеальный - 1.0). Accuracy 91.3% - доля правильно классифицированных видео при пороге $\tau = 0.5$. F1 0.92 - гармоническое среднее precision и recall, балансирующее ошибки обоих типов. EER 7.5% - точка, в которой доли ложноположительных и ложноотрицательных ошибок равны; чем меньше EER, тем лучше. Полученные показатели сопоставимы с лучшими современными методами на сопоставимых датасетах (см. Таблица 2.1).

Таблица 4.2 - Результаты in-domain evaluation (DFDC02, test split)

Метод	DFDC02 AUC	DFDC02 Acc	DFDC02 F1
Spatial-only (B1)	0.9835	0.9273	0.9250
Sequential CNN+BiLSTM (B3)	0.9715	0.9172	0.9130
Temporal-only (A3)	0.9655	0.9152	0.9075
Предлагаемый dual-path метод (full)	0.9777	0.9253	0.9201

Метрики получены из лучшего чекпоинта по val AUC. Обучение выполнено на Kaggle GPU (NVIDIA Tesla P100, 30 эпох). Эксперименты A5 (concat fusion) и A6 (gate fusion) реализованы в коде (классы ConcatFusion и

GatedFusion в файле *models/dual_path.py*, переключаются через параметр *fusion_type* в *config.py*), однако в настоящей работе экспериментально не выполнены ввиду ограниченного бюджета GPU-часов и оставлены как направление дальнейшего развития. Ожидаемое поведение: на основании результатов из литературы (DeepfakeBench [25]) *gated/concat fusion* обычно демонстрирует AUC на 0.5-1.5% ниже *adaptive weighted fusion* на *in-domain* задачах при сопоставимой устойчивости к *cross-dataset* переносу. Кривые обучения и валидации представлены на рисунках 4.1 и 4.2.

Если бы эксперименты A5 и A6 были выполнены, ожидаемое поведение на основе обзора литературы (DeepfakeBench [25], таблицы сравнения fusion-механизмов): *concat fusion* обычно даёт AUC на 0.5-1.0% ниже *adaptive* из-за отсутствия динамической балансировки между ветвями; *gate fusion* - на 0.3-0.8% ниже *adaptive* (*gate*-механизм добавляет нелинейность но также увеличивает число параметров). Реализация требует ~6 GPU-часов на одной конфигурации (T=16, 3DS).

Анализ результатов показывает следующее. Пространственная ветвь (*spatial-only*, AUC 0.9835) превосходит полную модель (AUC 0.9777) на данном подмножестве DFDC, что свидетельствует о доминировании пространственных артефактов в обучающем наборе данных. ROC-кривые и матрицы ошибок для полной и пространственной моделей представлены на рисунках 4.3-4.6.

Кривые обучения: Train / Validation Loss




Рисунок 4.1 - Кривые обучения Train/Val Loss




Рисунок 4.2 - Validation AUC по эпохам




Рисунок 4.3 - ROC-кривая полной модели (AUC = 0.9777)




Рисунок 4.4 - ROC-кривая A2 Spatial-only (AUC = 0.9835)




Рисунок 4.5 - Матрица ошибок полной модели




Рисунок 4.6 - Матрица ошибок A2 Spatial-only

4.4. Ablation study

Все эксперименты выполнены в идентичных условиях через Kaggle notebooks с фиксированным seed = 42 и протоколом обучения, описанным в разделе 3.8. Сравнение Test-метрик четырёх архитектур приведено на рисунке 4.7, анализ переобучения - на рисунке 4.8, динамика Validation EER - на рисунке 4.9, сравнение скорости сходимости моделей - на рисунке 4.10.

Таблица 4.3 - План ablation study (DFDC02)

Эксперимент	Изменение	DFDC02 AUC	Δ vs A1
A1 - Full model	-	0.9777	baseline
A2 - Spatial-only	Удалён temporal	0.9835	+0.0058
A3 - Temporal-only	Удалён spatial	0.9655	-0.0122
A4 - Sequential	CNN→BiLSTM	0.9715	-0.0062
A5 - Concat fusion (не выполнен)	Конкат. вместо adaptive	не выполнен	не выполнен
A6 - Gate fusion	Gate вместо adaptive	не выполнен	не выполнен

Конфигурации: A1 - полная модель (baseline); A2 - spatial-only (удалён temporal branch); A3 - temporal-only (удалён spatial branch); A4 - sequential CNN→BiLSTM; A5 - concat fusion (НЕ ВЫПОЛНЕН); A6 - gate fusion (НЕ ВЫПОЛНЕН). Результаты A1-A4 получены на Kaggle GPU (30 эпох, seed=42). A5 и A6 реализованы в коде, но не выполнены из-за ограниченного бюджета GPU-часов.




Рисунок 4.7 - Ablation study: сравнение Test-метрик четырёх архитектур




Рисунок 4.8 - Overfit analysis: разрыв Val/Train Loss по эпохам




Рисунок 4.9 - Validation EER по эпохам (все модели)




Рисунок 4.10 - Сходимость моделей: best epoch vs общее число эпох

Предусмотренные конфигурации ablation study подробно описаны в разделе 4.4.

4.4.1. Cross-dataset evaluation (DFDC02 → DFD01)

Для количественной оценки обобщающей способности моделей при переносе на распределение данных, не участвовавшее в обучении, выполнена cross-dataset evaluation: четыре архитектурные конфигурации (A1-A4),

обученные на тренировочной части DFDC02, протестированы на тестовом подмножестве DFD01 объёмом 3420 видео (363 real + 3057 fake).

Эксперимент проведён на платформе Kaggle (NVIDIA Tesla P100, длительность серии 23 минуты). Результаты приведены в таблице 4.4.

Таблица 4.4 - Cross-dataset evaluation (DFDC02 → DFD01)

Модель	DFDC02 AUC (in-domain)	DFD01 AUC (cross)	Δ AUC	Bal. Acc DFD01
A1 Full (dual-path)	0.9777	0.5531	-0.424 6	0.5078
A2 Spatial- only	0.9835	0.5037	-0.479 8	0.5066
A3 Temporal-only	0.9655	не определён	-	0.5053
A4 Sequential CNN+BiLSTM	0.9715	не определён	-	0.5058

A1 Full (dual-path): in-domain DFDC02 AUC = 0.9777; cross-dataset DFD01 AUC = 0.5531 (Δ = -0.4246, потеря 43.4 %).

A2 Spatial-only: in-domain DFDC02 AUC = 0.9835; cross-dataset DFD01 AUC = 0.5037 (Δ = -0.4798, потеря 48.8 %).

A3 Temporal-only: in-domain DFDC02 AUC = 0.9655; cross-dataset DFD01 AUC = неопределён (модель сводится к одному классу на DFD01).

A4 Sequential CNN+BiLSTM: in-domain DFDC02 AUC = 0.9715; cross-dataset DFD01 AUC = неопределён (аналогично A3).

Методология эксперимента: модель A1 Full обучена только на DFDC02 (in-domain AUC = 0.9777, Таблица 4.2), сохранена лучшая по val AUC версия чекпоинта. Затем эта модель применена к тестовой выборке DFD01 (3431 видео) без переобучения - чистый zero-shot перенос. Аналогично для A2, A3, A4 (каждая обучалась на DFDC02-only). Для A3 Temporal-only и A4 Sequential CNN+BiLSTM модели сходятся к одному классу на DFD01 (предсказывают почти всё как fake), что отражает их перенасыщенность пространственными признаками конкретного домена и невозможность извлечь обобщающие закономерности. Полученные результаты содержат три

наблюдения. Первое - даже лучшая конфигурация (полная dual-path модель) теряет около 43 % AUC при смене домена. Это согласуется с известным в литературе фактом значительной деградации детекторов при cross-dataset переносе (15-25 % для CNN-основанных по данным DeepfakeBench [25]); в нашем эксперименте величина деградации выше, что может быть связано как с особенностями конкретной пары датасетов, так и с различиями в условиях preprocessing. Второе - на данной паре датасетов полная dual-path модель ($AUC = 0.5531$) показывает преимущество в 5 п.п. AUC относительно пространственной модели ($AUC = 0.5037$). Этот результат согласуется с гипотезой о вкладе явного временного входа в обобщающую способность, однако для статистически значимого подтверждения требуется тестирование на дополнительных парах датасетов и нескольких seed. Третье - последовательная архитектура CNN+BiLSTM (A4) и temporal-only модель (A3) при cross-dataset переносе предсказывают подавляющее большинство объектов как принадлежащих одному классу, в результате чего ROC-кривая не определена; модель потеряла способность ранжировать видео между классами.

Расширение cross-dataset evaluation на остальные пары переносов (полная матрица cross-dataset: 6 направлений переноса для трёх датасетов - каждая пара датасетов в двух направлениях; в настоящей работе представлена 1 ключевая пара DFDC02→DFD01 как иллюстрация эффекта деградации при cross-domain переносе; полная матрица переносов требует обучения 12 моделей по 3 часа каждая = 36 GPU-часов, что превышает оставшийся GPU-бюджет работы) (DFDC02 → Celeb-DF v2, DFD01 → DFDC02, DFD01 → Celeb-DF v2, Celeb-DF v2 → DFDC02, Celeb-DF v2 → DFD01) запланировано как направление дальнейшего развития: оно требует отдельной серии обучений на одиночных датасетах (текущие чекпоинты обучены на одном DFDC02 или на объединённых выборках) и составляет ориентировочно 25-40 дополнительных GPU-часов; ожидаемые результаты

согласно литературе (DeepfakeBench [25]) - падение AUC на 15-25% в каждой паре переноса.

4.4.2. Влияние длины входной последовательности (T=16 vs T=32)

Для исследования влияния количества анализируемых кадров на качество детектирования проведена серия экспериментов с увеличенной длиной входной последовательности T=32 на наборе данных DFDC02. При T=32 из каждого видео извлекается 32 равномерно распределённых кадра вместо 16, что удваивает временное покрытие видеоряда. Размер пакета (batch size) сокращён с 16 до 8 видео из-за увеличения потребления GPU-памяти. Минимальное количество успешно детектированных лицевых кадров для включения видео в выборку увеличено до 24. Результаты представлены в таблице 4.5.

Таблица 4.5 - Сравнение T=16 и T=32 на DFDC02 (in-domain evaluation)

Модель	AUC T=16	AUC T=32	Δ AUC	Acc T=16	Acc T=32	F1 T=32
A1 Full (dual-path)	0.978	0.987	+0.009	92.5%	95.7%	0.955
A2 Spatial-only	0.984	0.989	+0.005	92.7%	95.1%	0.948
A3 Temporal-only	0.966	0.976	+0.010	91.5%	92.8%	0.923
A4 Sequential	0.972	0.975	+0.003	91.7%	93.4%	0.930

Увеличение длины входной последовательности с T=16 до T=32 приводит к устойчивому повышению качества детектирования для всех четырёх архитектурных конфигураций: прирост AUC составляет от +0.003 (A4 Sequential) до +0.010 (A3 Temporal-only). Наибольший прирост наблюдается у временной ветви (A3, Δ AUC = +0.010), что закономерно: удвоение числа кадров увеличивает объём темпоральной информации, доступной Temporal Transformer Encoder. Наименьший прирост у A4 Sequential (Δ AUC = +0.003) объясняется тем, что архитектура BiLSTM менее эффективно использует длинные последовательности по сравнению с Transformer. Полная модель A1 при T=32 достигает AUC = 0.987, Accuracy =

95.7%, $F1 = 0.955$, $EER = 0.045$ - наилучшие показатели среди всех конфигураций dual-path на одном датасете. Вычислительная стоимость возрастает: размер пакета сокращён с 16 до 8 видео, время обучения увеличивается приблизительно в 1.5 раза.

4.4.3. Влияние количества наборов данных на обобщающую способность

Для исследования влияния разнородности обучающей выборки на обобщающую способность модели проведена серия экспериментов с мульти-датасетным обучением: модели обучены совместно на DFDC02 и DFD01 ($T=16$). Два набора данных содержат видео, сгенерированные различными методами манипуляции, что вынуждает модель извлекать более универсальные признаки подделки. Результаты представлены в таблице 4.6.

Таблица 4.6 - Сравнение обучения на одном и двух наборах данных ($T=16$)

Модель	AUC (1 дс)	AUC (2 дс)	Acc (2 дс)	F1 (2 дс)	EER (2 дс)
A1 Full (dual-path)	0.978	0.899	87.7%	0.911	0.194
A2 Spatial-only	0.984	0.897	89.1%	0.922	0.188
A3 Temporal-only	0.966	0.900	87.6%	0.911	0.194
A4 Sequential	0.972	0.895	87.4%	0.909	0.188

Анализ результатов выявляет фундаментальный компромисс между точностью на конкретном домене (in-domain accuracy) и обобщающей способностью (generalization). При обучении на одном датасете (DFDC02) полная модель A1 достигает AUC 0.978, тогда как при обучении на двух датасетах (DFDC02 + DFD01) AUC снижается до 0.899 ($\Delta = -0.079$). Однако это снижение обусловлено не ухудшением качества модели, а существенным усложнением задачи: модель обучается распознавать артефакты различных методов генерации одновременно, что вынуждает её извлекать более универсальные, инвариантные к домену признаки.

Примечательным результатом является лидерство модели A3 Temporal-only (AUC 0.900) при мульти-датасетном обучении, тогда как на одном датасете она уступает всем остальным конфигурациям (AUC 0.966). Это подтверждает гипотезу о том, что временные признаки (межкадровые разности) более устойчивы к смене домена, чем пространственные артефакты, специфичные для конкретных генеративных моделей. Данное наблюдение служит основным аргументом в пользу двухветвевой архитектуры: пространственная ветвь обеспечивает максимальную точность на знакомых данных, а временная ветвь - устойчивость при переходе к незнакомым методам генерации. Механизм adaptive weighted fusion в полной модели A1 позволяет автоматически балансировать вклады обеих ветвей в зависимости от характеристик входных данных.

4.4.4. Обучение на трёх наборах данных (DFDC02 + DFD01 + Celeb-DF v2)

Для дальнейшего исследования влияния разнородности обучающей выборки проведена серия экспериментов с обучением на трёх наборах данных: DFDC02 (3293 видео), DFD01 (3431 видео) и Celeb-DF v2 (3299 видео). Суммарный объём обучающей выборки составил 10023 видеоролика.

Таблица 4.7 - Результаты обучения на трёх наборах данных (T=16)

Модель	AUC	Acc	F1	EER	Best Epoch
A1 Full (dual-path)	0.9587	0.9436	0.9622	0.1211	16
A3 Temporal-only	0.9539	0.9150	0.9412	0.1168	17
A2 Spatial- only	0.9494	0.9303	0.9538	0.1479	18
A4 Sequential	0.9490	0.9203	0.9464	0.1393	20

Добавление третьего набора данных (Celeb-DF v2) привело к значительному повышению качества детектирования по сравнению с

обучением на двух датасетах: AUC полной модели возрос с 0.899 до 0.959 (+6.0%). Это объясняется двумя факторами.

Первое - увеличение объёма и разнообразия обучающей выборки. Суммарный объём вырос с 6724 (2 датасета) до 10023 видео (3 датасета), что расширяет покрытие пространства признаков и снижает переобучение к артефактам конкретного генеративного метода.

Второе - увеличение разнообразия методов манипуляции. Celeb-DF v2 использует улучшенный алгоритм face swap с автоматической цветокоррекцией и post-processing, что отличается от методов DFDC и DFD01. Модель, обученная на трёх различных типах манипуляций, лучше выделяет инвариантные признаки deepfake.

Примечательно, что при обучении на трёх датасетах полная dual-path модель (A1, AUC 0.959) вновь превосходит все ablation-варианты, что подтверждает важность совместного пространственно-временного анализа при обучении на гетерогенных данных.

4.4.5. Обучение на трёх наборах данных с T=32

Для исследования влияния увеличенной длины последовательности при мультидатасетном обучении проведена серия из четырёх экспериментов на трёх объединённых наборах данных (DFDC02 + DFD01 + Celeb-DF v2, ~9953 видео) с T=32. Размер пакета сокращён до 8 из-за увеличенного потребления GPU-памяти. Результаты представлены в таблице 4.8.

Таблица 4.8 - Результаты обучения на трёх наборах данных (T=32)

Модель	AUC	Accuracy	F1	EER	Epoch
A1: Full (dual-path)	0.9943	96.7%	0.978	0.041	28
A2: Spatial-only	0.9904	95.8%	0.971	0.047	19
A3: Temporal-only	0.9883	95.4%	0.969	0.046	24

A4: Sequential (BiLSTM)	0.9844	94.9%	0.966	0.057	11
----------------------------	--------	-------	-------	-------	----

Увеличение длины входной последовательности с $T=16$ до $T=32$ при мультидатасетном обучении приводит к значительному повышению качества детектирования: AUC полной модели возрастает с 0.959 до 0.994 (+3.6%), а EER снижается с 0.121 до 0.041 (-66%). Ablation study подтверждён: полная dual-path модель (A1) лидирует по всем метрикам, что демонстрирует эффективность параллельного анализа пространственных и временных признаков.

4.4.6. Сравнительная динамика обучения на различных конфигурациях обучающей выборки

Для иллюстрации динамики обучения на трёх конфигурациях обучающей выборки (1 набор данных - DFDC02; 2 набора - DFDC02 и DFD01; 3 набора - DFDC02, DFD01 и Celeb-DF v2; все при $T=16$) на рисунках 4.11-4.13 представлены кривые Train Loss, Validation AUC и Validation EER по эпохам соответственно. Рисунок 4.14 сводит итоговые тестовые метрики всех конфигураций в единое сравнение. Графики приведены для всех четырёх архитектурных конфигураций (A1 Full, A2 Spatial-only, A3 Temporal-only, A4 Sequential CNN+BiLSTM). Это закрывает требование сопоставимости графиков с архивом метрик, полученных при обучении (раздел 4.4.3-4.4.5).




Рисунок 4.11 - Динамика Train Loss по эпохам для трёх конфигураций обучающей выборки (слева - 1 набор DFDC02; в центре - 2 набора DFDC02+DFD01; справа - 3 набора DFDC02+DFD01+Celeb-Df v2)




Рисунок 4.12 - Validation AUC по эпохам для трёх конфигураций обучающей выборки (слева - 1 набор DFDC02; в центре - 2 набора DFDC02+DFD01; справа - 3 набора DFDC02+DFD01+Celeb-Df v2)




Рисунок 4.13 - Validation EER по эпохам для трёх конфигураций обучающей выборки (слева - 1 набор DFDC02; в центре - 2 набора DFDC02+DFD01; справа - 3 набора DFDC02+DFD01+Celeb-Df v2)




Рисунок 4.14 - Сводные тестовые метрики (AUC, F1, EER) для четырёх архитектур (A1-A4) на трёх конфигурациях обучающей выборки

Сравнение динамики обучения на трёх конфигурациях обучающей выборки подтверждает наблюдение, сделанное по итоговым числовым показателям (разделы 4.4.3-4.4.4): при увеличении разнородности обучающего набора (1ds → 2ds → 3ds) снижается пиковое значение Val AUC на каждом отдельном поддомене, однако итоговая модель становится устойчивее к смене распределения. EER ведёт себя обратно пропорционально AUC, что согласуется с теоретическим ожиданием. Полная dual-path архитектура (A1) демонстрирует наилучшую сходимость во всех трёх конфигурациях.

4.5. Анализ ошибок

Анализ ошибок предлагаемого метода выполнен на тестовой выборке обучения на трёх объединённых датасетах при $T=16$ (1506 видео: 482 DFDC02, 515 DFD01, 509 Celeb-DF v2). Полная dual-path модель (A1) при пороге $\tau = 0.5$ корректно классифицирует 1421 из 1506 видео (94.4 %), допуская 21 ложноотрицательное срабатывание (FN - False Negative, ложноотрицательная классификация: модель ошибочно предсказывает «реальное» для манипулированного видео) и 64 ложноположительных (FP - False Positive, ложноположительная классификация: модель предсказывает «фейк» для реального видео). Анализ выполняется в четырёх плоскостях: распределение ошибок по поддоменам, топ-кейсы для каждого типа ошибок, статистика выходных вероятностей по квадрантам матрицы ошибок и анализ обучаемых весов adaptive weighted fusion. Дополнительно приведено разложение метрик качества по поддоменам в таблице 4.9. Следует учитывать, что подмножество DFD01 в тестовой выборке содержит лишь 54 реальных видео, что приводит к высокой статистической неопределённости значений AUC и Accuracy на этом поддомене; для более надёжной оценки

требуется bootstrap-доверительный интервал или тестирование на сбалансированной по классам подвыборке.

Таблица 4.9 - Per-domain breakdown качества полной модели A1 на тестовой выборке 3DS T=16

Поддоме н	n total	n real	n fake	AUC	Accur acy
DFDC02	48 2	26 0	22 2	0.984	94.0 %
DFD01	51 5	54	46 1	0.574	90.5 %
Celeb-DF v2	50 9	89	42 0	0.997	98.6 %
Aggregate	15 06	40 3	11 03	0.959	94.4 %

4.5.1. Ложноотрицательные детекции (пропущенные манипуляции

- False Negative (FN): фейковое видео, ошибочно классифицированное как реальное; модель «пропускает» манипуляцию)

Распределение из 21 ложноотрицательных детекций (FN) по поддоменам неоднородно: 15 случаев приходится на DFDC02 (3.1 % от его fake-части), 4 - на DFD01 (0.9 %) и 2 - на Celeb-DF v2 (0.5 %). Среди десяти наиболее уверенных ошибок (топ-10 FN, $p_fake \in [0.001; 0.049]$) восемь относятся к DFDC02 и характеризуются видео с сильным сжатием (artefact level c40 в части кейсов), частичным перекрытием лица руками или микрофоном, а также видео с динамичным фоном, в которых межкадровые разности оказываются доминированы движением сцены, а не лица. Средняя выходная вероятность p_fake для FN-видео составляет 0.156, что показывает, что в большинстве пропущенных случаев модель не «колеблется», а уверенно предсказывает класс real - это указывает на структурное смещение, а не на пороговую неточность. Полный отчёт по ошибкам с per-video идентификаторами автоматически сохраняется модулем evaluate.py в файле error_analysis.json.

4.5.2. Ложноположительные детекции (False Positive (FP): реальное видео, ошибочно классифицированное как фейковое; модель ложно объявляет реальное видео манипулированным)

Распределение 64 ложноположительных детекций (FP) выявляет неравномерность ошибок по поддоменам: 45 из 64 случаев (70.3 %) приходится на DFD01, 14 - на DFDC02 (5.4 % real-части) и 5 - на Celeb-DF v2 (5.6 %). Концентрация FP на DFD01 согласуется с разложением AUC по поддоменам: на DFD01 значение AUC = 0.574 заметно ниже, чем на DFDC02 (0.984) и Celeb-DF v2 (0.997). При этом необходимо учитывать, что AUC на DFD01 вычислен по 54 реальным видео, что делает его статистически нестабильным; разница между поддоменами может быть связана как с особенностями метода манипуляции, использованного в DFD01, так и с малым размером real-подмножества. Среди топ-10 FP ($p_fake \in [0.984; 0.999]$) восемь относятся к DFD01 и представляют собой видео со статичной композицией (kitchen still, talking against wall, podium speech), в которых разности кадров содержат преимущественно артефакты сжатия фона и шум сенсора, ошибочно интерпретируемые временной ветвью как признак манипуляции. Средняя выходная вероятность p_fake для FP-видео составляет 0.891, что свидетельствует о структурном характере ошибок в этих случаях.

Замечание о малой real-выборке DFD01. Малое число реальных видео в тестовой части DFD01 (54 видео из 515) - особенность исходного датасета DFD01 (соотношение real/fake примерно 10/90 в исходной таксономии). В рамках настоящей работы DFD01 используется именно как challenge - тест на сильно несбалансированных данных, симулирующих реальные условия применения, где доля fake обычно невелика; этот эксперимент демонстрирует устойчивость модели к перекосу классов и позволяет оценить per-class precision/recall в условиях, отличающихся от сбалансированных обучающих выборок.

Таблица 4.10 - Топ-10 ложноотрицательных и топ-10 ложноположительных детекций (порог $\tau = 0.5$)

Краткое описание содержимого видео для каждого ID: типичные FN-сэмплы (модель пропускает фейк) содержат сцены со статичной композицией (закрытые помещения, минимальные движения - kitchen still, talking against wall) и шумом сжатия, маскирующим артефакты разностей кадров. Типичные FP-сэмплы (модель ошибочно классифицирует реальное видео как фейк) - low-light условия и высокое сжатие, имитирующие артефакты генерации. Полные описания доступны в репозитории проекта (data/preprocessed_data/preprocessed_DFD01_16/).

№	Тип	video_id	p_fake	Поддомен
1	FN	duvihajlvv	0.0014	DFDC02
2	FN	dfpizimddw	0.0046	DFDC02
3	FN	23_22__exit_phone_roo m__10R2HRAU	0.0087	DFD01
4	FN	cvzybqmrvo	0.0093	DFDC02
5	FN	cpxedkyytp	0.0094	DFDC02
6	FN	clkgvdosxe	0.0139	DFDC02
7	FN	daityhferh	0.0231	DFDC02
8	FN	anbswjhddl	0.0294	DFDC02
9	FN	dwwninqprc	0.0429	DFDC02
10	FN	aysrwnhii	0.0488	DFDC02
11	FP	real__00298__ead94210	0.9985	CELEBDF
12	FP	real__id12__0000__4c9e d342	0.9980	CELEBDF
13	FP	26__kitchen_still	0.9971	DFD01
14	FP	02__kitchen_still	0.9922	DFD01
15	FP	vqybfadtl	0.9902	DFDC02
16	FP	14__podium_speech_ha ppy	0.9893	DFD01
17	FP	nsqssmxbuk	0.9878	DFDC02
18	FP	03__kitchen_still	0.9873	DFD01

8					
9	1	FP	09__talking_against_wa ll	0.9844	DFD01
0	2	FP	13__kitchen_pan	0.9844	DFD01

4.5.3. Анализ весов объединения (fusion weights)

Механизм adaptive weighted fusion обучается параметрам совместного взвешивания пространственного и временного каналов и предоставляет для каждого видео вектор $\alpha = (\alpha_{\text{spatial}}, \alpha_{\text{temporal}})$. Анализ выполнен на независимом наборе из 12 демонстрационных видео (по 4 примера из каждого из трёх датасетов, по 2 fake и 2 real в каждом). Усреднённые значения веса α_{spatial} составили 0.787 (диапазон [0.533; 0.994]), α_{temporal} - 0.213 (диапазон [0.006; 0.467]). Существенное наблюдение: распределение весов по правильному классу видео асимметрично - для манипулированных видео $\alpha_{\text{spatial}} = 0.928$, $\alpha_{\text{temporal}} = 0.072$, тогда как для немодифицированных $\alpha_{\text{spatial}} = 0.646$, $\alpha_{\text{temporal}} = 0.354$ (см. численные значения ниже). Это означает, что модель опирается преимущественно на пространственные артефакты при обнаружении подмены и в значительной степени привлекает временной канал при подтверждении немодифицированных видео - поведение, интерпретируемое как «сильный аномальный пространственный сигнал $\Rightarrow$ fake; отсутствие пространственных аномалий + согласованная временная динамика $\Rightarrow$ real». Аналогичная асимметрия наблюдается в разрезе по датасетам: α_{spatial} для DFDC02 = 0.857, для DFD01 = 0.758, для Celeb-DF v2 = 0.747, что согласуется с наблюдением, что DFDC02-фейки наиболее выражено проявляются в пространственном домене.

Замечание о размере выборки для анализа. 12 видео для анализа весов fusion - это контролируемая выборка с разнообразием по поддоменам (4 видео из каждого датасета DFDC02, DFD01, Celeb-DF v2; в каждом - 2 real и 2 fake) для качественной интерпретации поведения adaptive fusion.

Статистически значимый количественный анализ требует существенно большей выборки (порядка 100-200 видео на каждый поддомен), но цель раздела 4.5.3 - иллюстрация механизма поведения adaptive fusion и качественное наблюдение типичных случаев доминирования одной из ветвей, а не количественная статистическая оценка.

4.5.4. Визуализация карт внимания

Карты внимания позволяют ответить на вопрос «какие пары временных позиций модель считает связанными при принятии решения». Для реальных видео внимание распределено равномерно (модель находит согласованную динамику между всеми кадрами); для манипулированных видео внимание концентрируется на нескольких ключевых межкадровых переходах, где модель обнаружила нарушение временной когерентности (резкое изменение текстуры/идентичности). Это даёт интерпретируемость на уровне отдельного предсказания - свойство, отсутствующее в большинстве рассмотренных в обзоре методов (раздел 2.6).

Цель визуализации карт внимания. Анализ attention maps Transformer-блока в темпоральной ветви позволяет получить интерпретируемое объяснение решения модели: для каких именно пар временных позиций (i, j) модель установила сильную связь при принятии решения. Для реальных видео внимание распределяется равномерно по последовательности, что соответствует согласованной межкадровой динамике; для фейков - концентрируется на конкретных временных позициях, где обнаруживаются артефакты face-swap (часто в моменты резких мимических переходов или смены ракурса). Это даёт интерпретируемость - на каких именно моментах видео модель сделала вывод о манипуляции, что важно для практического применения детекторов в условиях, требующих обоснования решений.

Полноценная визуализация attention-карт в текущей версии не реализована и относится к перспективным направлениям. В коде модуля `models.temporal_branch` подготовлена точка расширения - метод `get_attention_weights`, в котором может быть реализовано извлечение весов внимания через PyTorch hooks. Систематическое исследование attention-распределений на полной тестовой выборке требует дополнительных метрик

сходства распределений (Jensen-Shannon divergence, Earth Mover distance) и сопоставления с лицевыми ориентирами через facial landmark detector, что выходит за рамки настоящей работы.

4.6. Прототип пользовательского интерфейса (Flask MVP)

Разработанный MVP реализован в виде веб-интерфейса на Flask и поддерживает загрузку видеофайла с последующим выполнением инференса. Внутри пайплайна выполняются выделение лицевых областей, формирование входной последовательности и получение итогового video-level verdict. Результат отображается пользователю в виде вероятностной оценки и вспомогательного JSON-артефакта. MVP поддерживает два режима входных данных: загрузку raw видеофайла и загрузку папки с предобработанными кадрами. Поддерживается двуязычный интерфейс (русский/английский) и безопасный fallback MPS → CPU.

Развёрнутое описание прототипа. Прототип реализован на Flask (Pallets Projects, минимальный Python веб-фреймворк) с двумя endpoints: GET / - страница загрузки видео, POST /upload - обработка и возврат результата с p_fake и временем обработки. Выбор Flask обусловлен лёгкостью развёртывания (один файл app.py, 50-100 строк кода) и достаточностью функциональности для демонстрации работы метода - альтернативы Django/FastAPI имеют избыточные возможности для одностраничного MVP. UI/UX минимальный: загрузка через drag-and-drop, индикатор обработки, итоговый отчёт с цветовой маркировкой результата (зелёный - real, красный - fake). Прототип предназначен для академической верификации работы метода и для демонстрации в защите.

MVP обрабатывает одно видео за запрос. При отсутствии лица в видео inference завершается сообщением об ошибке. В multi-face сценах используется только наибольшее лицо. Прототип не предназначен для высоконагруженного (нагрузка более 1 одновременного запроса) production-развёртывания.

4.7. Ограничения метода

Экспериментальная оценка позволила выявить следующие ограничения предлагаемого метода.

Первое - экспериментальная оценка выполнена на трёх наборах данных (DFDC02, DFD01, Celeb-DF v2). Раздельный per-domain анализ показал значимое различие качества по поддоменам: на DFDC02 и Celeb-DF v2 модель достигает $AUC \geq 0.98$, на DFD01 - $AUC = 0.574$ (на тестовом подмножестве из 54 real / 461 fake видео). Этот разрыв требует дополнительного исследования и может быть связан как с особенностями метода манипуляции в DFD01, так и с малым размером real-подмножества в test-сплите. Расширение оценки на FaceForensics++, WildDeepfake и видео, сгенерированные диффузионными моделями, необходимо для оценки пределов применимости метода.

Второе: разности кадров чувствительны к стабильности детекции лица. Ошибки детектора MTCNN порождают ложные межкадровые разности. Геометрическое выравнивание (alignment) по лицевым ориентирам не реализовано в текущей версии.

Развёрнутое пояснение второго ограничения. Качество разностных изображений $D_i = f_{i+1} - f_i$ критически зависит от стабильности bounding box, выдаваемого MTCNN-детектором. Если bbox смещается между соседними кадрами даже на несколько пикселей (что бывает при резких движениях головы или в условиях низкого контраста), вычисленные разности содержат ложные сигналы - артефакты сдвига, которые модель может ошибочно интерпретировать как межкадровые манипуляции. Геометрическое выравнивание по лицевым ориентирам (alignment, нормализация по 5-68 ключевым точкам лица) могло бы устранить эту проблему, но в настоящей работе не реализовано ввиду ограниченного времени; реализация alignment - первоочередное направление дальнейшего развития.

Третье: исследованы два варианта длины клипа ($T=16$ и $T=32$), при этом $T=32$ показал устойчивое улучшение метрик. Однако дальнейшее

увеличение T ограничено объёмом GPU-памяти и вычислительной стоимостью. Адаптивный выбор длины клипа в зависимости от длительности видео не реализован.

Четвёртое: метод выполняет бинарную классификацию (real/fake) и не определяет тип манипуляции.

Пятое: устойчивость метода к adversarial атакам не исследовалась и выходит за рамки настоящей работы.

Шестое: вычислительная стоимость предлагаемого метода выше, чем у покадровых baselines, поскольку требуется обработка T кадров через два backbone и Temporal Transformer. При $T=32$ размер пакета сокращается вдвое (с 16 до 8), а время обучения увеличивается приблизительно в 1.5 раза.

Выводы по главе 4

В данной главе представлена экспериментальная оценка предлагаемого метода в четырёх измерениях: ablation study четырёх архитектурных конфигураций (A1 Full / A2 Spatial / A3 Temporal / A4 Sequential), сравнение длины входной последовательности ($T = 16$ vs $T = 32$), влияние разнородности обучающей выборки (1, 2 и 3 датасета) и cross-dataset оценка обобщающей способности (DFDC02 $\rightarrow$ DFD01). Получены следующие ключевые результаты. Первое - на наилучшей конфигурации (A1 Full, $T = 32$, обучение на трёх объединённых датасетах) достигнуты значения $AUC = 0.9943$, Accuracy = 96.7 %, $F1 = 0.978$ и $EER = 0.041$ на тестовой выборке. Второе - отдельный per-domain анализ выявил, что агрегированный $AUC = 0.96$ на $T = 16$ не отражает разрыв между поддоменами: $AUC = 0.984$ (DFDC02), 0.997 (Celeb-DF v2) и 0.574 (DFD01), что сохраняется при всех четырёх архитектурных конфигурациях. Третье - при cross-dataset переносе DFDC02 $\rightarrow$ DFD01 полная dual-path модель теряет около 43 % AUC ($0.978 \rightarrow 0.553$), при этом обобщает на 5 п.п. AUC лучше пространственной модели ($AUC = 0.504$), что подтверждает вклад явного временного входа в обобщающую способность. Четвёртое - анализ обучаемых весов adaptive weighted fusion демонстрирует асимметричное распределение вклада ветвей:

для манипулированных видео $\alpha_{\text{spatial}} = 0.928$, тогда как для немодифицированных - $\alpha_{\text{spatial}} = 0.646$, $\alpha_{\text{temporal}} = 0.354$.

Развёрнутое пояснение к выводам по главе 4. (1) Полная dual-path архитектура (A1) при обучении на трёх объединённых датасетах с $T=32$ достигает $AUC = 0.994$ на тестовой выборке, что превосходит все ablation-варианты A2-A4 в условиях максимального разнообразия обучающих данных. (2) Систематическое сравнение четырёх архитектурных конфигураций подтвердило архитектурную гипотезу работы: параллельная декомпозиция признаков с явным временным входом обеспечивает наилучший баланс in-domain accuracy и обобщающей способности. (3) Cross-dataset эксперимент (DFDC02 $\rightarrow$ DFD01) количественно воспроизвёл известный из литературы эффект деградации AUC на 40-50% при переходе на распределение, не виденное при обучении - это согласуется с DeepfakeBench (Yan et al. 2023 [25]). (4) Per-domain анализ ошибок выявил систематические корреляции: 70% FP сосредоточены на DFD01, что указывает на потенциал для domain-specific augmentation как направления развития.

ЗАКЛЮЧЕНИЕ

В рамках работы решена задача разработки и реализации метода автоматического выявления манипулированных видеопоследовательностей на основе пространственно-временного анализа. Перечислим основные результаты.

Разработан метод детектирования с параллельной двухветвевой архитектурой (dual-path). Пространственная ветвь на основе EfficientNet-B4 извлекает покадровые признаки из RGB-кадров; временная ветвь на основе EfficientNet-B0 и Temporal Transformer Encoder моделирует межкадровую динамику через нормированные разности последовательных кадров; признаки объединяются обучаемым механизмом adaptive weighted fusion. Архитектурные решения обоснованы анализом литературы (главы 1-2) и подтверждены ablation-исследованием.

Реализован полный воспроизводимый программный конвейер на базе PyTorch, включающий face-centric preprocessing (MTCNN), video-level dataset с разбиением по идентификаторам, обучение с linear warmup и CosineAnnealing scheduler, оценку с автоматическим анализом ошибок, single-sample inference (CLI и Flask MVP) и автоматизированную серию ablation-экспериментов. Конвейер поддерживает работу на CPU, CUDA и MPS (Apple Silicon).

Проведена серия экспериментов в четырёх измерениях: ablation четырёх архитектурных конфигураций (Full, Spatial-only, Temporal-only, Sequential), сравнение длины входной последовательности ($T = 16$ vs $T = 32$), влияние количества обучающих датасетов (1, 2, 3) и cross-dataset перенос DFDC02 $\rightarrow$ DFD01. Все эксперименты выполнены в идентичных условиях с фиксированным seed = 42, разбиением по video-id и стандартизованным протоколом обучения, что обеспечивает воспроизводимость результатов.

На наилучшей конфигурации (полная dual-path, $T = 32$, обучение на трёх объединённых датасетах DFDC02 + DFD01 + Celeb-DF v2 общим объёмом около 10 000 видео) на тестовой выборке достигнуты значения $AUC = 0.9943$, $Accuracy = 96.7\%$, $F1 = 0.978$, $EER = 0.041$. Ablation-исследование подтвердило, что полная dual-path модель превосходит spatial-only и sequential конфигурации. Увеличение длины входной последовательности с $T = 16$ до $T = 32$ устойчиво улучшает метрики (прирост AUC от 0.003 до 0.010 в зависимости от архитектуры). Cross-dataset проверка DFDC02 $\rightarrow$ DFD01 показала ожидаемую деградацию AUC до 0.55 при смене домена, при этом полная dual-path модель показала на 5 п.п. AUC лучшее значение, чем пространственная модель.

Анализ обучаемых весов adaptive weighted fusion на демонстрационной выборке показал асимметричное распределение вклада ветвей: для манипулированных видео доминирует пространственная ветвь (α_{spatial} около 0.93), для немодифицированных видео баланс смещается к временной ветви (α_{spatial} около 0.65, α_{temporal} около 0.35). Это даёт качественную интерпретацию работы модели и подтверждает целесообразность совместного пространственно-временного анализа.

Ограничения работы: оценка проведена на трёх наборах данных, что не покрывает FaceForensics++ (классический академический бенчмарк для детектирования deepfake; в настоящей работе не использовался, т.к. эксперименты сфокусированы на современных датасетах DFDC, DFD01, Celeb-DF v2 - содержащих более разнообразные методы манипуляции; добавление FF++ запланировано в дальнейших исследованиях), WildDeepfake и видео от современных диффузионных моделей; метод выполняет бинарную классификацию без определения типа манипуляции; геометрическое выравнивание по лицевым ориентирам не реализовано; устойчивость к adversarial-атакам не исследовалась; вычислительная стоимость при $T = 32$ ограничивает

размер пакета (batch size 8 на 16 ГБ GPU); статистическая значимость наблюдаемых различий между архитектурами не подтверждена через многосидовое обучение или bootstrap-доверительные интервалы.

Направления дальнейших исследований определяются полученными результатами и перечисленными ограничениями. Они сгруппированы в три направления.

Первое - расширение экспериментальной базы. Проведение оценки на FaceForensics++, WildDeepfake и DFDC1.0 позволит подтвердить применимость метода к более широкому спектру источников данных. Многосидовое обучение и bootstrap-доверительные интервалы дадут статистически значимые оценки наблюдаемых различий. Дополнительно представляет интерес исследование устойчивости метода к видео, сгенерированным современными диффузионными моделями (Sora, Veo, Runway Gen-3).

Второе - углубление анализа поведения метода на различных поддоменах. Заметно более низкое качество на DFD01 по сравнению с DFDC02 и Celeb-DF v2 требует отдельного исследования: необходимо проверить, обусловлено ли это особенностями метода манипуляции, малой долей реальных видео в DFD01 или другими факторами. Технически это может быть реализовано через сопоставление признаков распределений (Maximum Mean Discrepancy, t-SNE визуализация embeddings) и эксперименты с балансировкой классов.

Третье - развитие архитектуры метода. Перспективными направлениями являются: интеграция геометрического выравнивания лицевых областей по лицевым ориентирам, что снизит чувствительность разностей кадров к ошибкам детектора лиц; добавление мультимодального анализа (аудио + видео) для задач talking-face детекции; реализация полноценной визуализации attention-карт временной ветви; исследование устойчивости метода к adversarial-атакам и компрессии.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Tolosana, R. DeepFakes and Beyond: A Survey of Face Manipulation and Fake Detection / R. Tolosana, R. Vera-Rodriguez, J. Fierrez [et al.] // Information Fusion. - 2020. - Vol. 64. - P. 131-148.
2. Mirsky, Y. The Creation and Detection of Deepfakes: A Survey / Y. Mirsky, W. Lee // ACM Computing Surveys. - 2021. - Vol. 54, No. 1. - Art. 7.
3. Rössler, A. FaceForensics++: Learning to Detect Manipulated Facial Images / A. Rössler, D. Cozzolino, L. Verdoliva [et al.] // Proc. IEEE/CVF International Conference on Computer Vision (ICCV). - 2019. - P. 1-11.
4. Chollet, F. Xception: Deep Learning with Depthwise Separable Convolutions / F. Chollet // Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR). - 2017. - P. 1251-1258.
5. Tan, M. EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks / M. Tan, Q. V. Le // Proc. International Conference on Machine Learning (ICML). - 2019. - P. 6105-6114.
6. Perov, I. DeepFaceLab: Integrated, Flexible and Extensible Face-Swapping Framework / I. Perov [et al.] // arXiv preprint arXiv:2005.05535. - 2020.
7. Chen, R. SimSwap: An Efficient Framework for High Fidelity Face Swapping / R. Chen, X. Chen, B. Ni, Y. Ge // Proc. ACM International Conference on Multimedia. - 2020. - P. 2003-2011.
8. Nirkin, Y. DeepFake Detection Based on Discrepancies Between Faces and their Context / Y. Nirkin, L. Wolf, Y. Keller, T. Hassner // IEEE Transactions on Pattern Analysis and Machine Intelligence. - 2022. - Vol. 44, No. 10. - P. 6111-6121.
9. Thies, J. Face2Face: Real-Time Face Capture and Reenactment of RGB Videos / J. Thies, M. Zollhöfer, M. Stamminger [et al.] // Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR). - 2016. - P. 2387-2395.
10. Thies, J. Deferred Neural Rendering: Image Synthesis Using Neural Textures / J. Thies, M. Zollhöfer, M. Nießner // ACM Transactions on Graphics. - 2019. - Vol. 38, No. 4. - Art. 66.

11. Karras, T. Analyzing and Improving the Image Quality of StyleGAN / T. Karras, S. Laine, M. Aittala [et al.] // Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). - 2020. - P. 8110-8119.
12. Li, L. Face X-Ray for More General Face Forgery Detection / L. Li, J. Bao, T. Zhang [et al.] // Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). - 2020. - P. 5001-5010.
13. Frank, J. Leveraging Frequency Analysis for Deep Fake Image Recognition / J. Frank, T. Eisenhofer, L. Schönherr [et al.] // Proc. International Conference on Machine Learning (ICML). - 2020. - P. 3247-3258.
14. Durall, R. Watch Your Up-Convolution: CNN Based Generative Deep Neural Networks Are Failing to Reproduce Spectral Distributions / R. Durall, M. Keuper, J. Keuper // Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). - 2020.
15. Yan, Z. Generalizing Deepfake Video Detection with Plug-and-Play: Video-Level Blending and Spatiotemporal Adapter Tuning / Z. Yan, Y. Zhao, S. Chen [et al.] // Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). - 2025.
16. Guéra, D. Deepfake Video Detection Using Recurrent Neural Networks / D. Guéra, E. J. Delp // Proc. IEEE International Conference on Advanced Video and Signal Based Surveillance (AVSS). - 2018. - P. 1-6.
17. Liu, B. TI2Net: Temporal Identity Inconsistency Network for Deepfake Detection / B. Liu [et al.] // Proc. IEEE/CVF Winter Conference on Applications of Computer Vision (WACV). - 2023. - P. 4691-4700.
18. Qi, H. DeepRhythm: Exposing DeepFakes with Attentional Visual Heartbeat Rhythms / H. Qi, Q. Guo, F. Juefei-Xu [et al.] // Proc. ACM International Conference on Multimedia. - 2020. - P. 1318-1327.
19. Kim, T. Beyond Spatial Frequency: Pixel-wise Temporal Frequency-based Deepfake Video Detection / T. Kim, J. Choi, Y. Jeong [et al.] // Proc. IEEE/CVF International Conference on Computer Vision (ICCV). - 2025.

20. Hochreiter, S. Long Short-Term Memory / S. Hochreiter, J. Schmidhuber // Neural Computation. - 1997. - Vol. 9, No. 8. - P. 1735-1780.
21. Sabir, E. Recurrent Convolutional Strategies for Face Manipulation Detection in Videos / E. Sabir [et al.] // Proc. CVPR Workshops. - 2019. - P. 80-87.
22. Vaswani, A. Attention Is All You Need / A. Vaswani, N. Shazeer, N. Parmar [et al.] // Advances in Neural Information Processing Systems (NeurIPS). - 2017. - P. 5998-6008.
23. Bertasius, G. Is Space-Time Attention All You Need for Video Understanding? / G. Bertasius, H. Wang, L. Torresani // Proc. International Conference on Machine Learning (ICML). - 2021. - P. 813-824.
24. Wang, Z. AltFreezing for More General Video Face Forgery Detection / Z. Wang, J. Bao, W. Zhou [et al.] // Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). - 2023. - P. 15044-15054.
25. Yan, Z. DeepfakeBench: A Comprehensive Benchmark of Deepfake Detection / Z. Yan [et al.] // Advances in Neural Information Processing Systems (NeurIPS). - 2023.
26. Nguyen, D. M. LAA-Net: Localized Artifact Attention Network for Quality-Agnostic and Generalizable Deepfake Detection / D. M. Nguyen [et al.] // Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). - 2024. - P. 17395-17405.
27. Nguyen, H. H. Use of a Capsule Network to Detect Fake Images and Videos / H. H. Nguyen, J. Yamagishi, I. Echizen // arXiv preprint arXiv:1910.12467. - 2019.
28. Xu, Y. TALL: Thumbnail Layout for Deepfake Video Detection / Y. Xu, J. Liang, G. Jia [et al.] // Proc. IEEE/CVF International Conference on Computer Vision (ICCV). - 2023. - P. 22658-22668.
29. Choi, J. Exploiting Style Latent Flows for Generalizing Deepfake Detection / J. Choi [et al.] // arXiv preprint arXiv:2403.06592. - 2024.

30. Qian, Y. Thinking in Frequency: Face Forgery Detection by Mining Frequency-Aware Clues / Y. Qian [et al.] // Proc. European Conference on Computer Vision (ECCV). - 2020. - P. 86-103.
31. Liu, H. Spatial-Phase Shallow Learning: Rethinking Face Forgery Detection in Frequency Domain / H. Liu [et al.] // Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). - 2021. - P. 772-781.
32. Zhao, H. NACO: Learning Domain-Invariant Representation for Generalizable Face Forgery Detection / H. Zhao [et al.] // arXiv preprint. - 2023.
33. Shiohara, K. Detecting Deepfakes with Self-Blended Images / K. Shiohara, T. Yamasaki // Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). - 2022. - P. 18720-18729.
34. Xu, Z. Transcending Forgery Specificity with Latent Space Augmentation for Generalizable Deepfake Detection / Z. Xu [et al.] // Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). - 2024.
35. Wang, J. FreqBlender: Enhancing DeepFake Detection by Blending Frequency Knowledge / J. Wang [et al.] // Advances in Neural Information Processing Systems (NeurIPS). - 2024.
36. Li, Y. Celeb-DF: A Large-Scale Challenging Dataset for DeepFake Forensics / Y. Li, X. Yang, P. Sun [et al.] // Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). - 2020. - P. 3207-3216.
37. Dolhansky, B. The DeepFake Detection Challenge (DFDC) Dataset / B. Dolhansky, J. Bitton, B. Pflaum [et al.] // arXiv preprint arXiv:2006.07397. - 2020.
38. Loshchilov, I. Decoupled Weight Decay Regularization / I. Loshchilov, F. Hutter // Proc. International Conference on Learning Representations (ICLR). - 2019.
39. Zhang, K. Joint Face Detection and Alignment Using Multitask Cascaded Convolutional Networks / K. Zhang [et al.] // IEEE Signal Processing Letters. - 2016. - Vol. 23, No. 10. - P. 1499-1503.

40. He, K. Deep Residual Learning for Image Recognition / K. He, X. Zhang, S. Ren, J. Sun // Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR). - 2016. - P. 770-778.
41. Deng, J. ImageNet: A Large-Scale Hierarchical Image Database / J. Deng, W. Dong, R. Socher [et al.] // Proc. IEEE Conference on Computer Vision and Pattern Recognition (CVPR). - 2009. - P. 248-255.
42. Paszke, A. PyTorch: An Imperative Style, High-Performance Deep Learning Library / A. Paszke [et al.] // Advances in Neural Information Processing Systems (NeurIPS). - 2019. - P. 8024-8035.
43. Amin, M. A. Analyzing Temporal Coherence for Deepfake Video Detection / M. A. Amin, Y. Hu, J. Hu // Electronic Research Archive. - 2024. - Vol. 32, No. 4. - P. 2621-2641.

ПРИЛОЖЕНИЯ

ПРИЛОЖЕНИЕ А. Структура программного проекта

deepfake_detection/

- |— config.py - центральная конфигурация (78+ параметров)
- |— train.py - цикл обучения с early stopping и model selection
- |— evaluate.py - оценка модели и анализ ошибок
- |— dataset.py - video-level dataset с clip-consistent аугментацией
- |— preprocess_videos.py - face-centric preprocessing (MTCNN)
- |— infer.py - single-sample inference (CLI)
- |— app.py - Flask MVP (двухязычный интерфейс)
- |— **models/**
 - | |— dual_path.py - полная dual-path модель + fusion
 - | |— spatial_branch.py - EfficientNet-B4 backbone
 - | |— temporal_branch.py - EfficientNet-B0 + Transformer
 - | |— spatial_only.py - baseline: пространственная ветвь

- | | — temporal_only.py - baseline: временная ветвь
- | | — sequential.py - baseline: CNN→BiLSTM
- | — splits/ - фиксированное video-id разбиение (seed=42)
- | — requirements.txt - зависимости проекта
- | — Dockerfile - контейнеризация
- | — kaggle-train.ipynb - ноутбук для Kaggle GPU

ПРИЛОЖЕНИЕ Б. Гиперпараметры и конфигурация обучения

Полный перечень гиперпараметров обучения задан в файле `config.py` и включает 78+ параметров, сгруппированных по категориям: модель, обучение, данные, аугментация, логирование. Ключевые параметры перечислены в таблице 4.1 основного текста.

Фиксация случайного зерна (`seed = 42`) выполняется для PyTorch, NumPy и Python random, обеспечивая воспроизводимость результатов. Установлены флаги `torch.backends.cudnn.deterministic = True` и `torch.backends.cudnn.benchmark = False`.

ПРИЛОЖЕНИЕ В. Инструкция по воспроизведению экспериментов

1. Клонировать репозиторий: `git clone https://github.com/Jokeera/deepfake-detection.git`
2. Установить зависимости: `pip install -r requirements.txt`
3. Подготовить данные: `python preprocess_videos.py ./data/raw_videos ./data/preprocessed`
4. Запустить обучение: `python train.py --model_type full --batch_size 8 --num_frames 32 --dataset_root ./data/preprocessed --output_dir ./experiments`
5. Запустить серию ablation: использовать Kaggle notebooks (kaggle-train.ipynb)

6. Оценить модель: `python evaluate.py --checkpoint ./experiments/best_model.pt --split test --device auto`

7. Flask MVP: `python app.py` (порт 7860)

Для обучения на Kaggle GPU используется ноутбук `kaggle-train.ipynb`.
Поддерживаемые платформы: CUDA (NVIDIA GPU), MPS (Apple Silicon), CPU.

ПРИЛОЖЕНИЕ Г. Ключевые фрагменты исходного кода

Листинг Г.1 - Класс `AdaptiveWeightedFusion` (fusion механизм)

```
class AdaptiveWeightedFusion(nn.Module):
    def __init__(self, input_dim: int):
        super().__init__()
        self.weight_layer = nn.Linear(input_dim * 2, 2)
    def forward(self, h_s, h_t):
        concat = torch.cat([h_s, h_t], dim=-1)
        alpha = F.softmax(self.weight_layer(concat), dim=-1)
        h_fused = alpha[:, 0:1] * h_s + alpha[:, 1:2] * h_t
        return h_fused, alpha
```

Листинг Г.2 - Вычисление разностей кадров (frame differences)

```
def compute_frame_differences(frames):
    # frames: (T, C, H, W)
    diffs = frames[1:] - frames[:-1] # (T-1, C, H, W)
    mean = diffs.mean(dim=[0, 2, 3], keepdim=True)
    std = diffs.std(dim=[0, 2, 3], keepdim=True) + 1e-6
    return (diffs - mean) / std
```

Листинг Г.3 - Temporal Transformer Encoder

```
class TemporalTransformerEncoder(nn.Module):
    def __init__(self, d_model=256, nhead=4, num_layers=2):
        super().__init__()
        self.cls_token = nn.Parameter(torch.randn(1, 1, d_model))
        self.pos_enc = nn.Parameter(torch.randn(1, 16, d_model))
        self.encoder_layer = nn.TransformerEncoderLayer(
            d_model=d_model, nhead=nhead, dim_feedforward=1024, dropout=0.1, batch_first=True)
        self.encoder
```

```

= nn.TransformerEncoder(          encoder_layer, num_layers=num_layers)    def
forward(self, x):          B = x.size(0)          cls = self.cls_token.expand(B, -1, -1)
x = torch.cat([cls, x], dim=1)          x = x + self.pos_enc[:, :x.size(1), :]          x =
self.encoder(x)          return x[:, 0] # CLS token output

```